LightGCL cho gợi ý đặt phòng khách sạn trên Expedia

Từ đặc điểm bài toán và dữ liệu, tới phương pháp graph-based CF, các thử nghiệm và hai cải tiến giúp model vượt ba baseline dựa trên booking.

01
Đặc điểm bài toán

02
Dataset Expedia và EDA

03
Các hướng giải quyết

04
Methodology: LightGCL

05
Thử nghiệm và cải tiến

06
Tổng kết

01 · BÀI TOÁN

Đặc điểm của bài toán gợi ý trong du lịch – khách sạn

BÀI TOÁN NEXT-BEST-PRODUCT

Từ lịch sử tìm kiếm và đặt phòng của mỗi user, gợi ý top-K nhóm khách sạn (hotel cluster) user nhiều khả năng đặt ở lần tiếp theo.

Tần suất mua rất thấp

Khách chỉ đặt phòng 1–2 lần mỗi năm, nên tín hiệu tương tác giữa user và khách sạn cực thưa.

Ngữ cảnh chuyến đóng vai trò lớn

Đi một mình, cặp đôi, gia đình hay nhóm lớn: cùng một user nhưng nhu cầu đổi theo từng chuyến.

Hành vi mang tính khám phá

Mỗi chuyến thường là nơi đến, khách sạn mới; khách xem nhiều lựa chọn rồi mới đặt, nên cần gợi ý lựa chọn chưa từng đặt.

Cold-start phía user

User mới hoặc mới đặt 1–2 lần có quá ít lịch sử để model biết họ thích gì; chưa từng đặt thì chỉ gợi ý được theo độ phổ biến.

Mô hình cần học được từ tương tác rất thưa, tận dụng hành vi chung của nhiều user và vẫn gợi ý được cho user có ít lịch sử.

02 · DATASET

Expedia Hotel Recommendations

Nhóm cột (train.csv)	Cột
User	user_id · date_time · site_name · user_location_country / region / city · is_mobile · channel
Ngữ cảnh chuyến đi	srch_ci · srch_co · srch_adults_cnt · srch_children_cnt · srch_rm_cnt · srch_destination_id · is_package · orig_destination_distance
Khách sạn	hotel_continent · hotel_country · hotel_market
Hành vi và nhãn	is_booking (click hay book) · hotel_cluster (0–99, item cần dự đoán)

train.csv
37,67 triệu dòng · 24 cột · 01/2013–12/2014

test.csv
2,53 triệu dòng · 01/2015–12/2015

destinations.csv
62.106 destination × 149 đặc trưng ẩn học từ hành vi tìm kiếm

Bài toán trên dataset: với mỗi user, dự đoán hotel_cluster của lần đặt tiếp theo, xếp top-K trong 100 cluster.

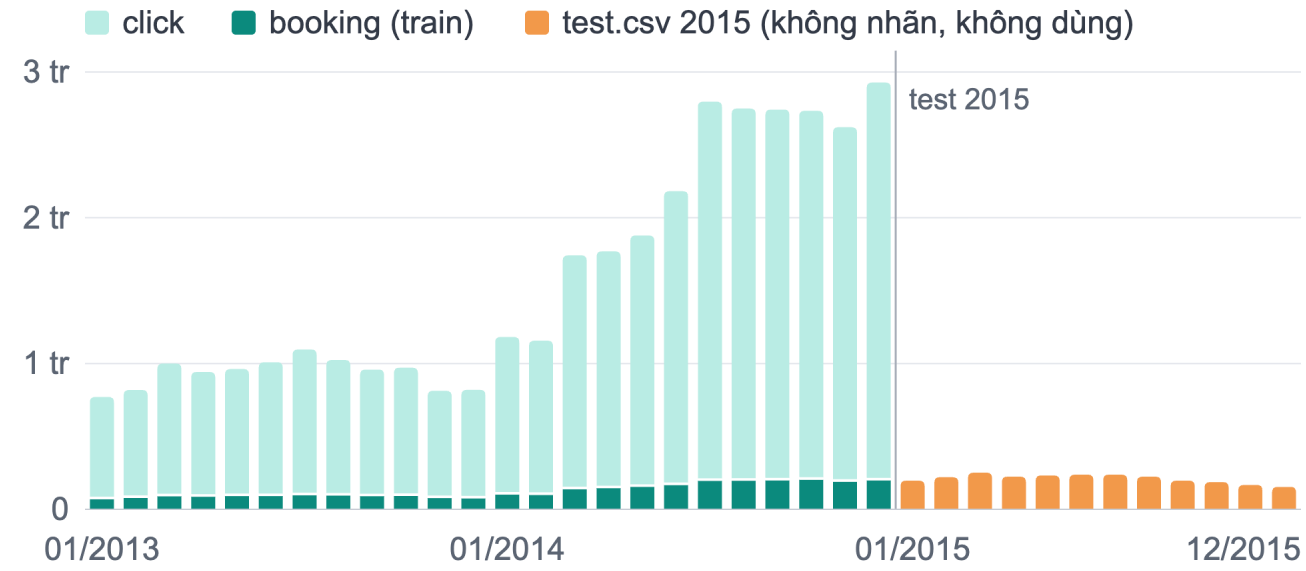
37,7 triệu event trong 2 năm, chỉ 8% là booking

37,7 tr
event (booking/click) 01/2013–12/2014

1,2 tr
user_id riêng biệt

7,97%
3 triệu booking; còn lại 34,7 triệu click

100
hotel_cluster (0–99) là item cần dự đoán



⚠ **orig_destination_distance** thiếu 35,90% ở train, 33,52% ở test

srch_ci / srch_co có năm 2557–2558; test có 1 ô sai định dạng "2161-10-00"

145.602 dòng có ngày check-in muộn hơn check-out, đều nằm ở click

Data dồn vào một nước, nhưng mỗi cluster trải trên hàng chục nước

Tỷ trọng số event theo hotel_country



country 50 · country 8 · 5,1% · 8 nước tiếp theo · 203 nước còn lại

TRUNG VỊ SỐ VÙNG MỖI CLUSTER CÓ MẶT

6 / 7	≈ 56 / 213	451 / 2.118
châu lục	nước	market

hotel_cluster là nhóm khách sạn tương tự nhau, không phải một vùng địa lý: không gợi ý theo vị trí được, phải học từ hành vi của user.

02 · EDA · ĐỘ THƯA

Booking rất thưa: đa số user có không quá 1 booking

8%

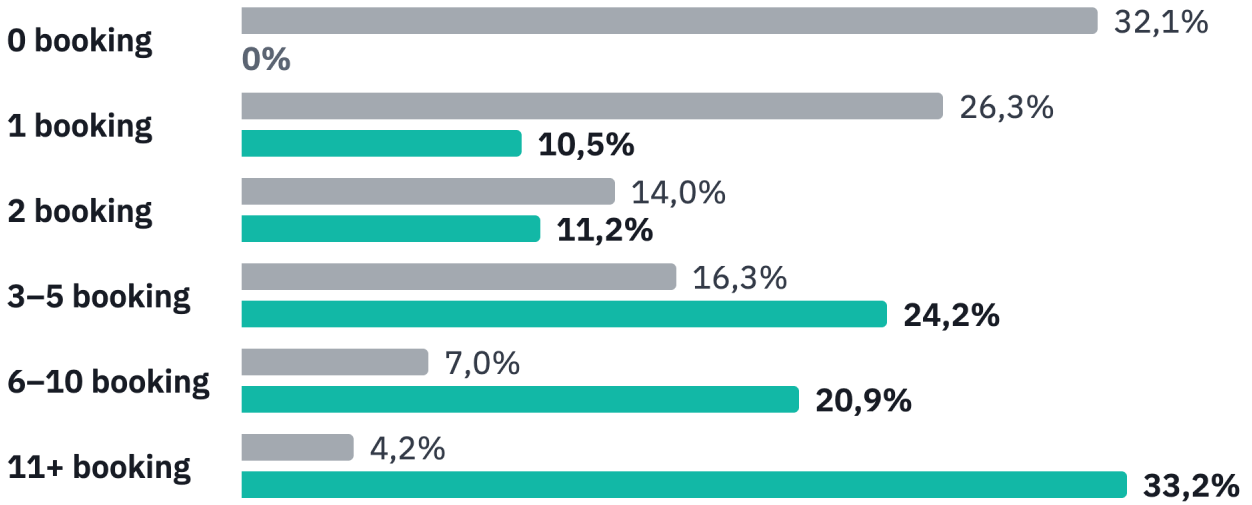
dòng log là booking (3 triệu trong 37,7 triệu); còn lại là click

58%

user có không quá 1 booking

32%

user chưa từng book, không có cạnh trong graph booking



27,6% user book từ 3 lần tạo ra 78,3% số booking.

User hay đặt lại cluster cũ, và tập user gần như cố định

Đặt lại là hành vi phổ biến

21,3%

số booking là đặt lại đúng cluster mà user đã từng đặt



- đặt lại cluster đã đặt
- lần đầu hoặc cluster khác

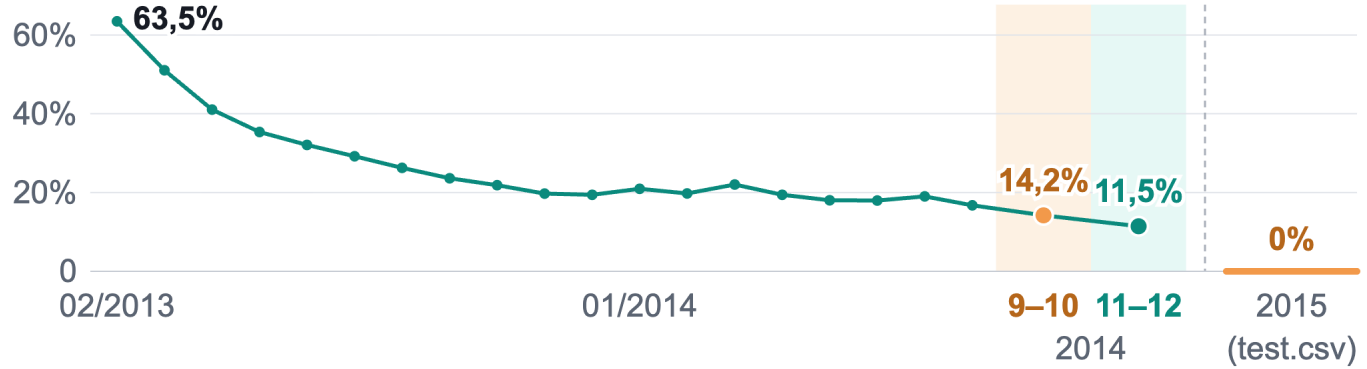
→ Giữ cluster đã book khi dự đoán và khi chấm

Tập user cố định

100%

user của test.csv (2015) đều đã xuất hiện ở train

% user xuất hiện lần đầu theo tháng (9–10 và 11–12/2014: trung bình 2 tháng)



→ Model chỉ cần dự đoán cho user đã biết

03 · HƯỚNG GIẢI QUYẾT · COLLABORATIVE FILTERING

✓ **Có sẵn:** ma trận tương tác user × hotel_cluster (click và booking).

⚠ **Không có:** đặc tính khách sạn; hotel_cluster chỉ là mã ẩn danh.

Ý TƯỞNG CHUNG

User giống nhau, lựa chọn giống nhau

Mỗi user và item có một embedding; điểm gợi ý là độ gần của hai embedding, học chỉ từ tương tác.

Chỉ cần ID và lịch sử tương tác.

NHÁNH GRAPH-BASED

Lọc cộng tác trên đồ thị

User và item là node, tương tác là cạnh; lan truyền nhiều bước để suy ra sở thích gián tiếp.

Input: ma trận (user, item) đã tương tác.

NHÁNH SESSION-BASED

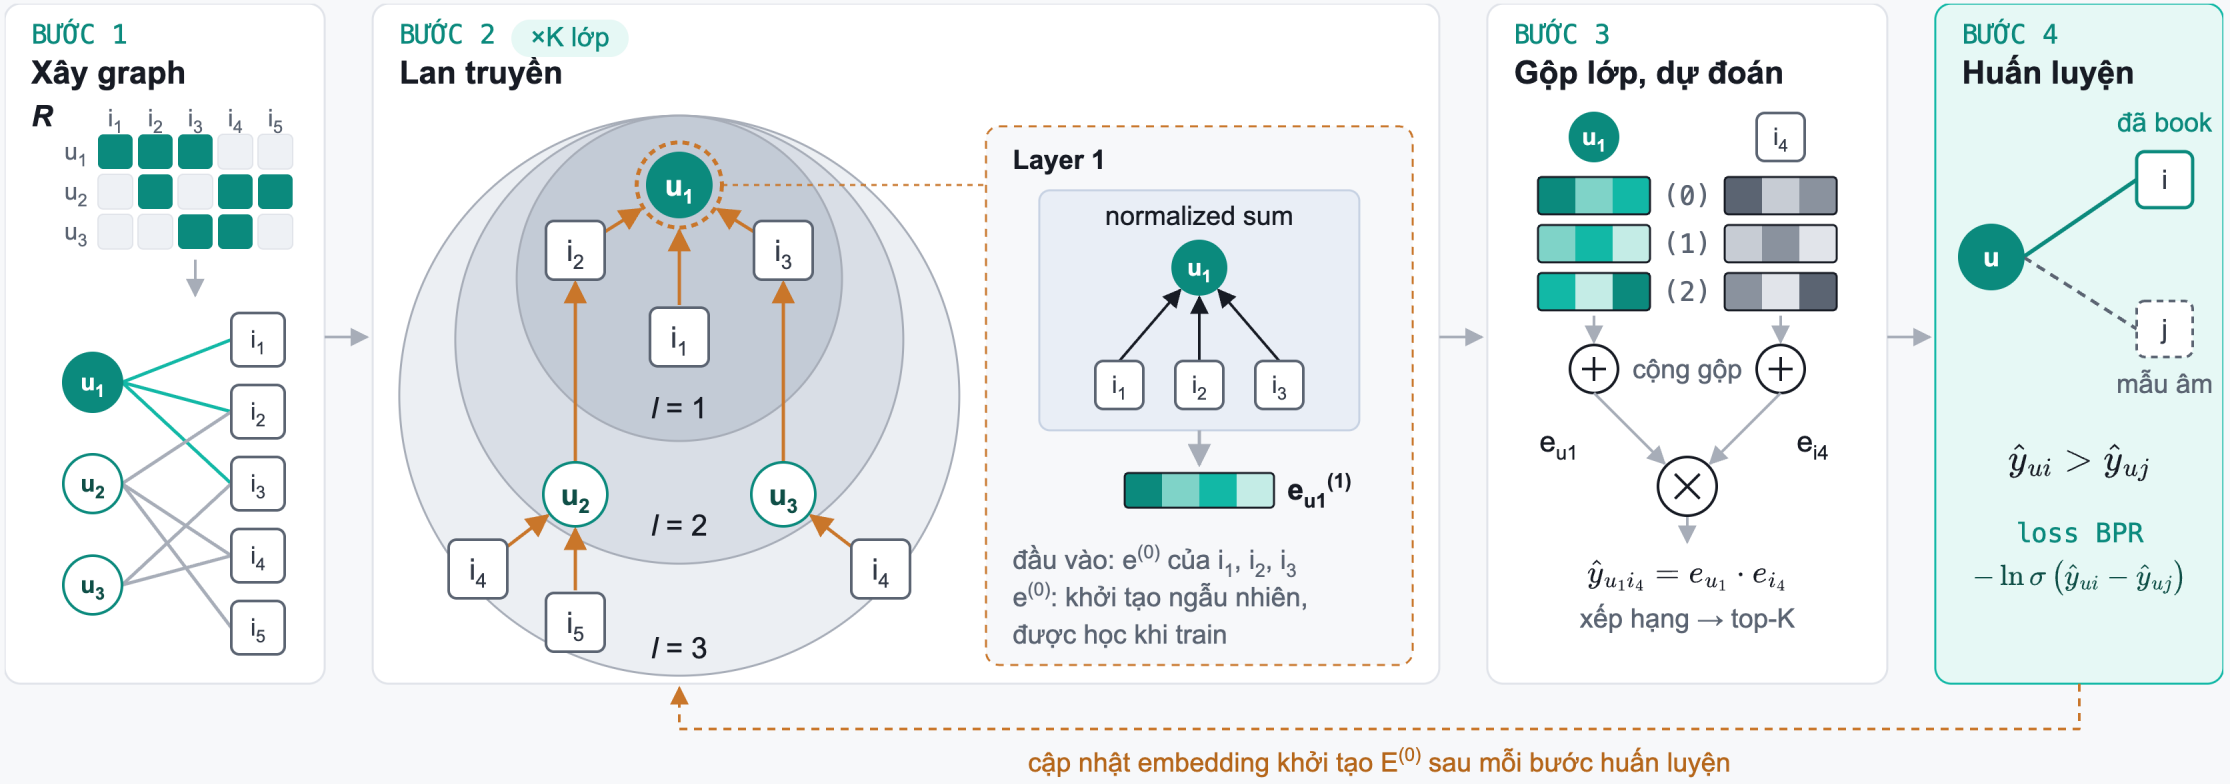
Lọc cộng tác theo phiên

Dự đoán hành động tiếp theo từ thứ tự hành vi trong phiên hiện tại.

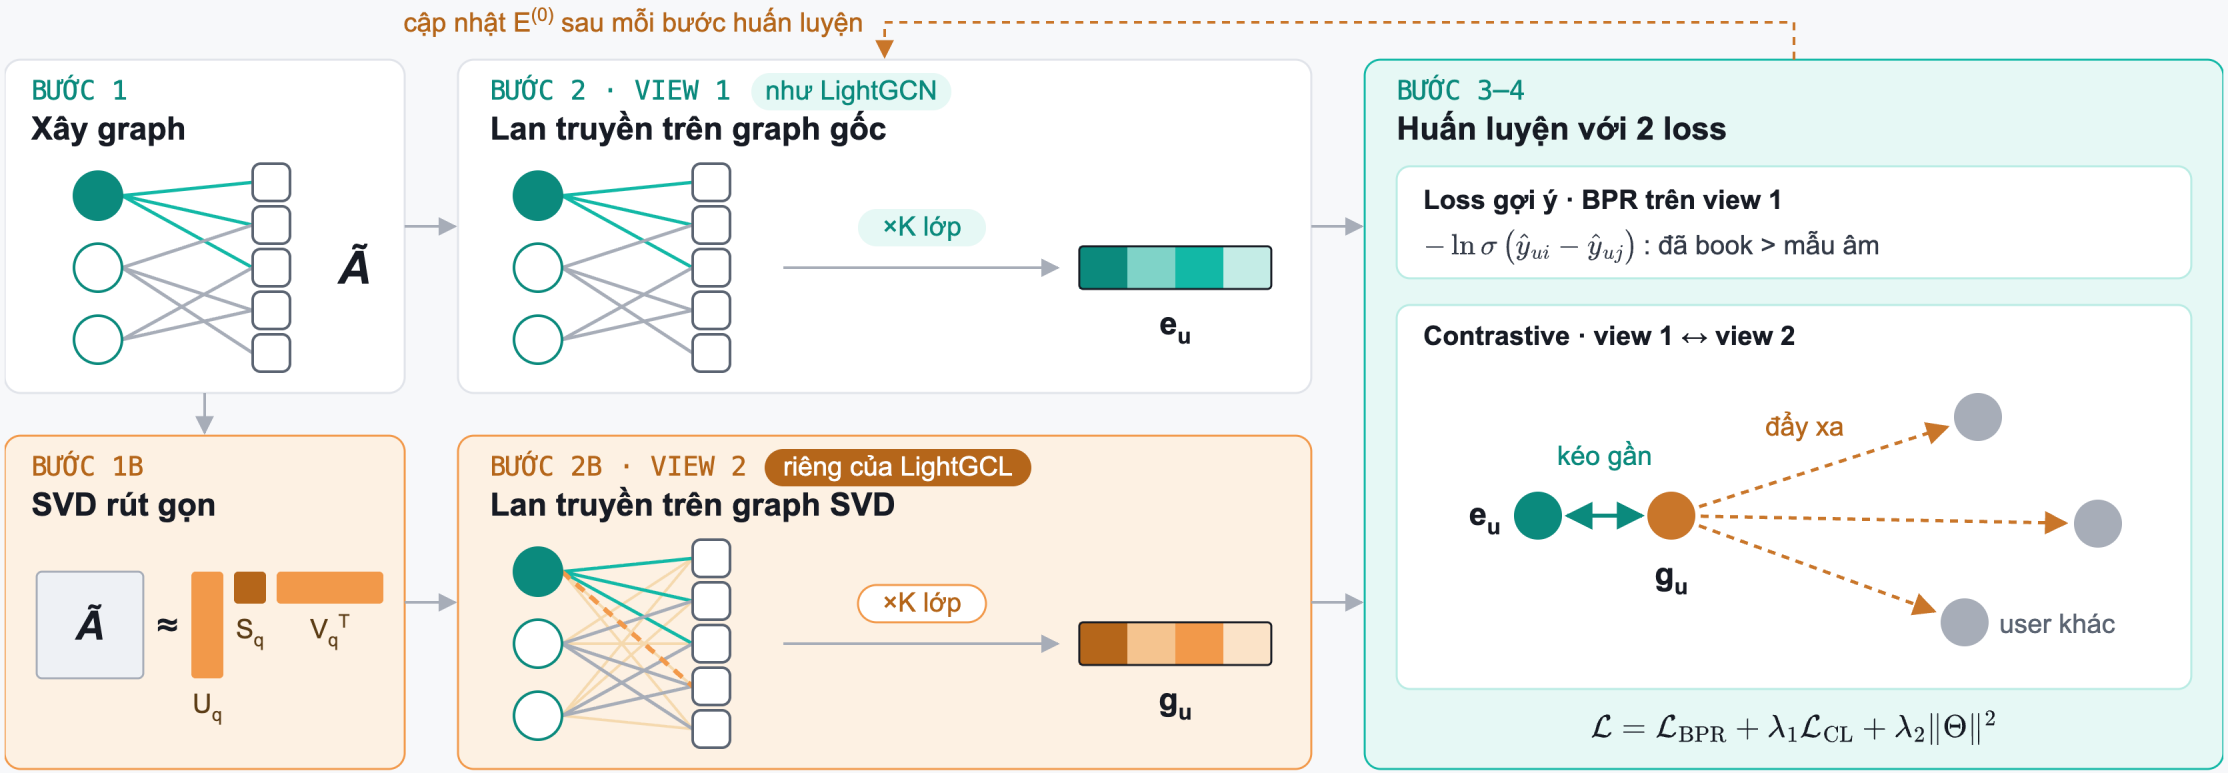
Input: chuỗi item theo thời gian trong một phiên.

Kết luận: chọn hướng graph-based, với phương pháp LightGCL (Cai et al., ICLR 2023).

Khung chung của graph-based CF



LightGCL: graph-based CF, thêm SVD view

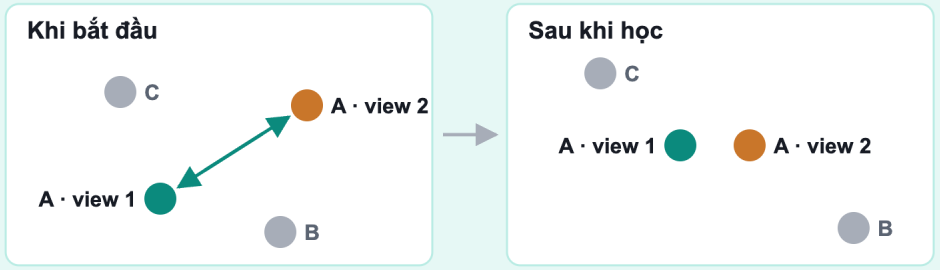


Khi gợi ý chỉ dùng embedding của đồ thị ban đầu; SVD view chỉ tác động qua quá trình train.

Contrastive learning với view SVD giúp học trên ma trận thưa

1 · CONTRASTIVE LEARNING

Kéo 2 view của cùng một user lại gần



$$\mathcal{L}_{\mathrm{CL}} = -\log \frac{\exp\left(g_u^{\top} e_u / \tau\right)}{\sum_v \exp\left(g_u^{\top} e_v / \tau\right)}$$

tử số: 2 view của cùng user u → kéo lại gần

mẫu số: so với mọi user v → đẩy user khác ra xa

e: view 1 (graph gốc) · g: view 2 (graph SVD) · τ: nhiệt độ

View 2 (graph SVD, xem bên dưới) nối thêm cluster mà user giống mình đã book

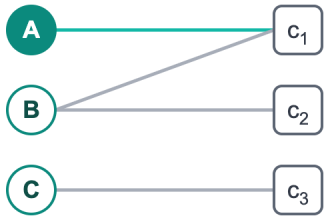
→ **kéo hai view lại gần = học thêm từ user giống mình, không cần nhãn mới**

2 · VIEW SVD

Hỗ trợ ma trận thưa, không thêm / xoá cạnh ngẫu nhiên

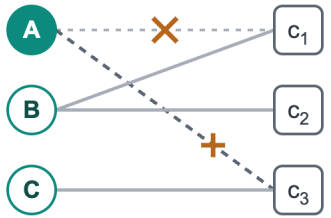
58% user có ≤ 1 booking: nhiều user chỉ có đúng 1 cạnh

Graph gốc



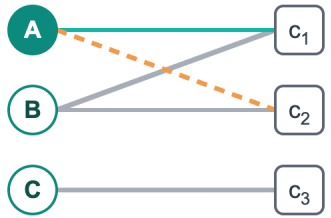
A chỉ có 1 cạnh: c_1

✗ Cách thường: thêm/xoá ngẫu nhiên



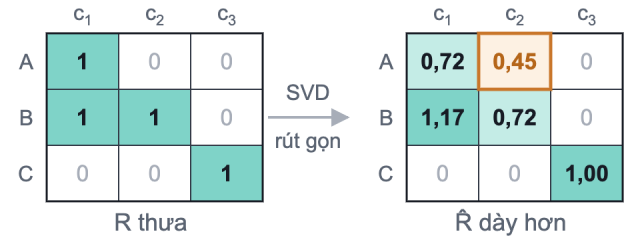
A mất cạnh thật duy nhất c_1,
lại bị nối ngẫu nhiên với c_3 → nhiễu

✓ LightGCL: tái dựng bằng SVD



Giữ mọi cạnh cũ,
thêm cạnh A–c_2 nhờ B (cùng book c_1)

Nhìn theo ma trận



Ô trống được lấp theo xu hướng chung, ô đã có vẫn còn

05 · THỬ NGHIỆM · ĐỐI CHIẾU CODE GỐC

Tái lập LightGCL trên Yelp: lệch so với paper không quá 1%

Metric	Paper	Tái lập	Lệch
Recall@20	0,0985	0,0975	−1,0%
NDCG@20	0,0842	0,0843	+0,1%
Recall@40	0,1553	0,1559	+0,4%
NDCG@40	0,1051	0,1055	+0,4%

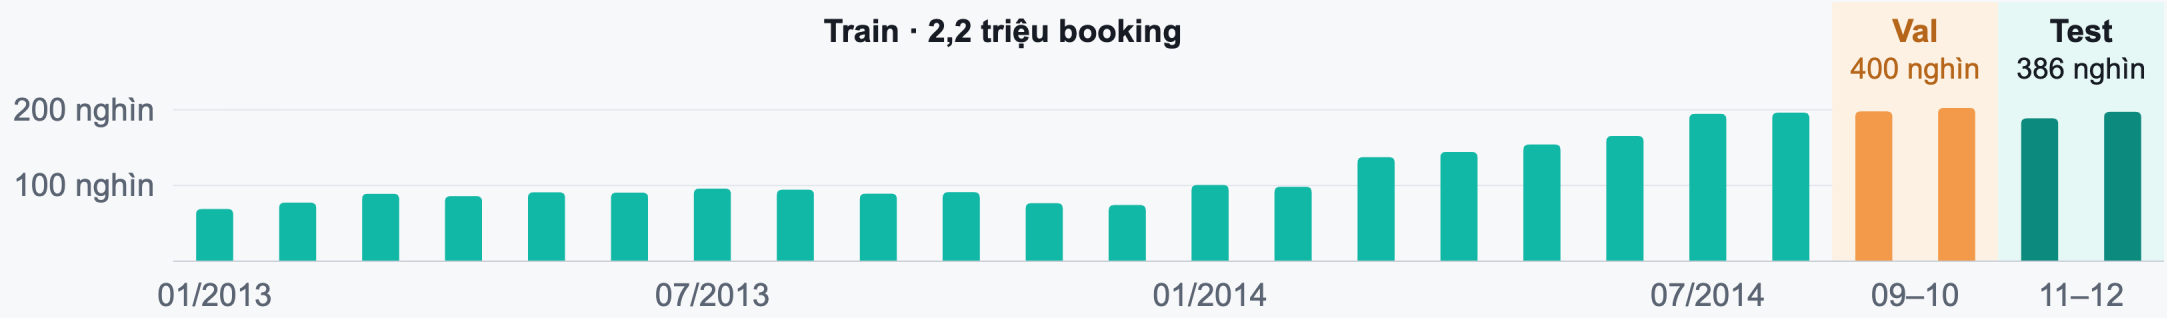
CÙNG ĐIỀU KIỆN VỚI PAPER

Bộ Yelp chia sẵn của repo HKUDS (29.601 user, 24.734 item), cấu hình mặc định, 100 epoch.

Mốc so sánh: Table 6 (Appendix E), kết quả của code hiện có trên GitHub.

✓ Model, vòng lặp train và cách tính metric này được giữ nguyên khi chuyển sang Expedia.

Graph từ booking, chia train / val / test theo thời gian



Graph	665 nghìn user × 100 cluster; 1,78 triệu cạnh từ 2,2 triệu booking trước 09/2014
Click	34,7 triệu dòng click không đưa vào graph
Test	11–12/2014, tự chia từ train.csv; test.csv của Kaggle không có nhãn nên không dùng
Chấm điểm	Giữ cluster user đã book trong danh sách gợi ý, vì đặt lại là hành vi phổ biến (khoảng 1/5 booking ở giai đoạn train)
Baseline	Popular (xếp theo số user đã đặt) · History (cluster user đã đặt lên đầu, còn lại theo Popular) · BPR-MF (phân rã ma trận booking)
Metric	Recall@K (R), NDCG@K (N), MAP@K với K = 5, 10, 20; chọn tham số theo R@5; MAP@5 là metric của cuộc thi Expedia

Hyperparameter tunning

Tham số	Chọn	Lý do (theo validation)
Learning rate	1e-4	Đỉnh validation cao nhất và giảm chậm nhất sau đỉnh
Hạng SVD q	q = 2	q lớn làm view SVD gần graph gốc, mất tác dụng chống học thuộc
L2 (λ2)	1e-5	Dò lại sau mỗi thay đổi graph; mạnh hơn thì model học kém đi
Early stopping	patience 3	Dừng khi val R@5 không tăng, giữ epoch tốt nhất
Batch	1024	Batch 4096 như paper không đủ bộ nhớ GPU

Cố định: kích thước embedding 64, hệ số contrastive loss 0,2.

Full softmax so với BPR

BPR · NEGATIVE SAMPLING

So với 1 cluster lấy ngẫu nhiên



mỗi cột: điểm ŷ của u với 1 cluster · cột xám: không được so

$$\mathcal{L}_{\text{BPR}} = -\ln \sigma\left(\hat{y}_{ui} - \hat{y}_{uj}\right) = -\ln \frac{\exp(\hat{y}_{ui})}{\exp(\hat{y}_{ui}) + \exp(\hat{y}_{uj})}$$

Mẫu âm có thể đã có điểm thấp → loss ≈ 0, model gần như không học được gì

FULL SOFTMAX

So với cả 100 cluster



mỗi cột: điểm ŷ của u với 1 cluster · cả 100 cluster đều được so

$$\mathcal{L}_{\text{softmax}} = -\ln \frac{\exp(\hat{y}_{ui})}{\sum_{c=1}^{100} \exp(\hat{y}_{uc})}$$

Chỉ 100 cluster nên so với cả tập vẫn nhẹ, không nhiễu do lấy mẫu

Loss gợi ý	Val R@5	Val R@20	Val NDCG@5	Val MAP@5
BPR · có negative sampling	0,2093	0,4837	0,1559	0,1205
Full softmax · không negative sampling	0,2102	0,4870	0,1573	0,1218

Time attention: cạnh mang trọng số là số lần book và recency

1 · CHỈ SỐ LẦN BOOK

Book bao nhiêu lần

	c_1	c_2	c_3	c_4
u_1	3	1	0	0
u_2	0	1	2	1
u_3	0	0	0	1

R: số lần book; LightGCL chuẩn hoá thành Â

u_1: c_1 book 3 lần > c_2 1 lần

2 · CHỈ RECENCY

Book gần đây hay đã lâu

	c_1	c_2	c_3	c_4
u_1	0,39 (365 ngày)	0,95 (30 ngày)	0	0
u_2	0	0,67 (200 ngày)	0,98 (10 ngày)	0,17 (500 ngày)
u_3	0	0	0	0,90 (60 ngày)

$$\tilde{t}_{uc} = \mathrm{MinMaxScaler}\left(t_{uc}^{\mathrm{last}}\right) = \frac{t_{uc}^{\mathrm{last}} - t_{\min}}{t_{\max} - t_{\min}}$$

t^{last}: lần book gần nhất · 1 = mới nhất, 0 = cũ nhất

3 · TRỘN · TIME ATTENTION

Kết hợp cả hai

	c_1	c_2	c_3	c_4
u_1	0,62	0,49	0	0
u_2	0	0,34	0,58	0,28
u_3	0	0	0	0,85

$$w_{uc} = \tfrac{1}{2}\,\hat{A}_{uc} + \tfrac{1}{2}\,\alpha_{uc}, \quad \alpha_{uc} = \frac{\exp(\tilde{t}_{uc})}{\sum_{c' \in \mathcal{N}(u)} \exp(\tilde{t}_{uc'})}$$

Â = normalize_adj(R) · α: softmax từng hàng của (2)

Model	Val R@5	Val R@20	Val NDCG@5	Val MAP@5
Cạnh 0–1 · bản gốc	0,2102	0,4870	0,1573	0,1218
Cạnh theo số lần book	0,2160	0,4958	0,1633	0,1273
Cạnh theo recency	0,2251	0,4831	0,1694	0,1322
Kết hợp · time attention	0,2296	0,5229	0,1738	0,1361

05 · THỬ NGHIỆM · BASELINE

Ba baseline để so sánh: Popular, History và BPR-MF

Ví dụ minh hoạ: một user đã book cluster 42 hai lần và cluster 17 một lần.

POPULAR

Ai cũng nhận danh sách phổ biến nhất

Xếp cluster theo số user đã đặt; mọi user nhận cùng một danh sách.

Top-5 cho user ví dụ:

91 48 42 59 28

→ Mốc thấp nhất, không cá nhân hoá; cũng là gợi ý cho user chưa từng book.

HISTORY

Đưa cluster user đã đặt lên đầu

Cluster đã book xếp trước (book nhiều lần đứng trước), chỗ còn lại lấp theo Popular.

Top-5 cho user ví dụ:

42 **17** 91 48 59

→ Đo sức mạnh của hành vi đặt lại: 21% booking là cluster đã đặt.

BPR-MF

Collaborative filtering cổ điển, không có graph

Phân rã ma trận user × cluster thành embedding, học bằng loss BPR; điểm gợi ý là độ gần của hai embedding.

Train lại trên booking của train + val tới 10/2014.

→ Cho thấy phần đóng góp của lan truyền trên graph và view SVD trong LightGCL.

06 · TỔNG KẾT · FOLD-IN

Khi có booking mới, model cập nhật trọng số cạnh mà không train lại

1 · Train một lần

Chỉ trên booking trước 09/2014, chọn epoch bằng validation.

2 · Cập nhật graph

Thêm booking 09–10/2014, chuẩn hoá lại, tính lại time attention.

3 · Lan truyền lại

Dùng tham số đã train; user book lần đầu nhận embedding qua các cluster vừa book.

User đã có trong graph lúc train · R@5

0,2101 → 0,2353

Graph đến 08/2014 → graph cập nhật đến 10/2014

15.382 user book lần đầu 09–10/2014 · R@5

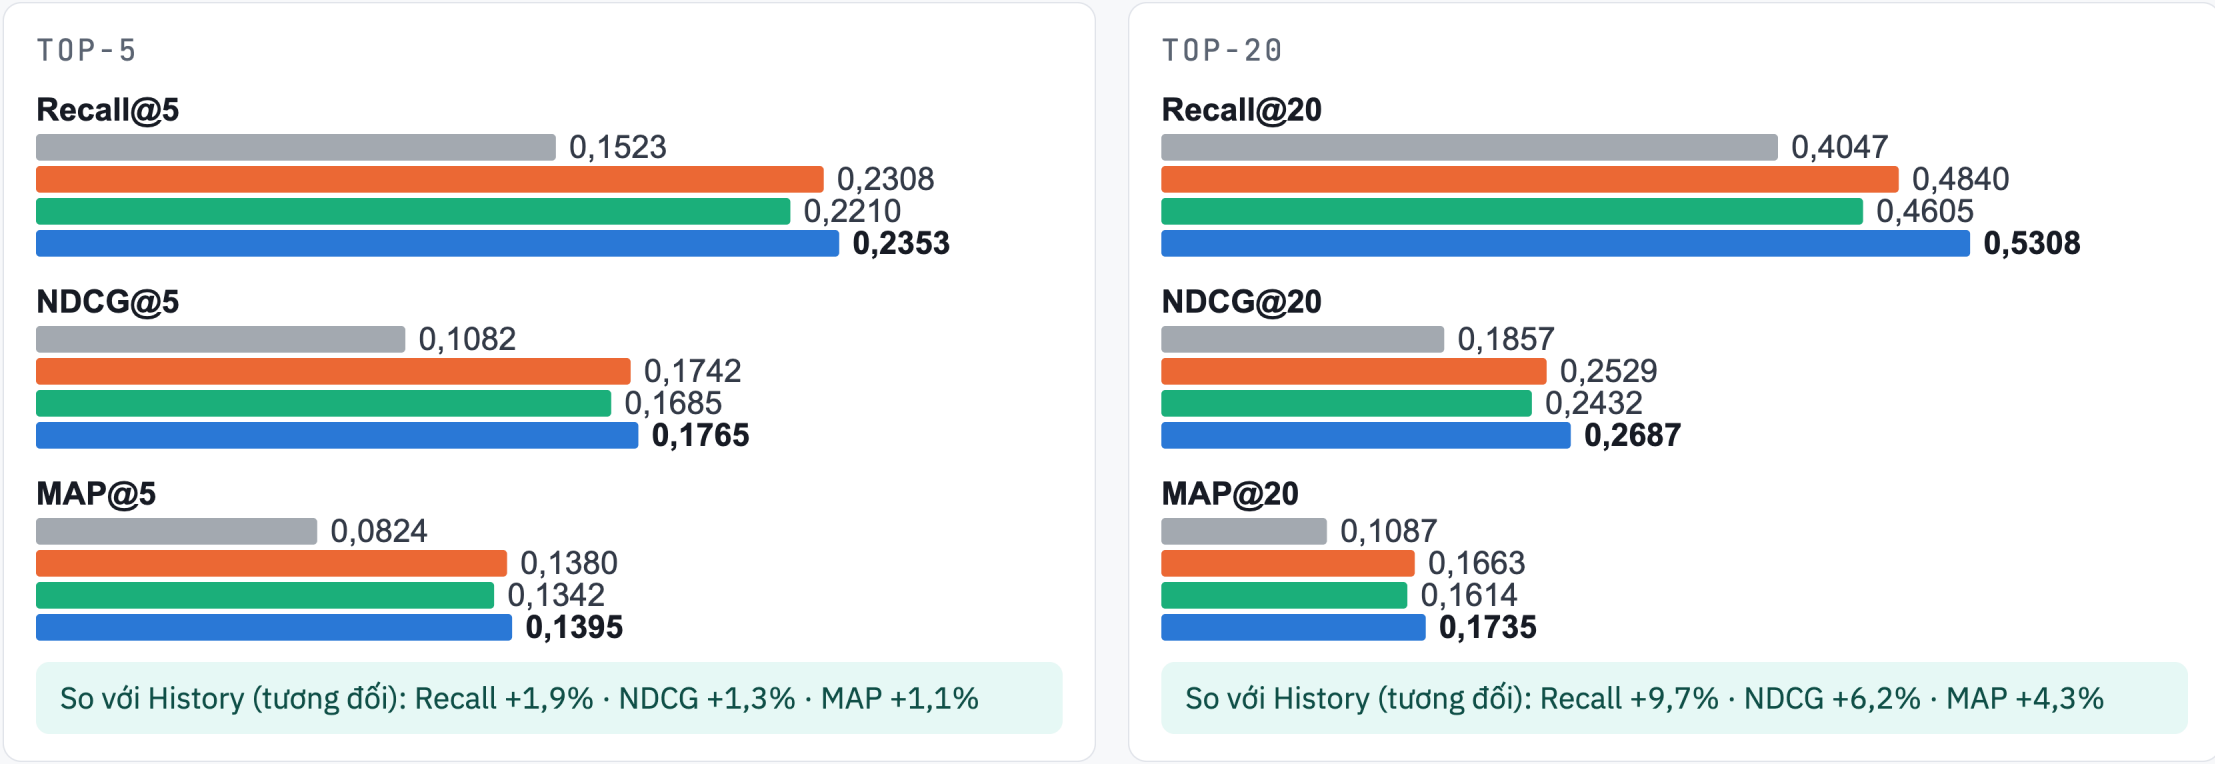
0,2411

so với History 0,2325 · BPR-MF train lại 0,2237 · Popular 0,1501

06 · TỔNG KẾT · KẾT QUẢ TRÊN TEST

Với time attention, LightGCL vượt cả ba baseline dựa trên booking

Popular · History · BPR-MF · LightGCL + time attention



150.971 user đã book trước 11/2014 · nhãn: booking 11–12/2014 · graph đã fold-in booking 09–10/2014

06 · TỔNG KẾT · KẾT QUẢ CUỐI

Với user mới hoàn toàn, model vẫn gợi ý tốt nhờ graph đã xây

TOÀN BỘ USER TEST · 150.971 USER

Model	Recall@5	NDCG@5	MAP@5
Popular	0,1523	0,1082	0,0824
History	0,2308	0,1742	0,1380
BPR-MF (train lại)	0,2210	0,1685	0,1342
LightGCL + time attention	0,2353	0,1765	0,1395

TRONG ĐÓ: USER MỚI · 15.382 USER

Model	Recall@5	NDCG@5	MAP@5
Popular	0,1501	0,1061	0,0808
History	0,2325	0,1851	0,1519
BPR-MF (train lại)	0,2237	0,1807	0,1492
LightGCL + time attention	0,2411	0,1906	0,1561

User mới: chưa có lịch sử book nào trước 09/2014 nên lúc train không có trong graph; lần book đầu rơi vào 09–10/2014.
Chỉ cần thêm các booking của user này vào graph rồi lan truyền lại, không train lại, model đã vượt History và BPR-MF.

Cold-start: 32,2% user test chưa có booking nào trước 11/2014, nên không có embedding để đưa vào graph.
Với nhóm này mọi phương pháp đều không áp dụng được, chỉ có thể dùng Popular (Recall@5 0,1323) nên không đưa vào bảng.