LightGCL cho gợi ý đặt phòng khách sạn trên Expedia

Từ đặc điểm bài toán và dữ liệu, tới phương pháp graph-based CF, các thử nghiệm và hai cải tiến giúp model vượt ba baseline dựa trên booking.

01
Đặc điểm bài toán

02
Dataset Expedia và EDA

03
Các hướng giải quyết

04
Methodology: LightGCL

05
Thử nghiệm và cải tiến

06
Tổng kết

01 · BÀI TOÁN

Đặc điểm của bài toán gợi ý trong du lịch – khách sạn

BÀI TOÁN NEXT-BEST-PRODUCT

Từ lịch sử tìm kiếm và đặt phòng của mỗi user, gợi ý top-K nhóm khách sạn (hotel cluster) user nhiều khả năng đặt ở lần tiếp theo.

Tần suất mua rất thấp

Khách chỉ đặt phòng 1–2 lần mỗi năm, nên tín hiệu tương tác giữa user và khách sạn cực thưa.

Ngữ cảnh chuyến đi quyết định

Đi một mình, cặp đôi, gia đình hay nhóm lớn: cùng một user nhưng nhu cầu đổi theo từng chuyến.

Hành vi mang tính khám phá

Mỗi chuyến thường là nơi đến, khách sạn mới; khách xem nhiều lựa chọn rồi mới đặt, nên cần gợi ý lựa chọn chưa từng đặt.

Cold-start phía user

User mới hoặc mới đặt 1–2 lần có quá ít lịch sử để model biết họ thích gì; chưa từng đặt thì chỉ gợi ý được theo độ phổ biến.

Mô hình cần học được từ tương tác rất thưa, tận dụng hành vi chung của nhiều user và vẫn gợi ý được cho user có ít lịch sử.

02 · DATASET

Expedia Hotel Recommendations

Nhóm cột (train.csv)	Cột
User	user_id · date_time · site_name · user_location_country / region / city · is_mobile · channel
Ngữ cảnh chuyến đi	srch_ci · srch_co · srch_adults_cnt · srch_children_cnt · srch_rm_cnt · srch_destination_id · is_package · orig_destination_distance
Khách sạn	hotel_continent · hotel_country · hotel_market
Hành vi và nhãn	is_booking (click hay book) · hotel_cluster (0–99, item cần dự đoán)

train.csv

37,67 triệu dòng · 24 cột · 01/2013–12/2014 · gồm click và booking

test.csv

2,53 triệu dòng · năm 2015 · không có hotel_cluster nên không dùng để chấm; tập test được tự chia từ train.csv

destinations.csv

62.106 destination × 149 đặc trưng ẩn học từ hành vi tìm kiếm

Bài toán trên dataset: với mỗi user, dự đoán hotel_cluster của lần đặt tiếp theo, xếp top-K trong 100 cluster.

02 · EDA · ĐỘ THƯA

Booking rất thưa: đa số user có không quá 1 booking

8%

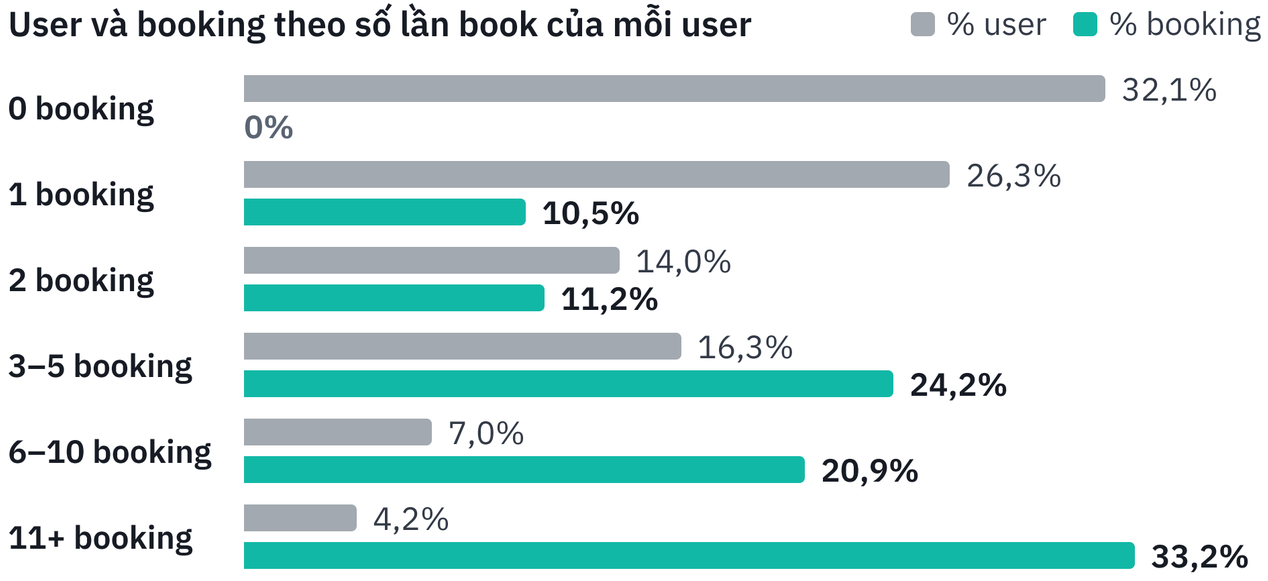
dòng log là booking (3 triệu trong 37,7 triệu); còn lại là click

58%

user có không quá 1 booking

32%

user chưa từng book, không có cạnh trong graph booking



27,6% user book từ 3 lần tạo ra 78,3% số booking.

User hay đặt lại cluster cũ, và tập user gần như cố định

Đặt lại là hành vi phổ biến

21,3%

số booking là đặt lại đúng cluster mà user đã từng đặt



- đặt lại cluster đã đặt
- lần đầu hoặc cluster khác

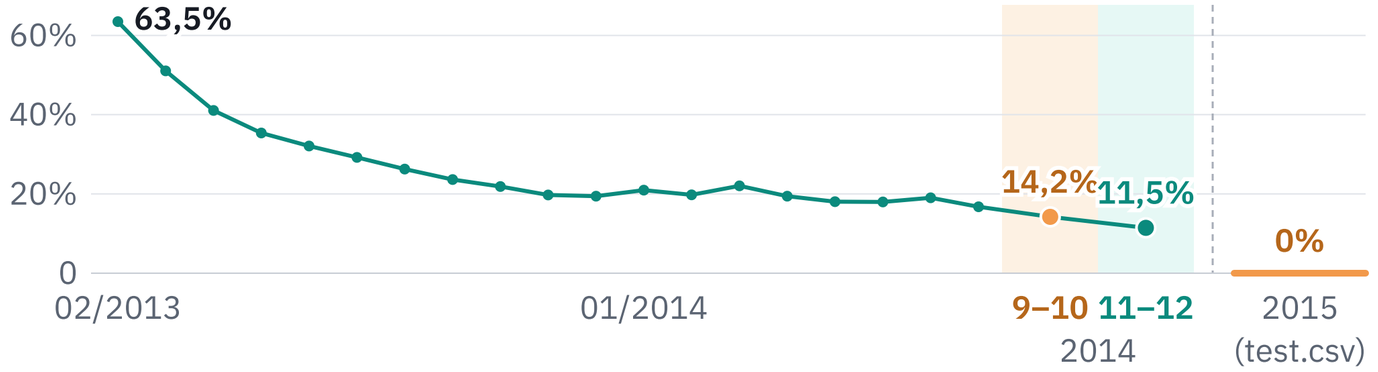
→ Giữ cluster đã book khi dự đoán và khi chấm

Tập user cố định

100%

user của test.csv (2015) đều đã xuất hiện ở train

% user xuất hiện lần đầu theo tháng (9–10 và 11–12/2014: trung bình 2 tháng)



→ Model chỉ cần dự đoán cho user đã biết

03 · HƯỚNG GIẢI QUYẾT · COLLABORATIVE FILTERING

✓ **Có sẵn:** ma trận tương tác user × hotel_cluster (click và booking).

⚠ **Không có:** đặc tính khách sạn; hotel_cluster chỉ là mã ẩn danh.

Ý TƯỞNG CHUNG

User giống nhau, lựa chọn giống nhau

Mỗi user và item có một embedding; điểm gợi ý là độ gần của hai embedding, học chỉ từ tương tác.

Chỉ cần ID và lịch sử tương tác.

NHÁNH GRAPH-BASED

Lọc cộng tác trên đồ thị

User và item là node, tương tác là cạnh; lan truyền nhiều bước để suy ra sở thích gián tiếp.

Input: ma trận (user, item) đã tương tác.

NHÁNH SESSION-BASED

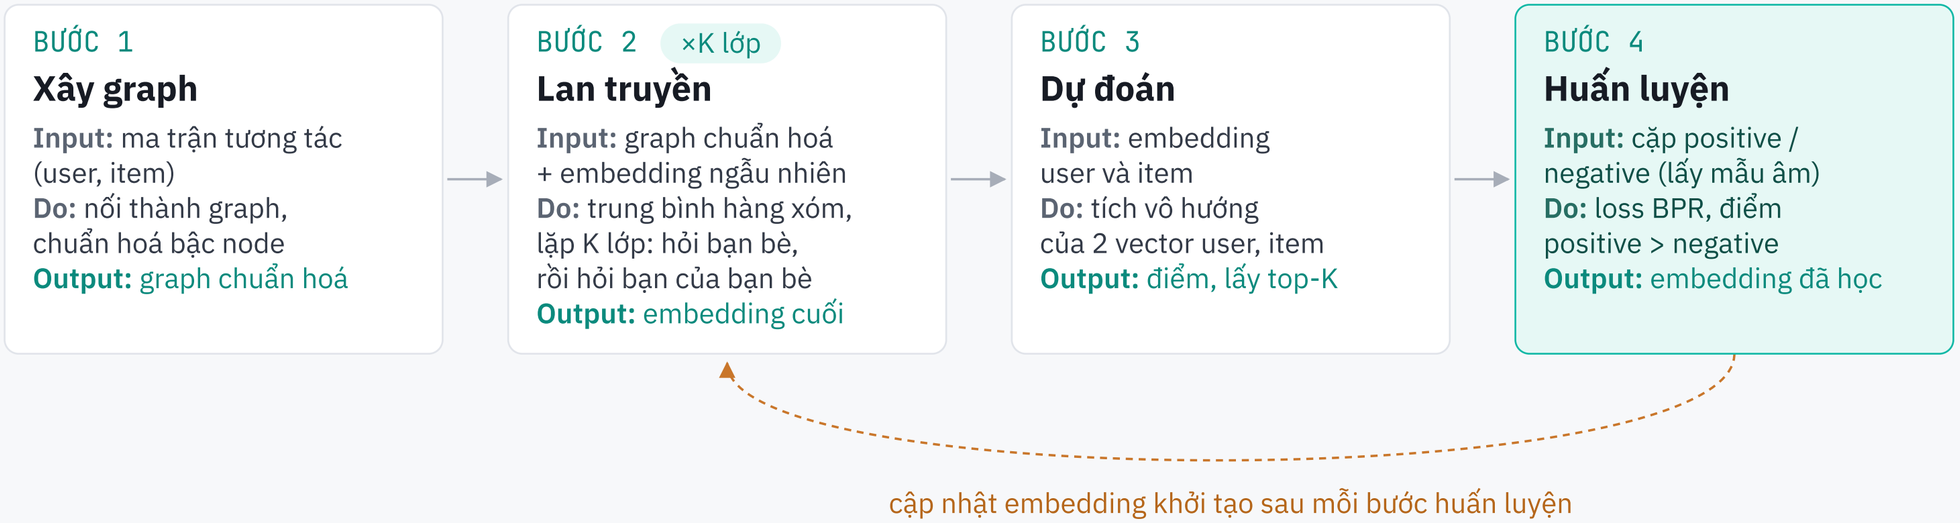
Lọc cộng tác theo phiên

Dự đoán hành động tiếp theo từ thứ tự hành vi trong phiên hiện tại.

Input: chuỗi item theo thời gian trong một phiên.

Chọn graph-based: booking rất thưa, lan truyền trên graph giúp mượn tín hiệu từ user tương tự; còn khi gợi ý lần đặt tiếp theo, user chưa có phiên tìm kiếm mới. Bản này dựng graph từ booking; click và ngữ cảnh để dành cho hướng mở rộng.

Khung chung của graph-based CF gồm 4 bước



Lan truyền cho user ít tương tác nhận thêm tín hiệu từ hàng xóm nhiều bước. Bước 1–3 gần như giữ nguyên qua các thế hệ graph-based CF; khác biệt chủ yếu nằm ở bước huấn luyện.

LightGCL: graph-based CF, thêm SVD view



Contrastive learning với view SVD giúp học trên ma trận thưa

⚠ **Ma trận thưa:** 58% user có không quá 1 booking, nên embedding chỉ học từ 1–2 cạnh.

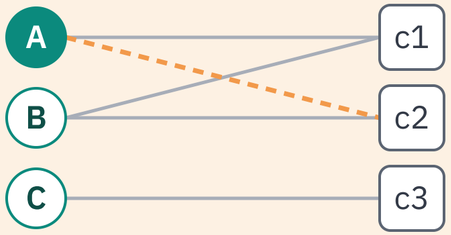
Contrastive learning: so hai view của cùng một user

View 1 · graph gốc



A chỉ có 1 cạnh: c1

View 2 · graph tái dựng bằng SVD



A được nối thêm với c2 nhờ B

Kéo lại gần: A ở view 1 và A ở view 2

Đẩy ra xa: A và các user khác (B, C)

Thêm tín hiệu học, không cần nhãn

User chỉ có 1 booking vẫn có thêm mục tiêu: hai view của chính mình phải khớp nhau.

Mượn xu hướng của user giống mình

View SVD nối cả cặp user–cluster chưa tương tác, kéo user ít cạnh về sở thích chung.

Không làm mất cạnh hiếm hoi

Cách thông thường xoá cạnh ngẫu nhiên, dễ mất cạnh duy nhất của user; SVD không xoá gì.

05 · THỬ NGHIỆM · ĐỐI CHIẾU CODE GỐC

Tái lập LightGCL trên Yelp: lệch so với paper không quá 1%

Metric	Paper	Tái lập	Lệch
Recall@20	0,0985	0,0975	−1,0%
NDCG@20	0,0842	0,0843	+0,1%
Recall@40	0,1553	0,1559	+0,4%
NDCG@40	0,1051	0,1055	+0,4%

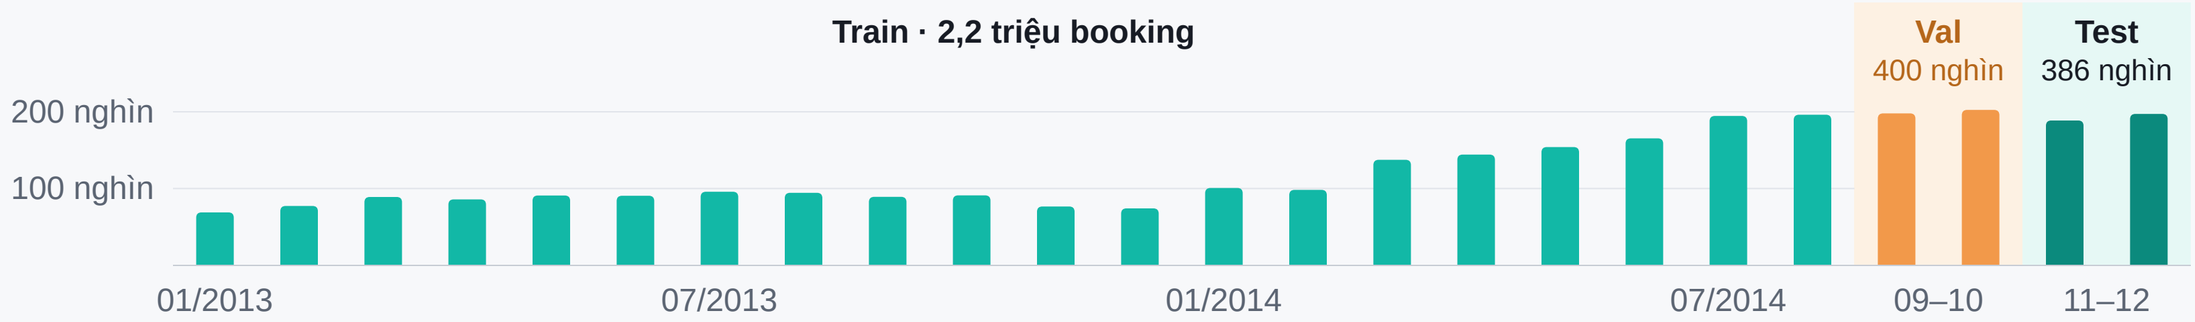
CÙNG ĐIỀU KIỆN VỚI PAPER

Bộ Yelp chia sẵn của repo HKUDS (29.601 user, 24.734 item), cấu hình mặc định, 100 epoch.

Mốc so sánh: Table 6 (Appendix E), kết quả của code hiện có trên GitHub.

✓ Model, vòng lặp train và cách tính metric này được giữ nguyên khi chuyển sang Expedia.

Graph từ booking, chia train / val / test theo thời gian



Graph	665 nghìn user × 100 cluster; 1,78 triệu cạnh từ 2,2 triệu booking trước 09/2014
Click	34,7 triệu dòng click chưa đưa vào graph, để dành cho hướng tiếp theo
Test	11–12/2014, tự chia từ train.csv; test.csv của Kaggle không có nhãn nên không dùng
Chấm điểm	Giữ cluster user đã book trong danh sách gợi ý, vì đặt lại là hành vi phổ biến (khoảng 1/5 booking ở giai đoạn train)
Baseline	Popular (xếp theo số user đã đặt) · History (cluster user đã đặt lên đầu, còn lại theo Popular) · BPR-MF (phân rã ma trận booking)
Metric	Recall@K (R), NDCG@K (N), MAP@K với K = 5, 10, 20; chọn tham số theo R@5; MAP@5 là metric của cuộc thi Expedia

Hyperparameter sau khi tunning

Tham số	Chọn	Lý do (theo validation)
Learning rate	1e-4	Đỉnh validation cao nhất và giảm chậm nhất sau đỉnh
Hạng SVD q	q = 2	q lớn làm view SVD gần graph gốc, mất tác dụng chống học thuộc
L2 (λ2)	1e-5	Dò lại sau mỗi thay đổi graph; mạnh hơn thì model học kém đi
Early stopping	patience 3	Dừng khi val R@5 không tăng, giữ epoch tốt nhất
Batch	1024	Batch 4096 như paper không đủ bộ nhớ GPU

Cố định: kích thước embedding 64, hệ số contrastive loss 0,2.

05 · THỬ NGHIỆM · CẢI TIẾN 1

Full softmax nhỉnh hơn BPR ở cả 4 độ đo

LIGHTGCL CẠNH 0-1, Q = 2 · CHỈ KHÁC HÀM LOSS

Loss gợi ý	Val R@5	Val R@20	Val NDCG@5	Val MAP@5
BPR · có negative sampling	0,2093	0,4837	0,1559	0,1205
Full softmax · không negative sampling	**0,2102**	**0,4870**	**0,1573**	**0,1218**

BPR · NEGATIVE SAMPLING

Mỗi cluster đã book chỉ được so với một cluster lấy ngẫu nhiên. Model dễ chấm cluster đã book cao hơn một cluster bất kỳ, nên loss giảm nhanh nhưng thứ hạng trong top 5 cải thiện ít.

FULL SOFTMAX THAY CHO BPR

Tập item chỉ có 100 hotel cluster nên tính softmax trên cả 100 cluster không tốn kém. Cluster đã book được so với mọi cluster còn lại, không còn nhiễu do lấy mẫu ngẫu nhiên.

05 · THỬ NGHIỆM · CẢI TIẾN 2

Time attention: cạnh mang trọng số là số lần book và recency

1 · Số lần book

Cạnh (user, cluster) đánh trọng số theo số lần book thay vì 0–1, vì đặt lại là hành vi phổ biến.

2 · Recency

Lấy thời điểm book gần nhất của mỗi cạnh, co về [0, 1] bằng cách so với min-max trên toàn graph. Cuối cùng lấy softmax.

3 · Trộn hai trọng số

Trọng số cạnh = ½ theo số lần book + ½ theo thời gian. Cách lan truyền và loss giữ nguyên.

Ví dụ: user book cluster A cách đây 365 ngày, cluster B cách đây 30 ngày → phần thời gian chia A 0,36 và B 0,64.

Model	Val R@5	Val R@20	Val NDCG@5	Val MAP@5
LightGCL, cạnh 0–1	0,2102	0,4870	0,1573	0,1218
LightGCL, cạnh theo số lần book	0,2160	0,4958	0,1633	0,1273
LightGCL + time attention	0,2296	0,5229	0,1738	0,1361

05 · THỬ NGHIỆM · BASELINE

Ba baseline để so sánh: Popular, History và BPR-MF

Ví dụ minh hoạ: một user đã book cluster 42 hai lần và cluster 17 một lần.

POPULAR

Ai cũng nhận danh sách phổ biến nhất

Xếp cluster theo số user đã đặt; mọi user nhận cùng một danh sách.

Top-5 cho user ví dụ:

91 48 42 59 28

→ Mốc thấp nhất, không cá nhân hoá; cũng là gợi ý cho user chưa từng book.

HISTORY

Đưa cluster user đã đặt lên đầu

Cluster đã book xếp trước (book nhiều lần đứng trước), chỗ còn lại lấp theo Popular.

Top-5 cho user ví dụ:

42 **17** 91 48 59

→ Đo sức mạnh của hành vi đặt lại: 21% booking là cluster đã đặt.

BPR-MF

Collaborative filtering cổ điển, không có graph

Phân rã ma trận user × cluster thành embedding, học bằng loss BPR; điểm gợi ý là độ gần của hai embedding.

Train lại trên booking của train + val tới 10/2014.

→ Cho thấy phần đóng góp của lan truyền trên graph và view SVD trong LightGCL.

06 · TỔNG KẾT · FOLD-IN

Khi có booking mới, model cập nhật trọng số cạnh mà không train lại

1 · Train một lần

Chỉ trên booking trước 09/2014, chọn epoch bằng validation.

2 · Cập nhật graph

Thêm booking 09–10/2014, chuẩn hoá lại, tính lại time attention.

3 · Lan truyền lại

Dùng tham số đã train; user book lần đầu nhận embedding qua các cluster vừa book.

User đã có trong graph lúc train · R@5

0,2101 → 0,2353

Graph đến 08/2014 → graph cập nhật đến 10/2014

15.382 user book lần đầu 09–10/2014 · R@5

0,2411

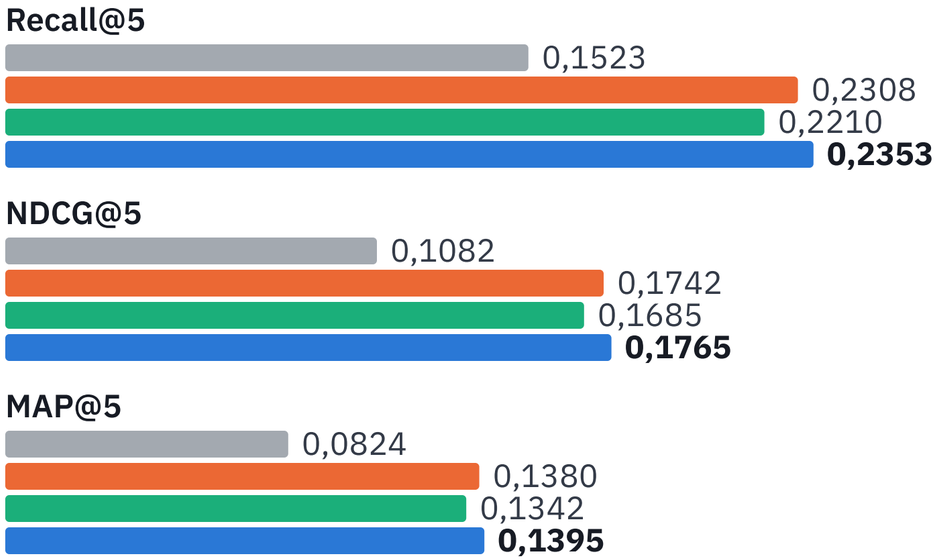
so với History 0,2325 · BPR-MF train lại 0,2237 · Popular 0,1501

06 · TỔNG KẾT · KẾT QUẢ TRÊN TEST

Với time attention, LightGCL vượt cả ba baseline dựa trên booking

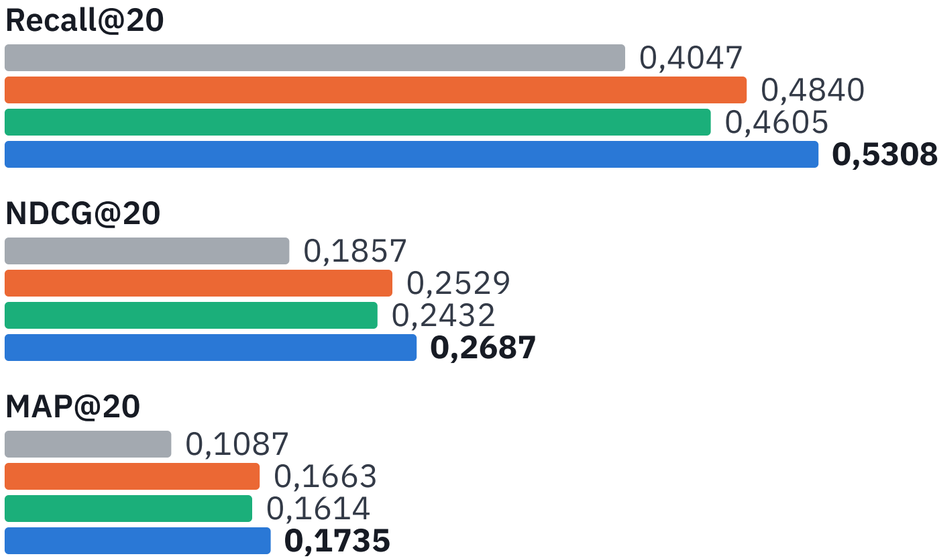
Popular · History · BPR-MF · LightGCL + time attention

TOP-5



So với History (tương đối): Recall +1,9% · NDCG +1,3% · MAP +1,1%

TOP-20



So với History (tương đối): Recall +9,7% · NDCG +6,2% · MAP +4,3%

150.971 user đã book trước 11/2014 · nhãn: booking 11–12/2014 · graph đã fold-in booking 09–10/2014

06 · TỔNG KẾT · KẾT QUẢ CUỐI

Với user có hành vi mới, model vẫn gợi ý tốt nhờ graph đã xây trước đó

TOÀN BỘ USER TEST · 150.971 USER

Model	Recall@5	NDCG@5	MAP@5
Popular	0,1523	0,1082	0,0824
History	0,2308	0,1742	0,1380
BPR-MF (train lại)	0,2210	0,1685	0,1342
LightGCL + time attention	0,2353	0,1765	0,1395

TRONG ĐÓ: USER MỚI 09–10/2014 · 15.382 USER

Model	Recall@5	NDCG@5	MAP@5
Popular	0,1501	0,1061	0,0808
History	0,2325	0,1851	0,1519
BPR-MF (train lại)	0,2237	0,1807	0,1492
LightGCL + time attention	0,2411	0,1906	0,1561

Kết luận: kể cả với user có hành vi mới (chưa có trong graph lúc train), chỉ cần thêm booking mới vào graph đã xây rồi lan truyền, model vẫn cho ra kết quả tốt dựa trên đồ thị đã xây dựng.

Cold-start: 32,2% user trên tập test chưa book trước 11/2014 nên không có trong graph và không có embedding. Với nhóm này mọi phương pháp, kể cả History, dùng chung danh sách Popular (Recall@5 0,1323), nên không đưa vào bảng.

Nhãn: booking 11–12/2014 · model train trên booking trước 09/2014 · graph đã fold-in booking 09–10/2014 · chữ cam là giá trị cao nhất mỗi cột