Cá nhân hóa gợi ý khách sạn ngay từ lần tìm kiếm đầu tiên

Next-best-product cho du lịch khách sạn

01 Đặc điểm bài toán

02 Dataset Expedia và EDA

03 Các hướng giải quyết

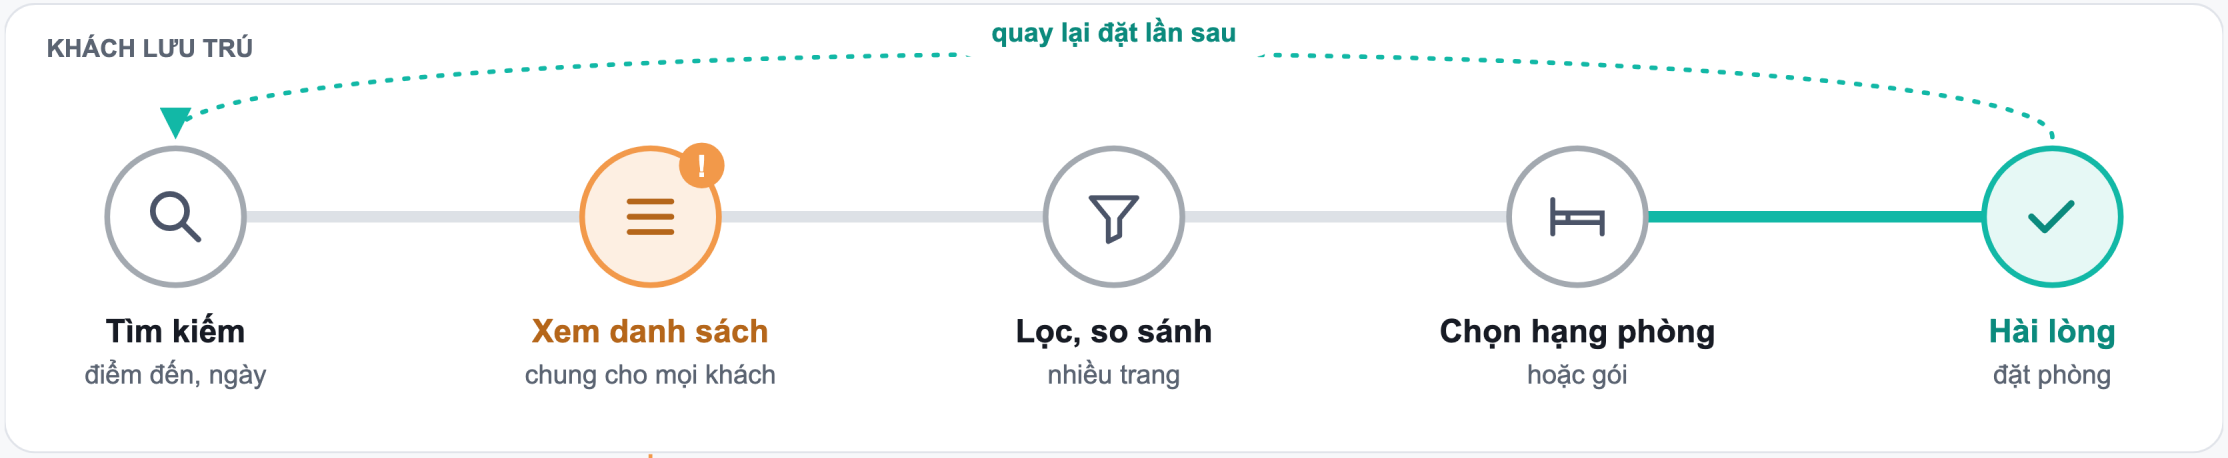
04 Methodology: LightGCL

05 Thử nghiệm và cải tiến

06 Tổng kết

01 · BÀI TOÁN · HÀNH TRÌNH CỦA KHÁCH

Danh sách chung cho mọi khách khiến khách bỏ cuộc dần



quá nhiều lựa chọn · không cá nhân hóa

Khách bỏ cuộc dần

Ví dụ: cùng tìm khách sạn ở Phú Quốc, 20–23/11

Hơn 300 chỗ ở, mọi khách thấy cùng một thứ tự

Đi một mình	Đi cùng gia đình
phòng nhỏ, giá hợp lý	phòng rộng, có bữa sáng

BÊN BÁN LƯU TRÚ

- Mất booking
- Mất khách quay lại
- Bỏ lỡ cơ hội bán

Hệ gợi ý xếp hạng sản phẩm riêng cho từng khách



Ăn uống, giải trí
user – món ăn, phim

Mua sắm
user – sản phẩm

Đề tài

Du lịch nghỉ dưỡng
user – hạng phòng, gói

01 · BÀI TOÁN

Đặc điểm của bài toán gợi ý trong du lịch – khách sạn

BÀI TOÁN NEXT-BEST-PRODUCT

Từ lịch sử tìm kiếm và đặt phòng của mỗi user, gợi ý top-K nhóm khách sạn (hotel cluster) user nhiều khả năng đặt ở lần tiếp theo.

Tần suất mua rất thấp

Khách chỉ đặt phòng 1–2 lần mỗi năm, nên tín hiệu tương tác giữa user và khách sạn cực thưa.

Ngữ cảnh chuyến đóng vai trò lớn

Đi một mình, cặp đôi, gia đình hay nhóm lớn: cùng một user nhưng nhu cầu đổi theo từng chuyến.

Hành vi mang tính khám phá

Mỗi chuyến thường là nơi đến, khách sạn mới; khách xem nhiều lựa chọn rồi mới đặt, nên cần gợi ý lựa chọn chưa từng đặt.

Cold-start phía user

User mới hoặc mới đặt 1–2 lần có quá ít lịch sử để model biết họ thích gì; chưa từng đặt thì chỉ gợi ý được theo độ phổ biến.

Mô hình cần học được từ tương tác rất thưa, tận dụng hành vi chung của nhiều user và vẫn gợi ý được cho user có ít lịch sử.

02 · DATASET

Bộ dữ liệu Expedia Hotel Recommendations

TOÀN BỘ FILE TRAIN.CSV

37.670.293 dòng

07/01/2013 → 31/12/2014

Click · 34.669.600 · 92,0%

Click không dùng làm nhãn

Booking · 3.000.693 · 8,0%

USER

1.198.786

813.985 có đặt phòng

CẦN XẾP HẠNG

100 cluster

hotel_cluster, id ẩn danh

Bài toán trên dataset: với mỗi user, dự đoán hotel_cluster của lần đặt tiếp theo, xếp top-K trong 100 cluster.

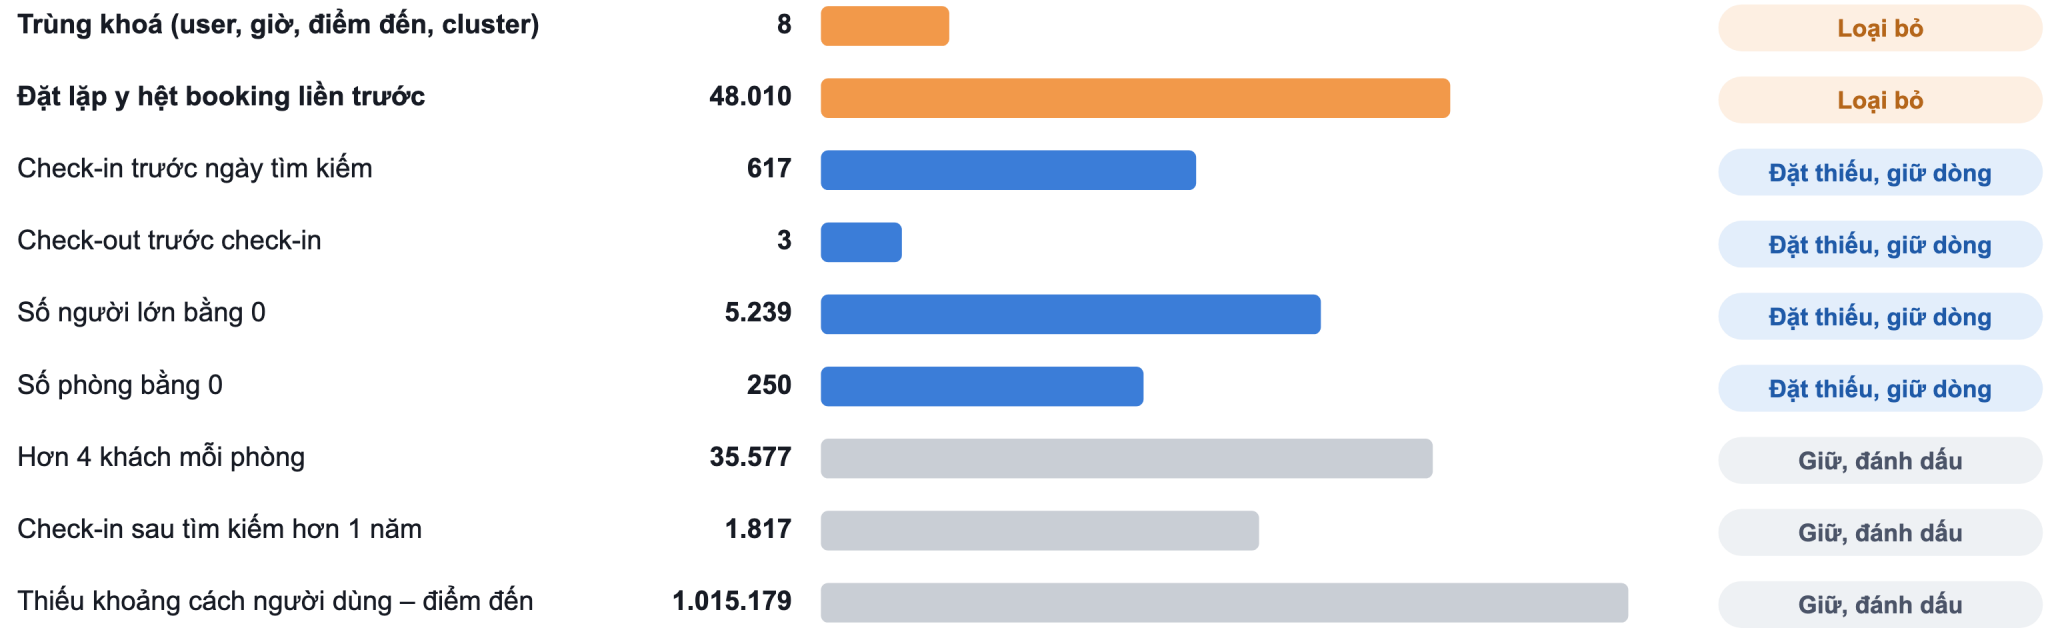
7 nhóm cột

lần tìm kiếm · chứa nhãn

- **Tương tác, thời gian**
  cnt · date_time · is_booking
- **Người dùng**
  user_id
- **Ngữ cảnh chuyến đi**
  is_package · srch_adults_cnt · srch_children_cnt · srch_ci · srch_co · srch_rm_cnt
- **Tìm kiếm, điểm đến**
  srch_destination_id · srch_destination_type_id
- **Khách sạn, mục tiêu**
  hotel_cluster · hotel_continent · hotel_country · hotel_market
- **Vị trí người dùng**
  orig_destination_distance · user_location_city · user_location_country · user_location_region
- **Kênh, nền tảng**
  channel · is_mobile · posa_continent · site_name

Dữ liệu khá sạch: chỉ bỏ 1,6% booking trùng lặp

Số booking bị ảnh hưởng thang log, trên 3.000.693 booking thô — loại bỏ; đặt thiếu, giữ dòng; giữ, đánh dấu

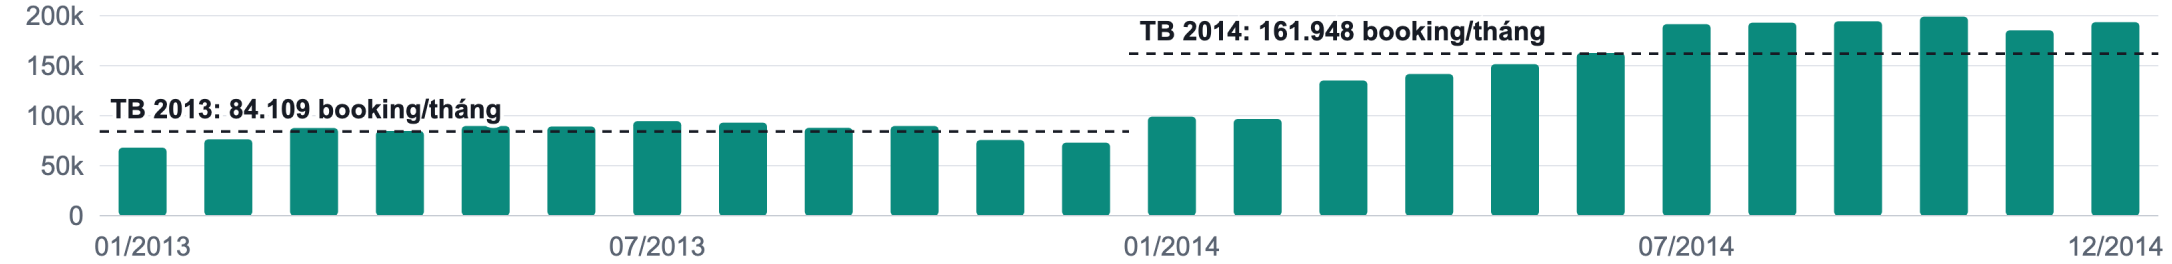


Dữ liệu **khá sạch**: chỉ bỏ phần trùng lặp, gần như toàn bộ booking dùng được.

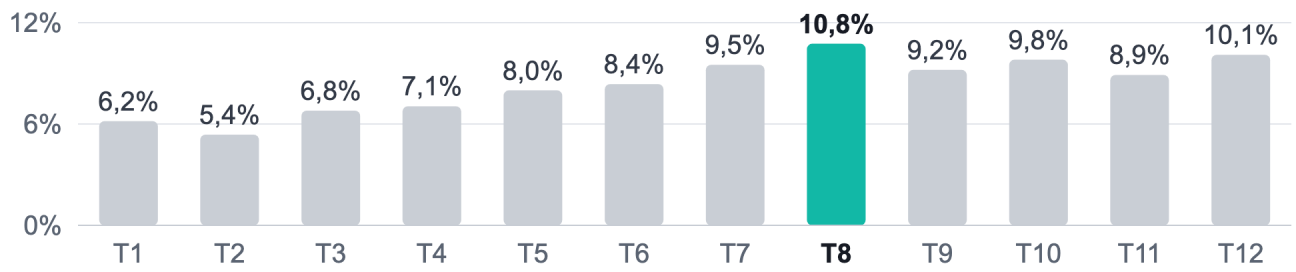
Lỗi nhập liệu được **giữ dòng, đặt thiếu**; khoảng cách người dùng – điểm đến thiếu quá nhiều nên **không dùng làm đầu vào**.

Dữ liệu tăng nhanh, booking đổi theo mùa và nhóm khách

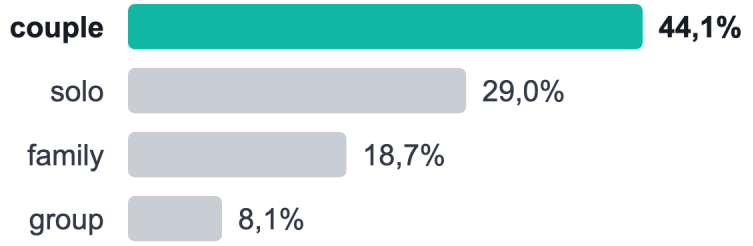
Số booking mỗi tháng (train.csv, đã bỏ booking trùng)



Tỷ lệ booking theo tháng check-in



Tỷ lệ booking theo nhóm khách



Nhu cầu đang **tăng nhanh**: dữ liệu năm sau dày hơn hẳn năm trước, và đi lệch theo mùa du lịch.

Khách đi **cặp đôi** là nhóm chính; **ngày đi và nhóm khách** thay đổi theo mùa nên là tín hiệu cần dùng.

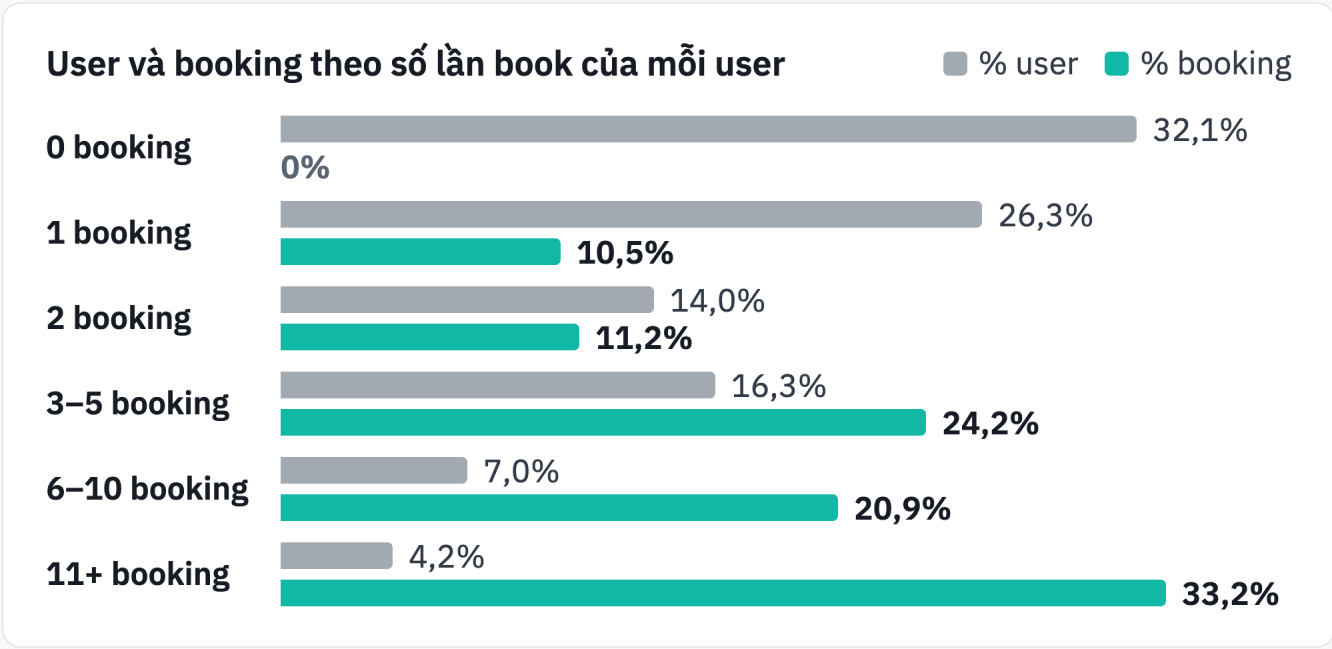
02 · EDA · ĐỘ THƯA

Booking rất thưa: đa số user có không quá 1 booking

8%
tỷ lệ booking so với click

58%
user có không quá 1 booking

32%
user chưa từng book



Lịch sử mỗi user **quá mỏng** để học sở thích riêng: cần **mượn tín hiệu từ user tương tự**.

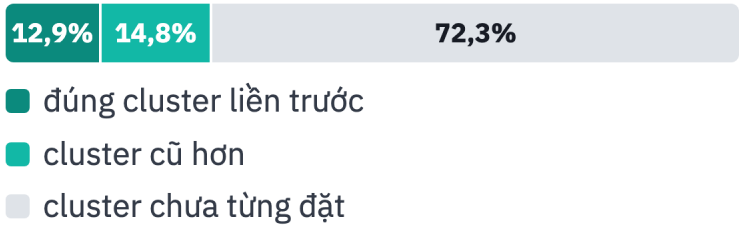
Tín hiệu **dồn vào nhóm nhỏ** user book nhiều; user **chưa từng book** không có lịch sử để cá nhân hoá.

User hay đặt lại cluster cũ, và tập user dần ổn định

Đặt lại là hành vi phổ biến

27,7%

booking của user đã có lịch sử là đặt lại một cluster đã từng đặt

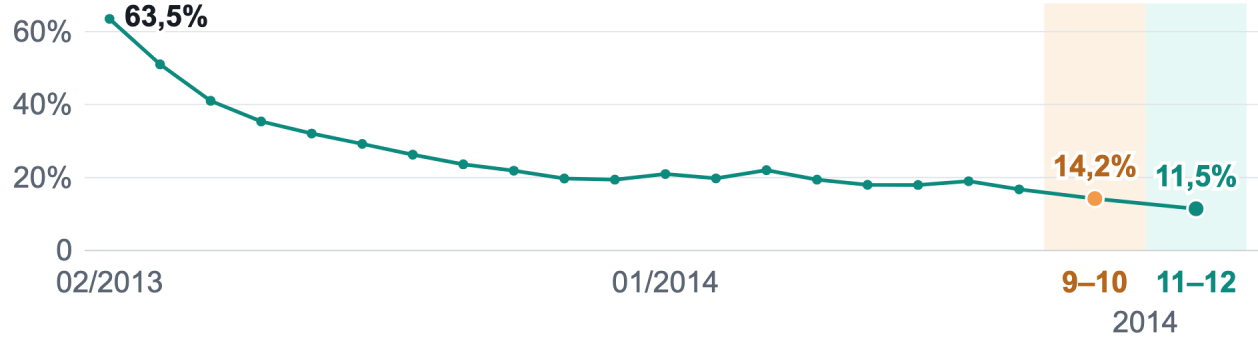


Tập user dần ổn định

89%

user hoạt động tháng 12/2014 đã xuất hiện từ các tháng trước

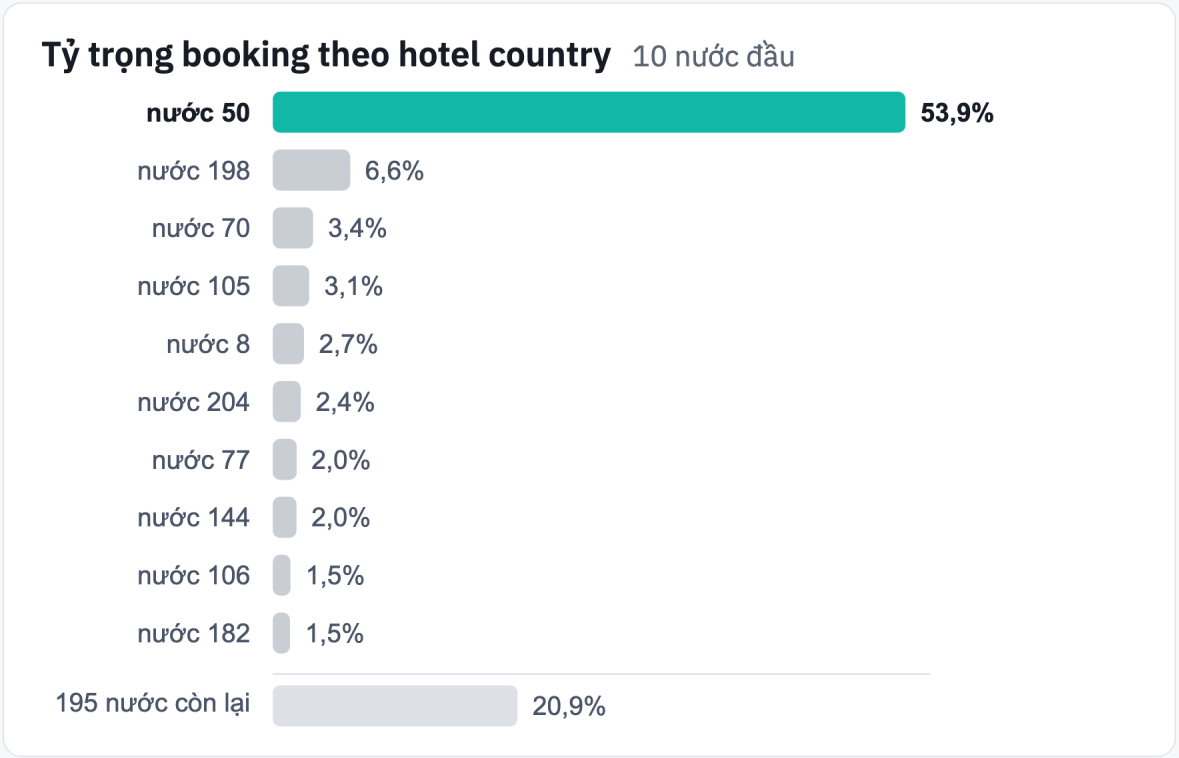
% user xuất hiện lần đầu theo tháng (9–10 và 11–12/2014: trung bình 2 tháng)

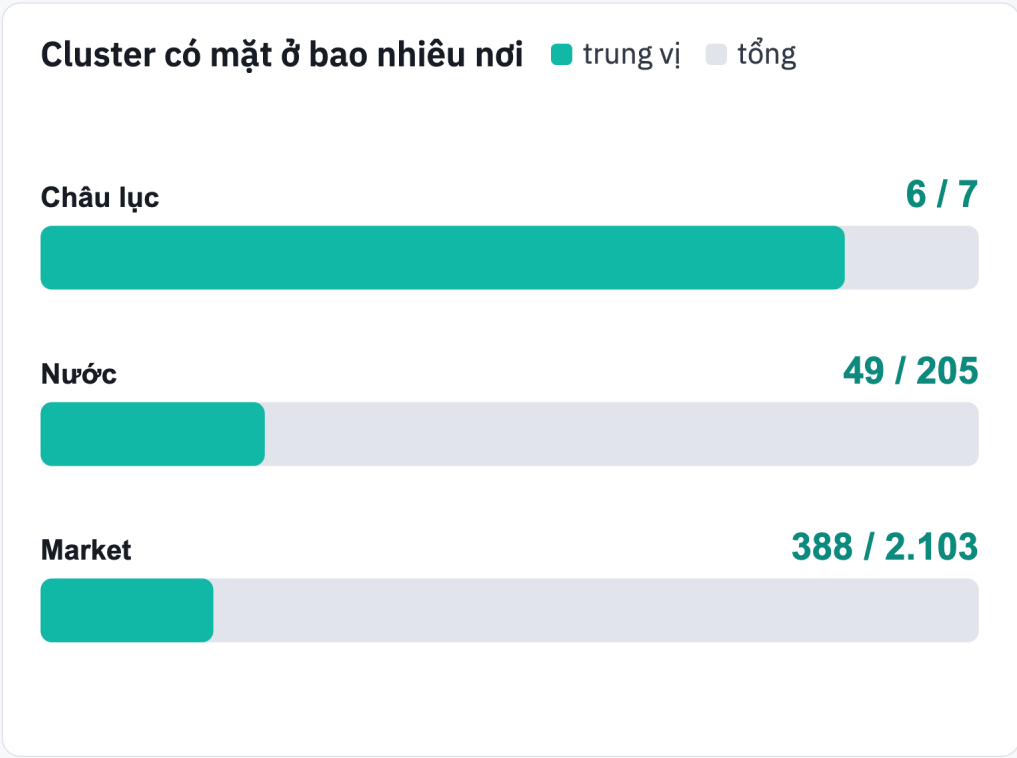


Khách hay **quay lại cluster cũ**: gợi ý cần giữ các cluster đã book, không chỉ đề xuất cái mới.

Phần lớn user cần gợi ý **đã xuất hiện trong dữ liệu**: tận dụng được lịch sử sẵn có của họ.

Booking dồn vào một nước, nhưng mỗi cluster trải trên hàng chục nước

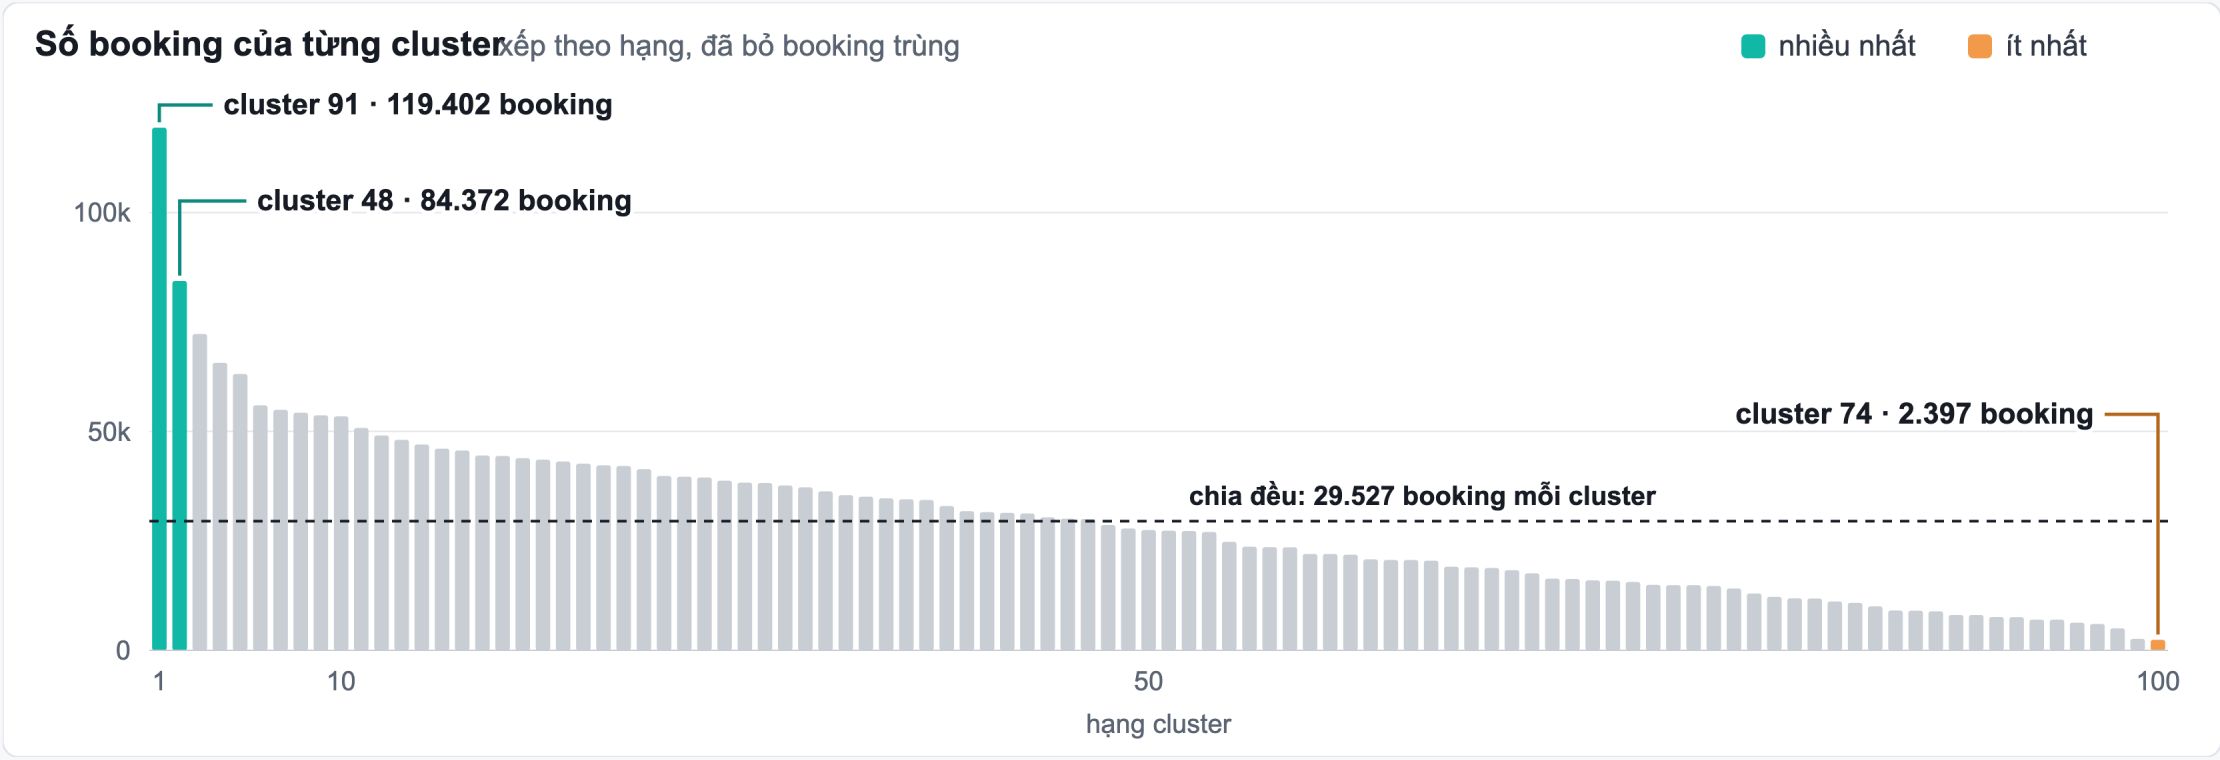




Booking **dồn vào một nước** (hơn một nửa).

Nhưng mỗi cluster trải ở **nhiều nước, nhiều market**: cluster không phải nhóm theo địa lý.

Booking trải khá đều trên 100 cluster, không cluster nào áp đảo



Không cluster nào **áp đảo**: chỉ gợi ý vài cluster phổ biến thì không đủ, **cần cá nhân hoá**.

Cluster nào cũng **có nhiều booking**: độ thưa nằm ở **phía user**, không phải phía cluster.

03 · HƯỚNG GIẢI QUYẾT · CHỌN HƯỚNG TIẾP CẬN

⚠ **Không có thông tin khách sạn:** hotel_cluster chỉ là mã ẩn danh, nên không dùng được content-based.

✓ **Có sẵn:** lịch sử click và booking của từng user theo thời gian, nên dùng các hướng chỉ cần lịch sử tương tác.

CÁC HƯỚNG TIẾP CẬN CÓ THỂ SỬ DỤNG

Collaborative Filtering

User giống nhau, lựa chọn giống nhau: gợi ý dựa trên hành vi của các user tương tự.

Input: ma trận tương tác user × item, không quan tâm tới thứ tự.

Ví dụ: Matrix Factorization, LightGCL

Phù hợp khi: lịch sử từng user thưa, cần mượn tín hiệu từ user tương tự.

Sequential

Học thứ tự trong lịch sử dài hạn của từng user để dự đoán item tiếp theo.

Input: chuỗi item của từng user qua nhiều lần tương tác.

Ví dụ: SASRec, BERT4Rec

Phù hợp khi: user có chuỗi tương tác dài, thứ tự mang nhiều thông tin.

Session-based

Học thứ tự hành vi trong một phiên ngắn để dự đoán bước tiếp theo.

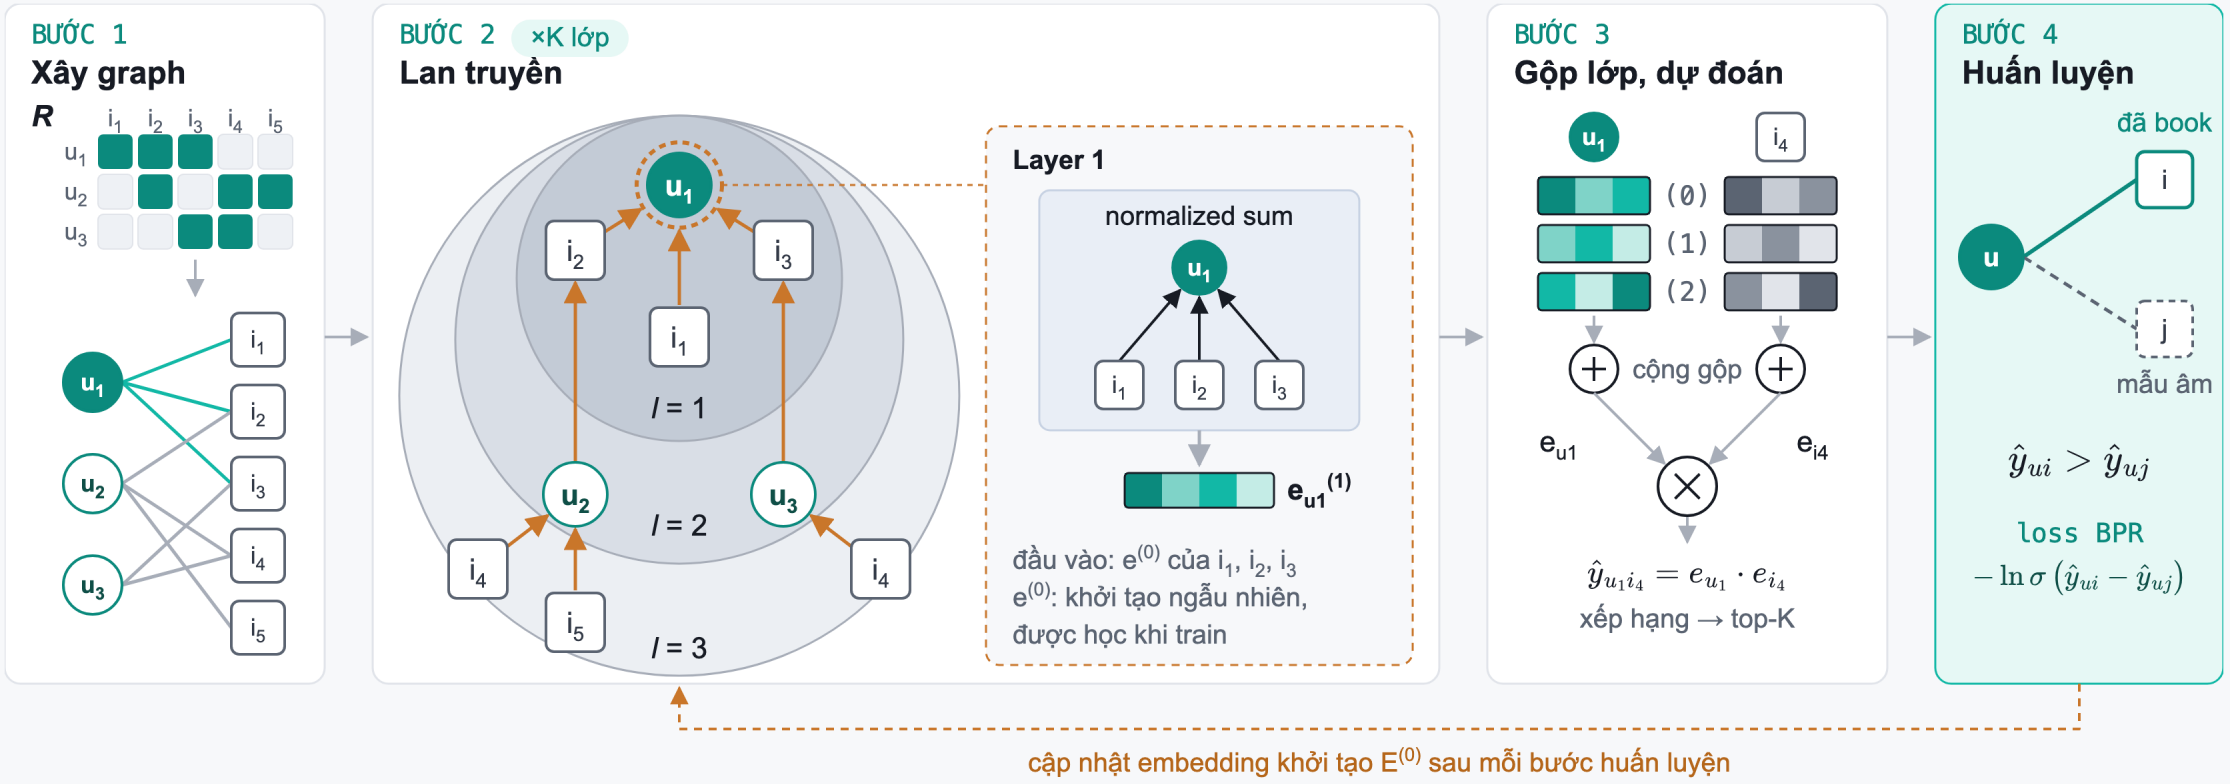
Input: chuỗi item trong một phiên, có thể ẩn danh.

Ví dụ: GRU4Rec, SR-GNN

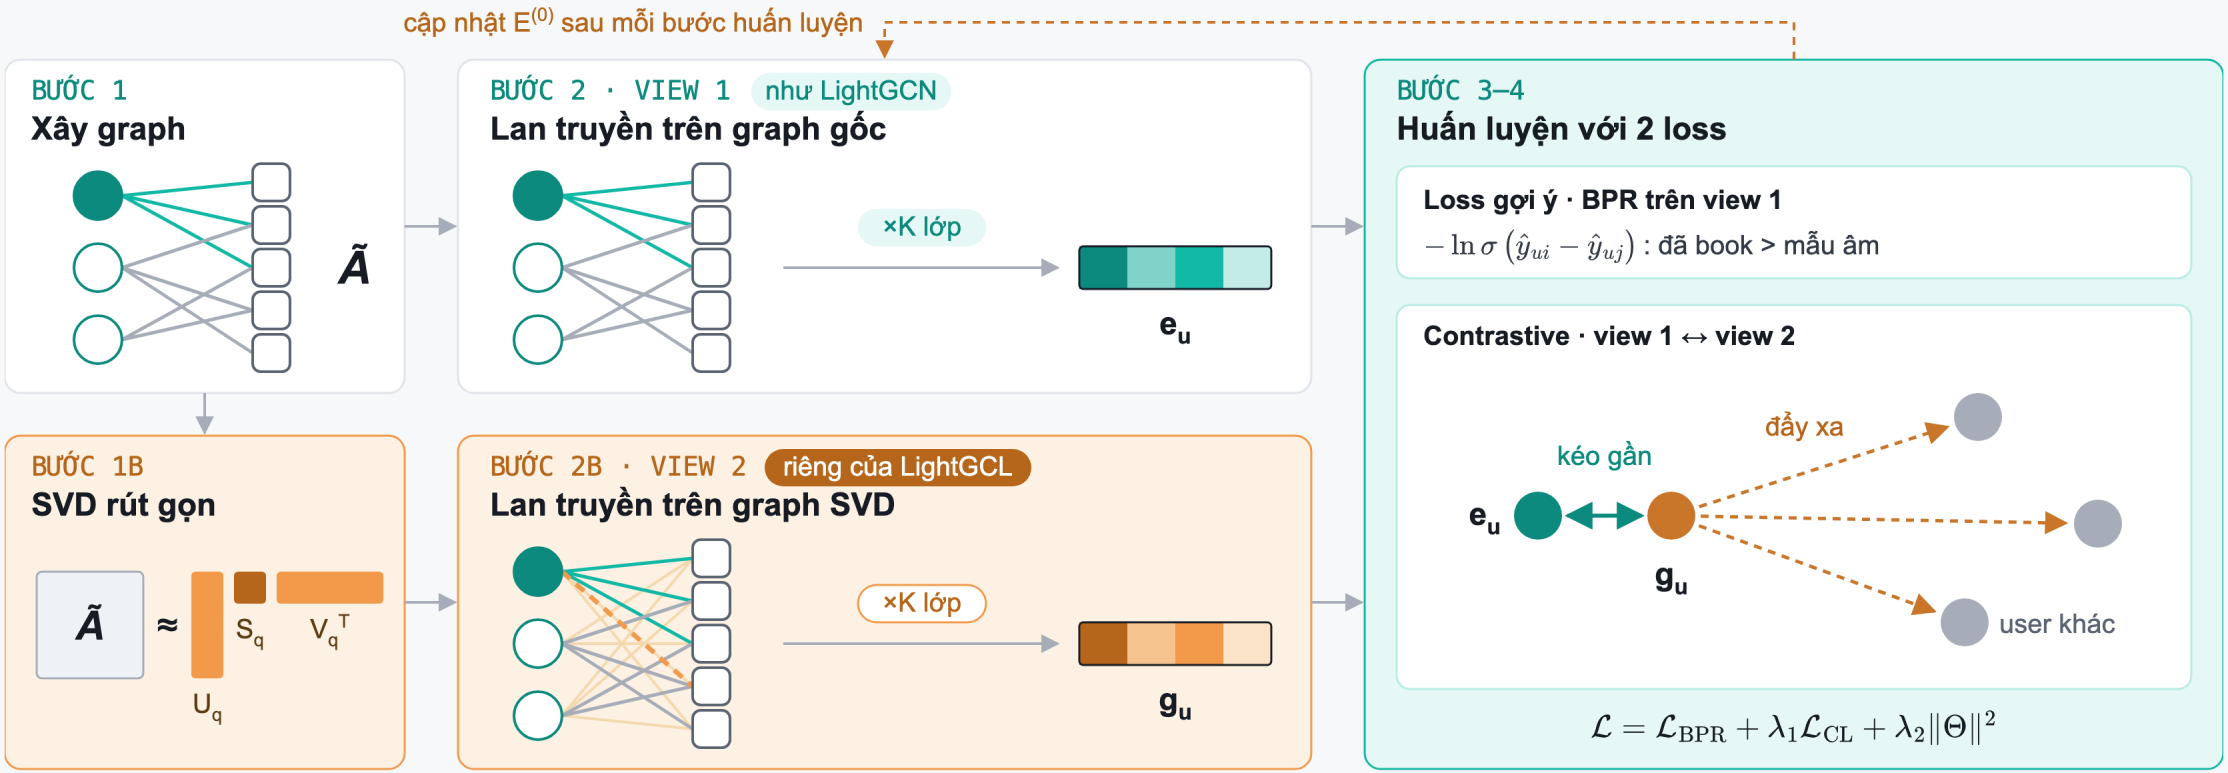
Phù hợp khi: user ẩn danh, ít hành vi trong phiên.

💡 **Kết luận:** chọn Collaborative Filtering, với phương pháp LightGCL (Cai et al., ICLR 2023).

Khung chung của graph-based CF



LightGCL: graph-based CF, thêm SVD view

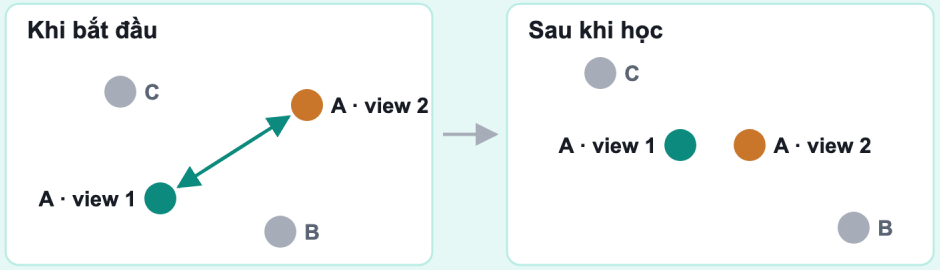


Khi gợi ý chỉ dùng embedding của đồ thị ban đầu; SVD view chỉ tác động qua quá trình train.

Contrastive learning với view SVD giúp học trên ma trận thưa

1 · CONTRASTIVE LEARNING

Kéo 2 view của cùng một user lại gần



$$\mathcal{L}_{\mathrm{CL}} = -\log \frac{\exp\left(g_u^{\top} e_u / \tau\right)}{\sum_v \exp\left(g_u^{\top} e_v / \tau\right)}$$

tử số: 2 view của cùng user u → kéo lại gần

mẫu số: so với mọi user v → đẩy user khác ra xa

e: view 1 (graph gốc) · g: view 2 (graph SVD) · τ: nhiệt độ

View 2 (graph SVD, xem bên dưới) nối thêm cluster mà user giống mình đã book

→ kéo hai view lại gần = học thêm từ user giống mình, không cần nhãn mới

2 · VIEW SVD

Hỗ trợ ma trận thưa, không thêm / xoá cạnh ngẫu nhiên

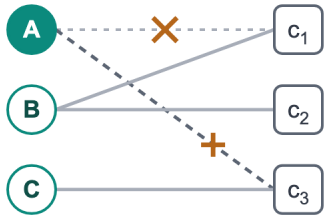
58% user có ≤ 1 booking: nhiều user chỉ có đúng 1 cạnh

Graph gốc



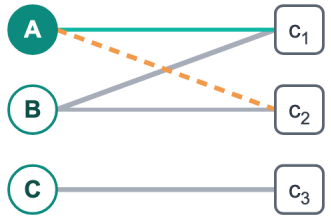
A chỉ có 1 cạnh: c_1

✗ Cách thường: thêm/xoá ngẫu nhiên



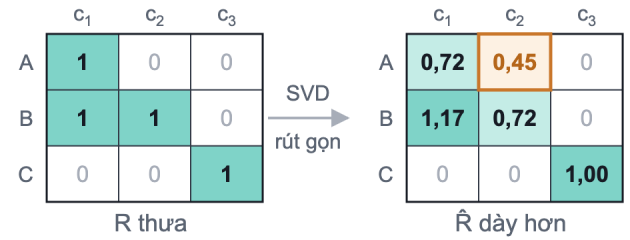
A mất cạnh thật duy nhất c_1,
lại bị nối ngẫu nhiên với c_3 → nhiễu

✓ LightGCL: tái dựng bằng SVD



Giữ mọi cạnh cũ,
thêm cạnh A–c_2 nhờ B (cùng book c_1)

Nhìn theo ma trận



Ô trống được lấp theo xu hướng chung, ô đã có vẫn còn

05 · THỬ NGHIỆM · ĐỐI CHIẾU CODE GỐC

Tái lập LightGCL trên Yelp: lệch so với paper không quá 1%

Metric	Paper	Tái lập	Lệch
Recall@20	0,0985	0,0975	−1,0%
NDCG@20	0,0842	0,0843	+0,1%
Recall@40	0,1553	0,1559	+0,4%
NDCG@40	0,1051	0,1055	+0,4%

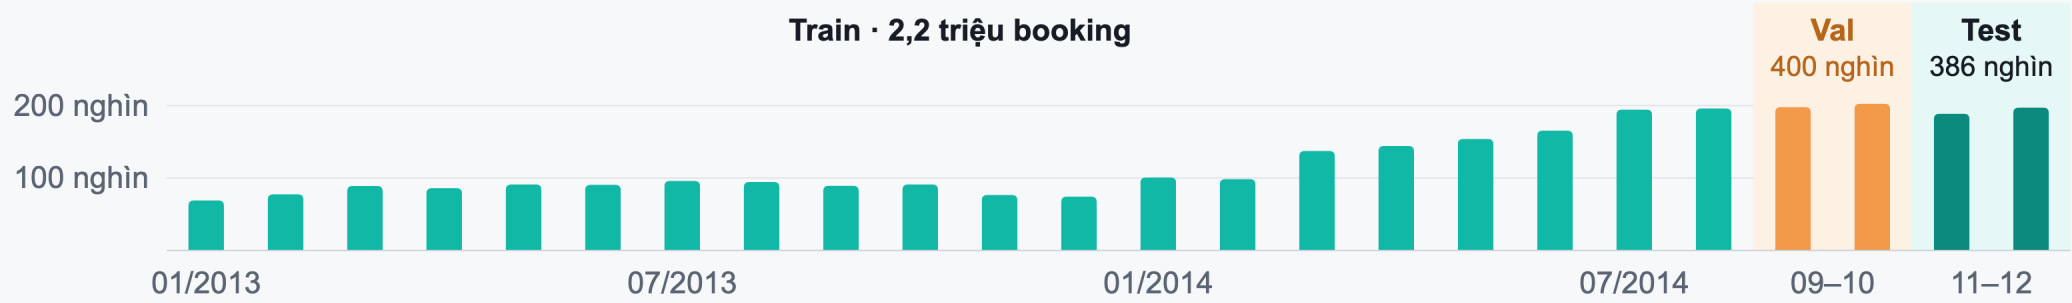
CÙNG ĐIỀU KIỆN VỚI PAPER

Bộ Yelp chia sẵn của repo HKUDS (29.601 user, 24.734 item), cấu hình mặc định, 100 epoch.

Mốc so sánh: Table 6 (Appendix E), kết quả của code hiện có trên GitHub.

✓ Model, vòng lặp train và cách tính metric này được giữ nguyên khi chuyển sang Expedia.

Graph từ booking, chia train / val / test theo thời gian



Graph	665 nghìn user × 100 cluster; 1,78 triệu cạnh từ 2,2 triệu booking trước 09/2014
Click	34,7 triệu dòng click không đưa vào graph
Test	11–12/2014, tự chia từ train.csv; test.csv của Kaggle không có nhãn nên không dùng
Chấm điểm	Giữ cluster user đã book trong danh sách gợi ý, vì đặt lại là hành vi phổ biến (khoảng 27% booking của user cũ ở giai đoạn train)
Baseline	Popular (xếp theo số user đã đặt) · History (cluster user đã đặt lên đầu, còn lại theo Popular) · BPR-MF (phân rã ma trận booking)
Metric	Recall@K (R), NDCG@K (N), MAP@K với K = 5, 10, 20; chọn tham số theo R@5; MAP@5 là metric của cuộc thi Expedia

Full softmax so với BPR

BPR · NEGATIVE SAMPLING

So với 1 cluster lấy ngẫu nhiên



mỗi cột: điểm ŷ của u với 1 cluster · cột xám: không được so

$$\mathcal{L}_{\text{BPR}} = -\ln \sigma\left(\hat{y}_{ui} - \hat{y}_{uj}\right) = -\ln \frac{\exp(\hat{y}_{ui})}{\exp(\hat{y}_{ui}) + \exp(\hat{y}_{uj})}$$

Mẫu âm có thể đã có điểm thấp → loss ≈ 0, model gần như không học được gì

FULL SOFTMAX

So với cả 100 cluster



mỗi cột: điểm ŷ của u với 1 cluster · cả 100 cluster đều được so

$$\mathcal{L}_{\text{softmax}} = -\ln \frac{\exp(\hat{y}_{ui})}{\sum_{c=1}^{100} \exp(\hat{y}_{uc})}$$

Chỉ 100 cluster nên so với cả tập vẫn nhẹ, không nhiễu do lấy mẫu

Loss gợi ý	Val R@5	Val R@20	Val NDCG@5	Val MAP@5
BPR · có negative sampling	0,2093	0,4837	0,1559	0,1205
Full softmax · không negative sampling	0,2102	0,4870	0,1573	0,1218

Time attention: cạnh mang trọng số là số lần book và recency

1 · CHỈ SỐ LẦN BOOK

Book bao nhiêu lần

	c_1	c_2	c_3	c_4
u_1	3	1	0	0
u_2	0	1	2	1
u_3	0	0	0	1

R: số lần book; LightGCL chuẩn hoá thành Â

u_1: c_1 book 3 lần > c_2 1 lần

2 · CHỈ RECENCY

Book gần đây hay đã lâu

	c_1	c_2	c_3	c_4
u_1	0,39 365 ngày	0,95 30 ngày	0	0
u_2	0	0,67 200 ngày	0,98 10 ngày	0,17 500 ngày
u_3	0	0	0	0,90 60 ngày

$$\tilde{t}_{uc} = \mathrm{MinMaxScaler}\left(t_{uc}^{\mathrm{last}}\right) = \frac{t_{uc}^{\mathrm{last}} - t_{\min}}{t_{\max} - t_{\min}}$$

t^{last}: lần book gần nhất · 1 = mới nhất, 0 = cũ nhất

3 · TRỘN · TIME ATTENTION

Kết hợp cả hai

	c_1	c_2	c_3	c_4
u_1	0,62	0,49	0	0
u_2	0	0,34	0,58	0,28
u_3	0	0	0	0,85

$$w_{uc} = \tfrac{1}{2}\,\hat{A}_{uc} + \tfrac{1}{2}\,\alpha_{uc}, \quad \alpha_{uc} = \frac{\exp(\tilde{t}_{uc})}{\sum_{c' \in \mathcal{N}(u)} \exp(\tilde{t}_{uc'})}$$

Â = normalize_adj(R) · α: softmax từng hàng của (2)

Model	Val R@5	Val R@20	Val NDCG@5	Val MAP@5
Cạnh 0–1 · bản gốc	0,2102	0,4870	0,1573	0,1218
Cạnh theo số lần book	0,2160	0,4958	0,1633	0,1273
Cạnh theo recency	0,2251	0,4831	0,1694	0,1322
Kết hợp · time attention	0,2296	0,5229	0,1738	0,1361

Ba baseline để so sánh: Popular, History và BPR-MF

Ví dụ minh hoạ: một user đã book cluster 42 hai lần và cluster 17 một lần.

POPULAR

Ai cũng nhận danh sách phổ biến nhất

Xếp cluster theo số user đã đặt; mọi user nhận cùng một danh sách.

Top-5 cho user ví dụ:

91 48 42 59 28

→ Mốc thấp nhất, không cá nhân hoá; cũng là gợi ý cho user chưa từng book.

HISTORY

Đưa cluster user đã đặt lên đầu

Cluster đã book xếp trước (book nhiều lần đứng trước), chỗ còn lại lấp theo Popular.

Top-5 cho user ví dụ:

42 **17** 91 48 59

→ Đo sức mạnh của hành vi đặt lại: 27,7% booking của user cũ là cluster đã đặt.

BPR-MF

Collaborative filtering cổ điển, không có graph

Phân rã ma trận user × cluster thành embedding, học bằng loss BPR; điểm gợi ý là độ gần của hai embedding.

Train lại trên booking của train + val tới 10/2014.

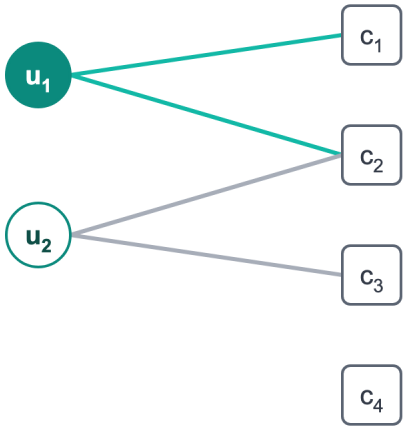
→ Cho thấy phần đóng góp của lan truyền trên graph và view SVD trong LightGCL.

Khi có booking mới, model cập nhật trọng số cạnh mà không train lại

Train một lần: booking 01/2013–08/2014 | **Fold-in: booking 09–10/2014** | **Nhãn test: 11–12/2014**

① GRAPH LÚC TRAIN

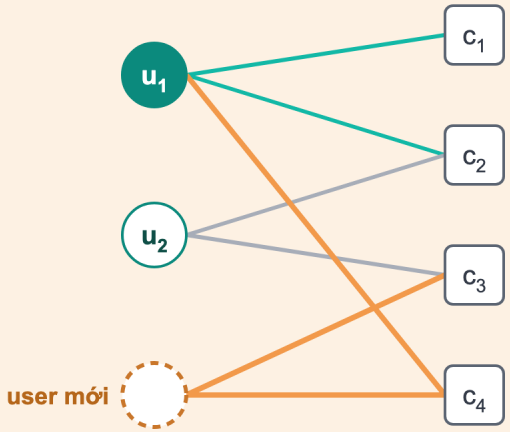
Học $E^{(0)}$ cho user và cluster



Chỉ dùng booking trước 09/2014, chọn epoch bằng validation

② THÊM BOOKING 09–10/2014

Cập nhật graph, không train lại



Thêm node và cạnh mới (cam), chuẩn hoá lại ma trận kề, tính lại time attention

③ LAN TRUYỀN LẠI

Dùng tham số đã train

$E^{(0)}$ của user mới = 0 → 0 0 0 0

Cluster vừa book: c_3 + c_4

$e_{\text{user mới}}$

lấy từ các cluster vừa book

→ chấm $\hat{y} = e_u \cdot e_c$ trên 100 cluster, lấy top-5

User cũ (u_1) cũng nhận thêm tín hiệu từ cạnh mới

06 · TỔNG KẾT · KẾT QUẢ TRÊN TEST

Với time attention, LightGCL vượt cả ba baseline dựa trên booking

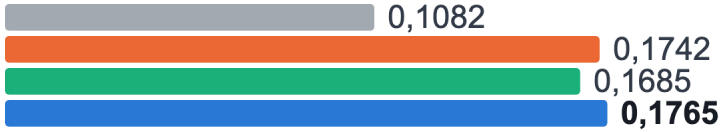
Popular History BPR-MF LightGCL + time attention

TOP-5

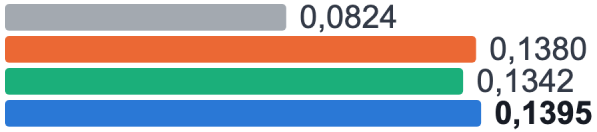
Recall@5



NDCG@5



MAP@5



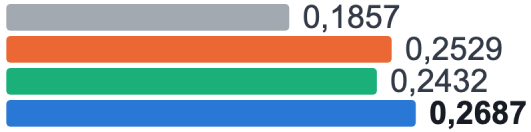
So với History (tương đối): Recall +1,9% · NDCG +1,3% · MAP +1,1%

TOP-20

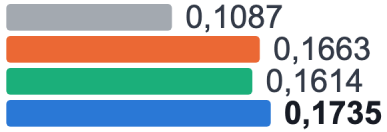
Recall@20



NDCG@20



MAP@20



So với History (tương đối): Recall +9,7% · NDCG +6,2% · MAP +4,3%

06 · TỔNG KẾT · KẾT QUẢ CUỐI

Với user mới hoàn toàn, model vẫn gợi ý tốt nhờ graph đã xây

TOÀN BỘ USER TEST · 150.971 USER

Model	Recall@5	NDCG@5	MAP@5
Popular	0,1523	0,1082	0,0824
History	0,2308	0,1742	0,1380
BPR-MF (train lại)	0,2210	0,1685	0,1342
LightGCL + time attention	0,2353	0,1765	0,1395

TRONG ĐÓ: USER MỚI · 15.382 USER

Model	Recall@5	NDCG@5	MAP@5
Popular	0,1501	0,1061	0,0808
History	0,2325	0,1851	0,1519
BPR-MF (train lại)	0,2237	0,1807	0,1492
LightGCL + time attention	0,2411	0,1906	0,1561

User mới: chưa có lịch sử book nào trước 09/2014 nên lúc train không có trong graph; lần book đầu rơi vào 09–10/2014.
Chỉ cần thêm các booking của user này vào graph rồi lan truyền, không train lại, model vẫn cho kết quả tốt.

Cold-start: 32,2% user test chưa có booking nào trước 11/2014, nên không có embedding để đưa vào graph.
Với nhóm này mọi phương pháp đều không áp dụng được, chỉ có thể dùng Popular (Recall@5 0,1323) nên không đưa vào bảng.

HIỆU CHỈNH THAM SỐ

Tham số	Chọn	Lý do (theo validation)
Learning rate	1e-4	Đỉnh validation cao nhất và giảm chậm nhất sau đỉnh
Hạng SVD q	q = 2	q lớn làm view SVD gần graph gốc, mất tác dụng chống học thuộc
L2 (λ2)	1e-5	Dò lại sau mỗi thay đổi graph; mạnh hơn thì model học kém đi
Early stopping	patience 3	Dừng khi val R@5 không tăng, giữ epoch tốt nhất
Batch	1024	Batch 4096 như paper không đủ bộ nhớ GPU

Cố định: kích thước embedding 64, hệ số contrastive loss 0,2.