# LightGCL cho gợi ý đặt phòng khách sạn trên Expedia

**Phạm Anh Minh** · Mentor: **Lê Huỳnh Đức**

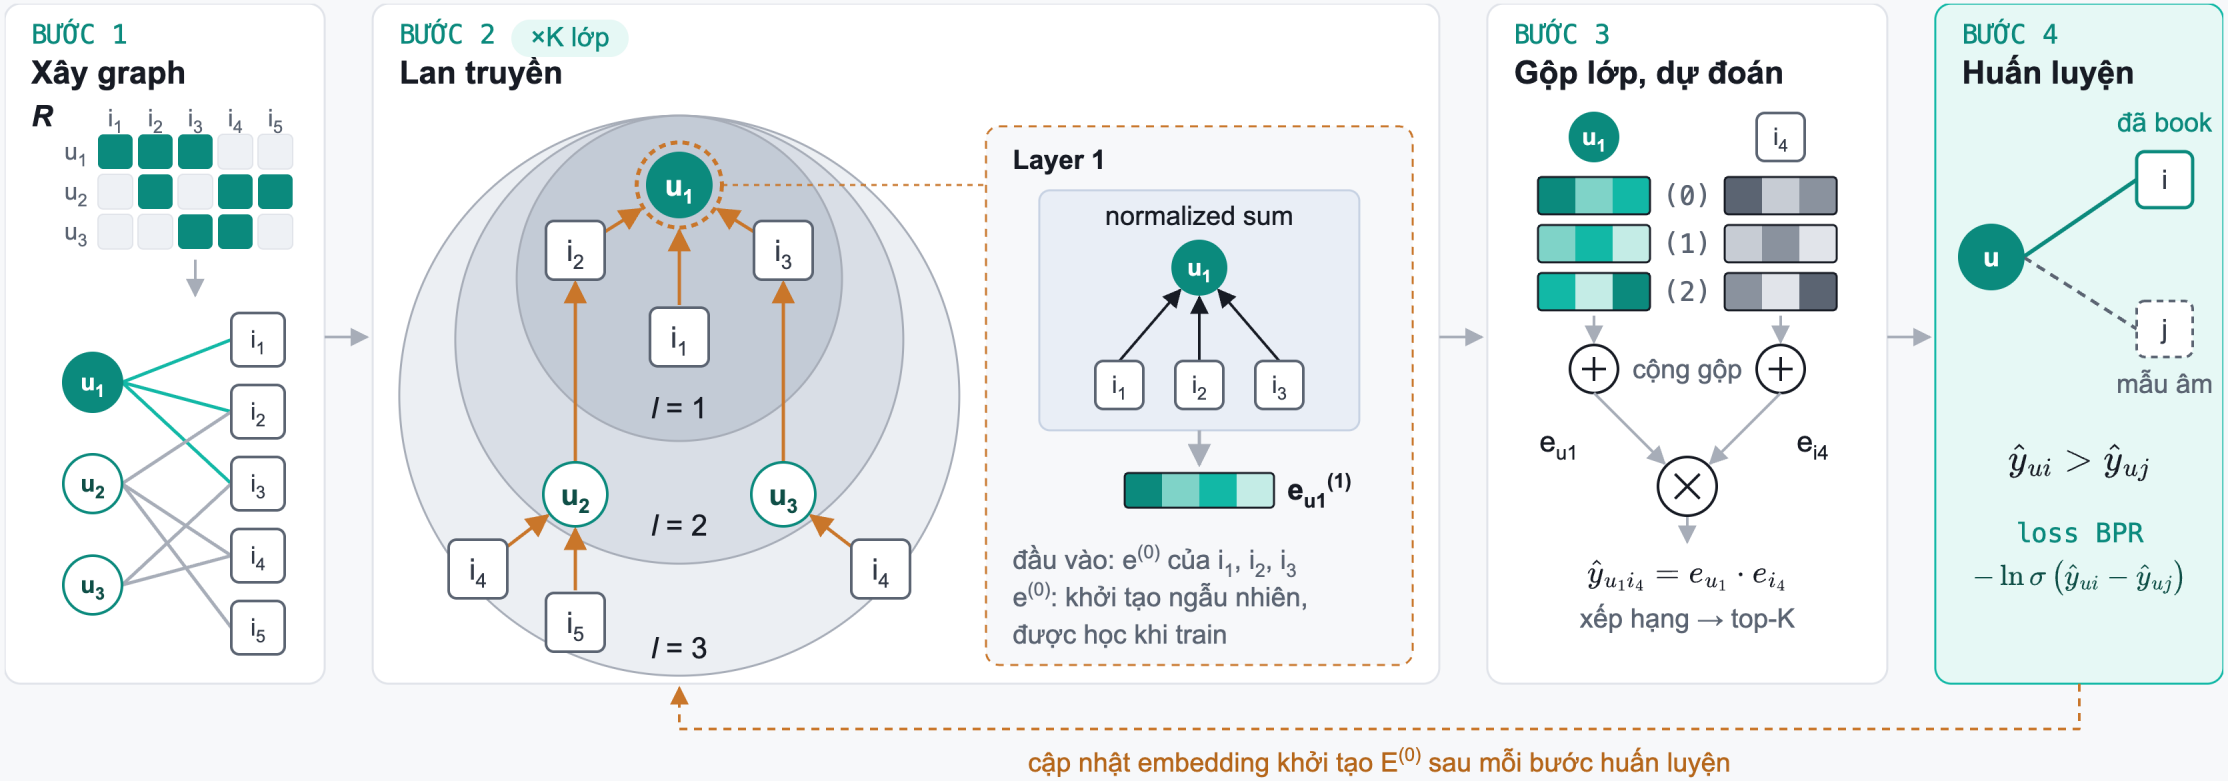
01
**Dataset Expedia và EDA**

02
**Methodology: LightGCL**

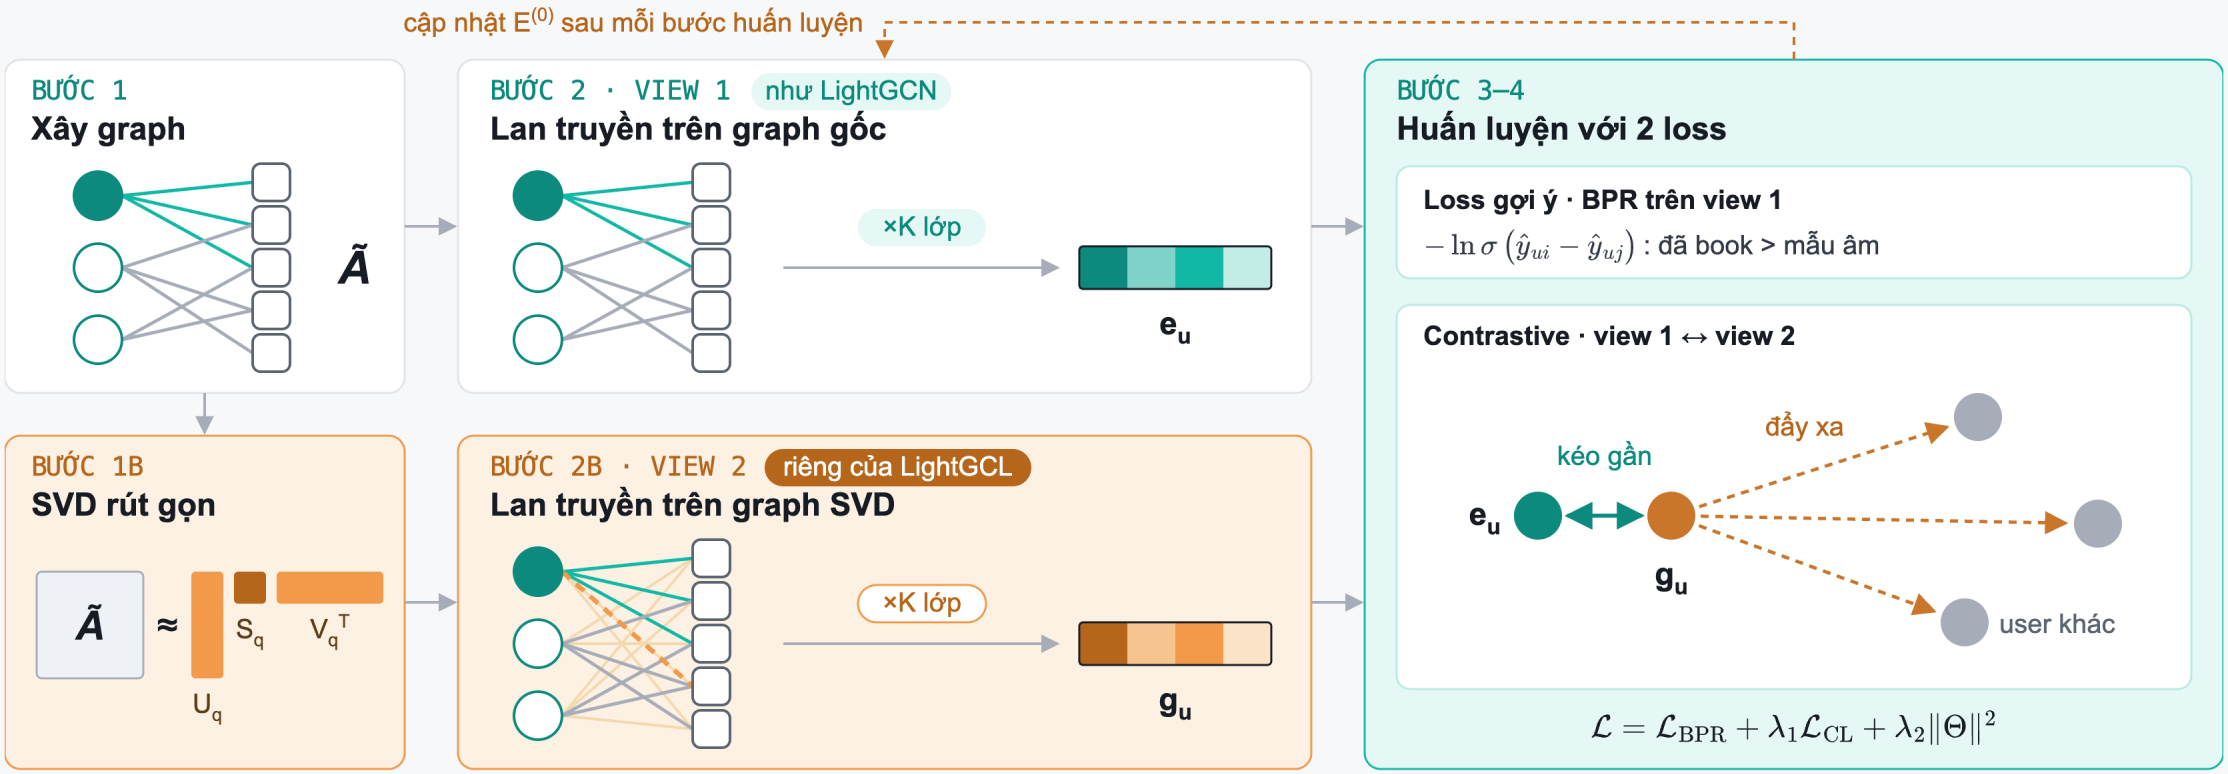
03
**Thử nghiệm và cải tiến**

04
**Tổng kết**

# Khung chung của graph-based CF



# LightGCL: graph-based CF, thêm SVD view



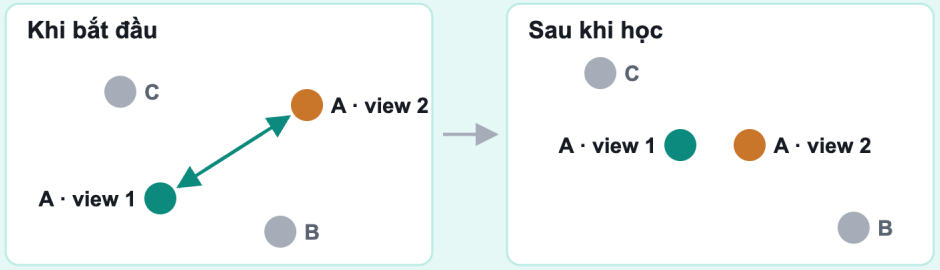

Khi gợi ý chỉ dùng embedding của đồ thị ban đầu; SVD view chỉ tác động qua quá trình train.

01 · METHODOLOGY · ĐIỂM MỚI

# Contrastive learning với view SVD giúp học trên ma trận thưa

1 · CONTRASTIVE LEARNING

## Kéo 2 view của cùng một user lại gần




$$\mathcal{L}_{\mathrm{CL}} = -\log \frac{\exp\left(g_u^{\top} e_u / \tau\right)}{\sum_v \exp\left(g_u^{\top} e_v / \tau\right)}$$

**tử số: 2 view của cùng user u → kéo lại gần**

**mẫu số: so với mọi user v → đẩy user khác ra xa**

e: view 1 (graph gốc) · g: view 2 (graph SVD) · τ: nhiệt độ

View 2 (graph SVD, xem bên dưới) nối thêm cluster mà user giống mình đã book

→ **kéo hai view lại gần = học thêm từ user giống mình, không cần nhãn mới**

2 · VIEW SVD

## Hỗ trợ ma trận thưa, không thêm / xoá cạnh ngẫu nhiên

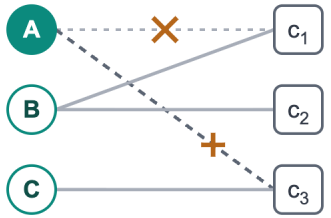
58% user có ≤ 1 booking: nhiều user chỉ có đúng 1 cạnh

**Graph gốc**



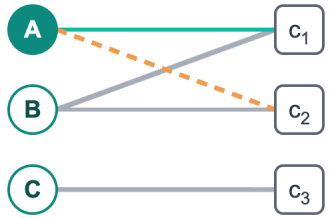

A chỉ có 1 cạnh: $c_1$

**✗ Cách thường: thêm/xoá ngẫu nhiên**



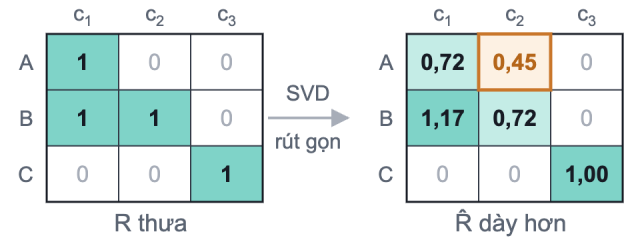

A mất cạnh thật duy nhất $c_1$,
lại bị nối ngẫu nhiên với $c_3$ → nhiễu

**✓ LightGCL: tái dựng bằng SVD**



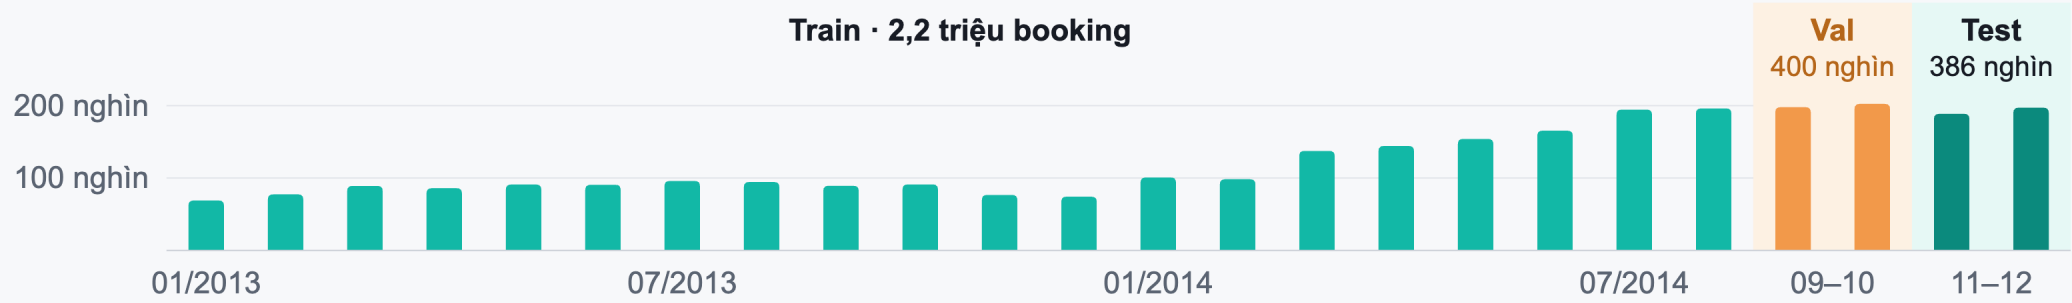

Giữ mọi cạnh cũ,
thêm cạnh A–$c_2$ nhờ B (cùng book $c_1$)

**Nhìn theo ma trận**




Ô trống được lấp theo xu hướng chung, ô đã có vẫn còn

# Graph từ booking, chia train / val / test theo thời gian




| | |
|---|---|
| Graph | 665 nghìn user × 100 cluster; 1,78 triệu cạnh từ 2,2 triệu booking trước 09/2014 |
| Click | 34,7 triệu dòng click không đưa vào graph |
| Test | 11–12/2014, tự chia từ train.csv; test.csv của Kaggle không có nhãn nên không dùng |
| Chấm điểm | Giữ cluster user đã book trong danh sách gợi ý, vì đặt lại là hành vi phổ biến (khoảng 27% booking của user cũ ở giai đoạn train) |
| Baseline | Popular (xếp theo số user đã đặt) · History (cluster user đã đặt lên đầu, còn lại theo Popular) · BPR-MF (phân rã ma trận booking) |
| Metric | Recall@K (R), NDCG@K (N), MAP@K với K = 5, 10, 20; chọn tham số theo R@5; MAP@5 là metric của cuộc thi Expedia |

# Full softmax so với BPR

BPR · NEGATIVE SAMPLING

**So với 1 cluster lấy ngẫu nhiên**




mỗi cột: điểm ŷ của u với 1 cluster · cột xám: không được so

$$\mathcal{L}_{\text{BPR}} = -\ln \sigma\left(\hat{y}_{ui} - \hat{y}_{uj}\right) = -\ln \frac{\exp(\hat{y}_{ui})}{\exp(\hat{y}_{ui}) + \exp(\hat{y}_{uj})}$$

Mẫu âm có thể đã có điểm thấp → loss ≈ 0, model gần như không học được gì

FULL SOFTMAX

**So với cả 100 cluster**




mỗi cột: điểm ŷ của u với 1 cluster · cả 100 cluster đều được so

$$\mathcal{L}_{\text{softmax}} = -\ln \frac{\exp(\hat{y}_{ui})}{\sum_{c=1}^{100} \exp(\hat{y}_{uc})}$$

Chỉ 100 cluster nên so với cả tập vẫn nhẹ, không nhiễu do lấy mẫu

| Loss gợi ý | Val R@5 | Val R@20 | Val NDCG@5 | Val MAP@5 |
|---|---|---|---|---|
| BPR · có negative sampling | 0,2093 | 0,4837 | 0,1559 | 0,1205 |
| Full softmax · không negative sampling | 0,2102 | 0,4870 | 0,1573 | 0,1218 |

# Time attention: cạnh mang trọng số là số lần book và recency

### 1 · CHỈ SỐ LẦN BOOK

**Book bao nhiêu lần**

| | $c_1$ | $c_2$ | $c_3$ | $c_4$ |
|---|---|---|---|---|
| $u_1$ | 3 | 1 | 0 | 0 |
| $u_2$ | 0 | 1 | 2 | 1 |
| $u_3$ | 0 | 0 | 0 | 1 |

R: số lần book; LightGCL chuẩn hoá thành Â

$u_1$: $c_1$ book 3 lần > $c_2$ 1 lần

### 2 · CHỈ RECENCY

**Book gần đây hay đã lâu**

| | $c_1$ | $c_2$ | $c_3$ | $c_4$ |
|---|---|---|---|---|
| $u_1$ | 0,39 (365 ngày) | 0,95 (30 ngày) | 0 | 0 |
| $u_2$ | 0 | 0,67 (200 ngày) | 0,98 (10 ngày) | 0,17 (500 ngày) |
| $u_3$ | 0 | 0 | 0 | 0,90 (60 ngày) |

$$\tilde{t}_{uc} = \mathrm{MinMaxScaler}\left(t_{uc}^{\mathrm{last}}\right) = \frac{t_{uc}^{\mathrm{last}} - t_{\min}}{t_{\max} - t_{\min}}$$

$t^{\mathrm{last}}$: lần book gần nhất · 1 = mới nhất, 0 = cũ nhất

### 3 · TRỘN · TIME ATTENTION

**Kết hợp cả hai**

| | $c_1$ | $c_2$ | $c_3$ | $c_4$ |
|---|---|---|---|---|
| $u_1$ | 0,62 | 0,49 | 0 | 0 |
| $u_2$ | 0 | 0,34 | 0,58 | 0,28 |
| $u_3$ | 0 | 0 | 0 | 0,85 |

$$w_{uc} = \tfrac{1}{2}\,\hat{A}_{uc} + \tfrac{1}{2}\,\alpha_{uc}, \quad \alpha_{uc} = \frac{\exp(\tilde{t}_{uc})}{\sum_{c' \in \mathcal{N}(u)} \exp(\tilde{t}_{uc'})}$$

Â = normalize_adj(R) · α: softmax từng hàng của (2)

| Model | Val R@5 | Val R@20 | Val NDCG@5 | Val MAP@5 |
|---|---|---|---|---|
| Cạnh 0–1 · bản gốc | 0,2102 | 0,4870 | 0,1573 | 0,1218 |
| Cạnh theo số lần book | 0,2160 | 0,4958 | 0,1633 | 0,1273 |
| Cạnh theo recency | 0,2251 | 0,4831 | 0,1694 | 0,1322 |
| Kết hợp · time attention | 0,2296 | 0,5229 | 0,1738 | 0,1361 |

02 · THỬ NGHIỆM · BASELINE

# Ba baseline để so sánh: Popular, History và BPR-MF

**Ví dụ minh hoạ:** một user đã book cluster 42 hai lần và cluster 17 một lần.

POPULAR

## Ai cũng nhận danh sách phổ biến nhất

Xếp cluster theo số user đã đặt; mọi user nhận cùng một danh sách.

Top-5 cho user ví dụ:

91 48 42 59 28

→ Mốc thấp nhất, không cá nhân hoá; cũng là gợi ý cho user chưa từng book.

HISTORY

## Đưa cluster user đã đặt lên đầu

Cluster đã book xếp trước (book nhiều lần đứng trước), chỗ còn lại lấp theo Popular.

Top-5 cho user ví dụ:

**42** **17** 91 48 59

→ Đo sức mạnh của hành vi đặt lại: 27,7% booking của user cũ là cluster đã đặt.

BPR-MF

## Collaborative filtering cổ điển, không có graph

Phân rã ma trận user × cluster thành embedding, học bằng loss BPR; điểm gợi ý là độ gần của hai embedding.

Train lại trên booking của train + val tới 10/2014.

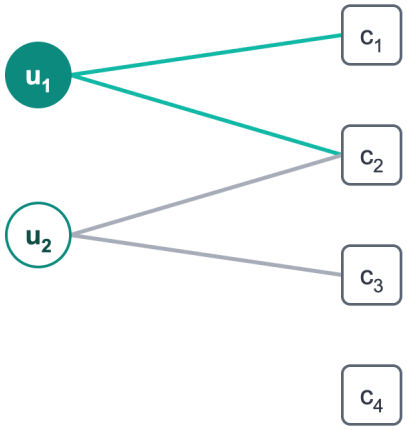
→ Cho thấy phần đóng góp của lan truyền trên graph và view SVD trong LightGCL.

# Khi có booking mới, model cập nhật trọng số cạnh mà không train lại

**Train một lần: booking 01/2013–08/2014** | **Fold-in: booking 09–10/2014** | **Nhãn test: 11–12/2014**

## ① GRAPH LÚC TRAIN

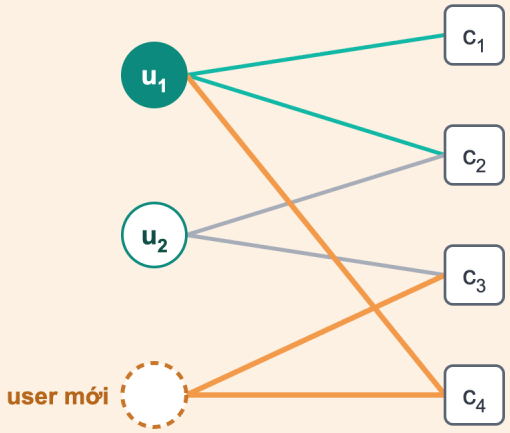
**Học $E^{(0)}$ cho user và cluster**




Chỉ dùng booking trước 09/2014, chọn epoch bằng validation

## ② THÊM BOOKING 09–10/2014

**Cập nhật graph, không train lại**




Thêm node và cạnh mới (cam), chuẩn hoá lại ma trận kề, tính lại time attention

## ③ LAN TRUYỀN LẠI

**Dùng tham số đã train**

$E^{(0)}$ của user mới = 0 → 0 0 0 0

Cluster vừa book: $c_3$ + $c_4$

$e_{\text{user mới}}$

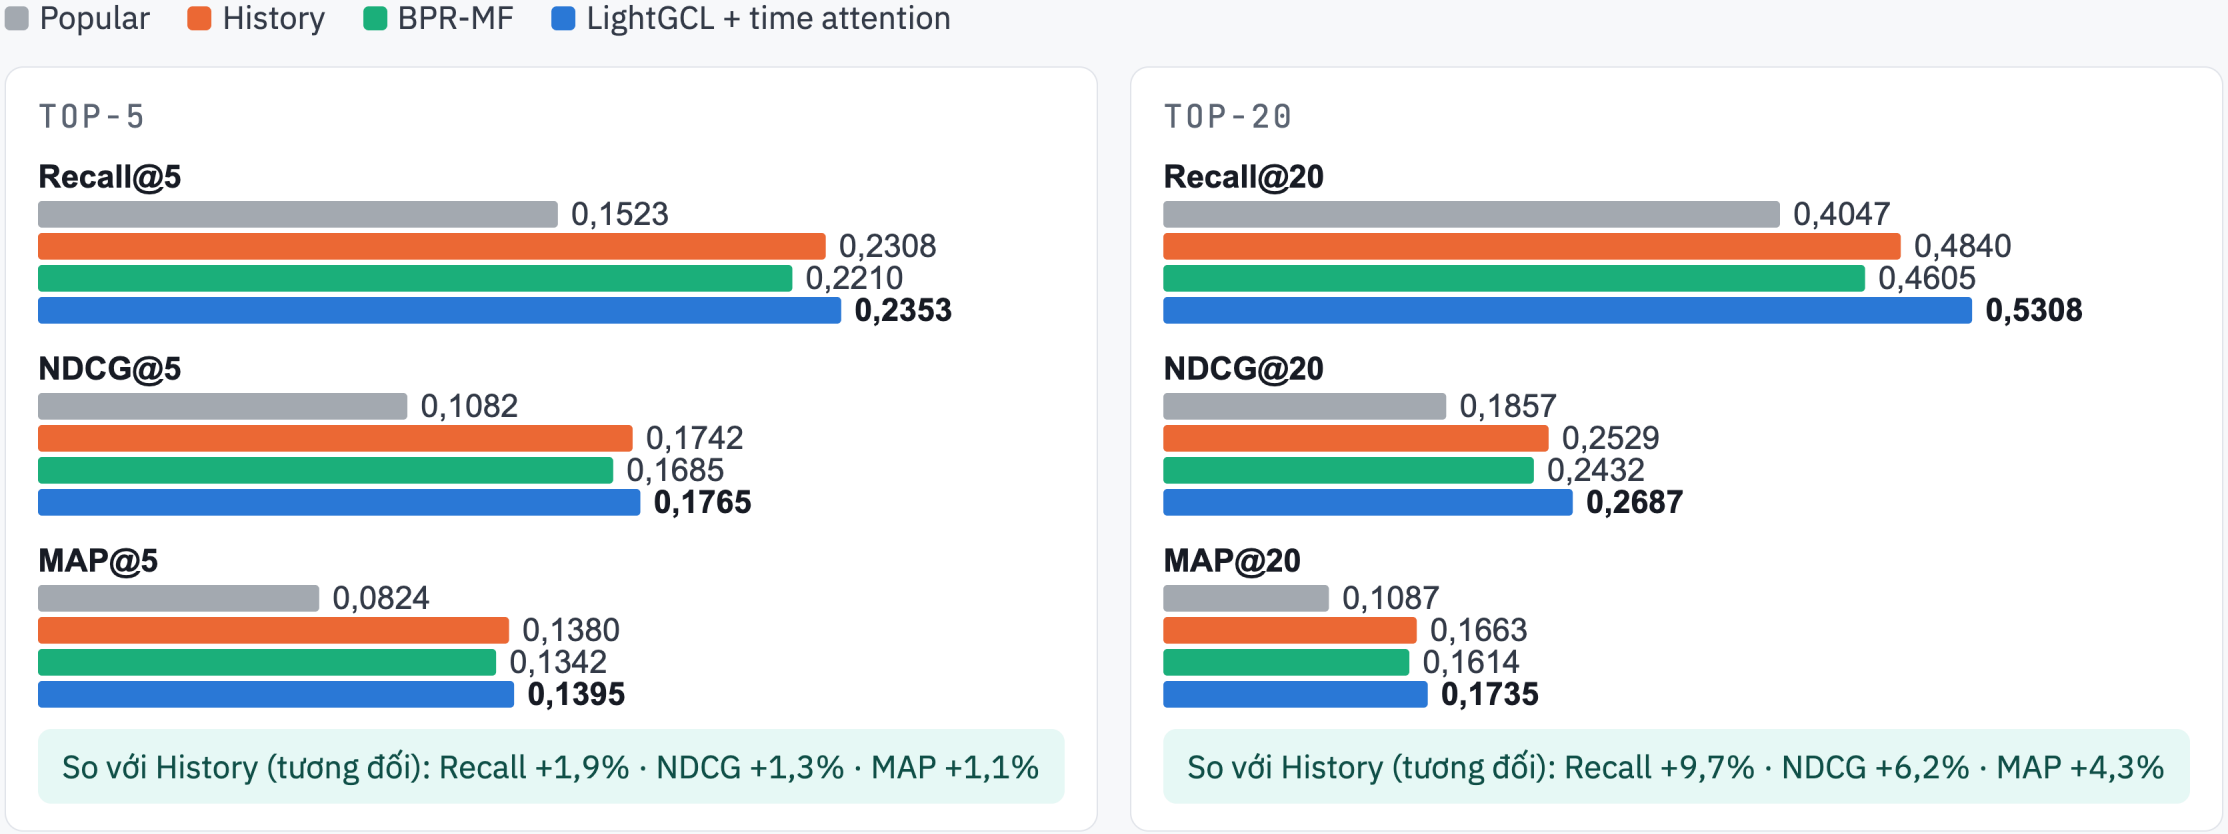
**lấy từ các cluster vừa book**

→ chấm $\hat{y} = e_u \cdot e_c$ trên 100 cluster, lấy top-5

User cũ ($u_1$) cũng nhận thêm tín hiệu từ cạnh mới

03 · TỔNG KẾT · KẾT QUẢ TRÊN TEST

# Với time attention, LightGCL vượt cả ba baseline dựa trên booking




So với History (tương đối): Recall +1,9% · NDCG +1,3% · MAP +1,1%

So với History (tương đối): Recall +9,7% · NDCG +6,2% · MAP +4,3%

03 · TỔNG KẾT · KẾT QUẢ CUỐI

# Với user mới hoàn toàn, model vẫn gợi ý tốt nhờ graph đã xây

TOÀN BỘ USER TEST · 150.971 USER

| Model | Recall@5 | NDCG@5 | MAP@5 |
|---|---|---|---|
| Popular | 0,1523 | 0,1082 | 0,0824 |
| History | 0,2308 | 0,1742 | 0,1380 |
| BPR-MF (train lại) | 0,2210 | 0,1685 | 0,1342 |
| LightGCL + time attention | 0,2353 | 0,1765 | 0,1395 |

TRONG ĐÓ: USER MỚI · 15.382 USER

| Model | Recall@5 | NDCG@5 | MAP@5 |
|---|---|---|---|
| Popular | 0,1501 | 0,1061 | 0,0808 |
| History | 0,2325 | 0,1851 | 0,1519 |
| BPR-MF (train lại) | 0,2237 | 0,1807 | 0,1492 |
| LightGCL + time attention | 0,2411 | 0,1906 | 0,1561 |

**User mới:** chưa có lịch sử book nào trước 09/2014 nên lúc train không có trong graph; lần book đầu rơi vào 09–10/2014.
Chỉ cần thêm các booking của user này vào graph rồi lan truyền, không train lại, model vẫn cho kết quả tốt.

**Cold-start:** 32,2% user test chưa có booking nào trước 11/2014, nên không có embedding để đưa vào graph.
Với nhóm này mọi phương pháp đều không áp dụng được, chỉ có thể dùng Popular (Recall@5 0,1323) nên không đưa vào bảng.

PHỤ LỤC · ĐỐI CHIẾU CODE GỐC

# Tái lập LightGCL trên Yelp: lệch so với paper không quá 1%

| Metric | Paper | Tái lập | Lệch |
|---|---|---|---|
| Recall@20 | 0,0985 | 0,0975 | −1,0% |
| NDCG@20 | 0,0842 | 0,0843 | +0,1% |
| Recall@40 | 0,1553 | 0,1559 | +0,4% |
| NDCG@40 | 0,1051 | 0,1055 | +0,4% |

### CÙNG ĐIỀU KIỆN VỚI PAPER

Bộ Yelp chia sẵn của repo HKUDS (29.601 user, 24.734 item), cấu hình mặc định, 100 epoch.

Mốc so sánh: Table 6 (Appendix E), kết quả của code hiện có trên GitHub.

✓ Model, vòng lặp train và cách tính metric này được giữ nguyên khi chuyển sang Expedia.

## PHỤ LỤC · HIỆU CHỈNH THAM SỐ

| Tham số | Chọn | Lý do (theo validation) |
|---|---|---|
| Learning rate | 1e-4 | Đỉnh validation cao nhất và giảm chậm nhất sau đỉnh |
| Hạng SVD q | q = 2 | q lớn làm view SVD gần graph gốc, mất tác dụng chống học thuộc |
| L2 (λ2) | 1e-5 | Dò lại sau mỗi thay đổi graph; mạnh hơn thì model học kém đi |
| Early stopping | patience 3 | Dừng khi val R@5 không tăng, giữ epoch tốt nhất |
| Batch | 1024 | Batch 4096 như paper không đủ bộ nhớ GPU |

Cố định: kích thước embedding 64, hệ số contrastive loss 0,2.