

LightGCL trên Expedia

Thử nghiệm và kết quả

Hai baseline để so sánh: Popular và History

POPULAR

Cùng một danh sách cho mọi user

Xếp 100 cluster theo số user đã đặt cluster đó trong giai đoạn train (trước 09/2014).

TOP-5 TRÊN EXPEDIA

91 • 48 • 42 • 59 • 28

Lần lượt 9,5%, 7,0%, 6,1%, 5,8% và 5,6% user đã đặt

Mốc tối thiểu: model nào thua Popular là chưa học được gì từ từng user.

HISTORY

Ưu tiên cluster user đã đặt

Các cluster user đã đặt trong giai đoạn train đứng đầu, đặt càng nhiều lần càng xếp trước, hoà nhau thì theo Popular. Các vị trí còn lại lấp theo thứ tự Popular.

VÍ DỤ MINH HOẠ

User đặt cluster 7 hai lần và cluster 30 một lần:

7 • 30 • 91 • 48 • 42

Mạnh vì user hay đặt lại: 15,6% cặp (user, cluster) ở train được đặt hơn một lần; 12,6% cặp ở test là đặt lại cluster cũ.

- Hai baseline và LightGCL được chấm trên cùng tập user test, cùng nhãn và cùng metric.

Tái lập LightGCL trên Yelp: kết quả giống so với paper

Metric	Paper	Notebook	Lệch
Recall@20	0,0985	0,0975	-1,0%
NDCG@20	0,0842	0,0843	+0,1%
Recall@40	0,1553	0,1559	+0,4%
NDCG@40	0,1051	0,1055	+0,4%

✔ CÙNG ĐIỀU KIỆN VỚI PAPER

Bộ Yelp đã chia sẵn của repo HKUDS (29.601 user, 24.734 item), cấu hình mặc định, 100 epoch. Mốc so sánh là Table 6 (Appendix E), kết quả của code hiện có trên GitHub.

- Model, vòng lặp train và cách tính metric này được dùng lại nguyên vẹn cho Expedia.

Từ Yelp sang Expedia: graph chỉ dựng từ booking

Khía cạnh	Yelp (paper)	Expedia (thử nghiệm này)
Tương tác	Đánh giá user-business, có sẵn trong bộ dữ liệu của tác giả	Chỉ dòng booking (is_booking = 1); 34,7 triệu dòng click không dùng
Item	24.734 business	100 hotel_cluster
Cạnh của graph	Mỗi cặp (user, business); trung bình 36 item mỗi user	Mỗi cặp (user, cluster) đã đặt; đặt lại nhiều lần gộp thành 1 cạnh; trung bình 2,7 cluster mỗi user
Chia dữ liệu	Train/test chia sẵn bởi tác giả	Theo thời gian: train trước 09/2014, validation 09-10, test 11-12/2014
Cách chấm	Bỏ các item user đã tương tác ở train khỏi danh sách gợi ý	Giữ các cluster user đã đặt trong danh sách, vì đặt lại cluster cũ là hành vi phổ biến (12,6% cặp ở test)
Batch	4096	1024 (do phải tính contrastive loss trên 665 nghìn user)

Dấu hiệu overfit: với 100 cluster, model học thuộc cluster của từng user

Với cấu hình gốc, recall trên validation đạt đỉnh ngay epoch đầu rồi giảm dần.

DẤU HIỆU 1 · TRAIN TỐT LÊN, VAL XẤU ĐI

0,4250 → 0,3448

Recall@20 trên tập val giảm từ epoch 1 đến epoch 20, trong khi loss train vẫn giảm đều từ 0,47 xuống 0,04.



DẤU HIỆU 2 · REC LOSS TẬP TRAIN GẦN 0

BPR loss ≈ 0,04

Model xếp gần như đúng mọi cặp đã book trong train, nhưng điều đó không giúp dự đoán lần book sau.


Dự định thử nghiệm	Thay đổi
Giảm learning rate	Thử lr 1e-3 (mặc định), 3e-4, 1e-4, 3e-5, 1e-5; thêm learning rate scheduler
Early stopping trên validation	Dừng khi kết quả trên tập validation không tăng sau 3 epoch, giữ lại epoch tốt nhất
Tăng regularization L2	Thử $\lambda_2 = 1e-7$ (mặc định), 1e-6, 1e-5, 3e-5, 1e-4, 1e-3

Loss train và recall validation theo từng epoch



💡 lr càng lớn, loss tụt càng nhanh và recall đạt đỉnh càng sớm rồi giảm: model học thuộc tập train. lr 1e-4 cho đỉnh cao nhất (0,4408 ở epoch 8) và giảm chậm nhất sau đỉnh.

Model overfit từ rất sớm nên cần tăng regularization (λ_2)



λ_2	Val R@5	Epoch đỉnh / dừng
1e-7 (mặc định)	0,2147	4 / 7
1e-6	0,2149	4 / 7
1e-5	0,2160	5 / 8
3e-5	0,2175	11 / 14
1e-4	0,2074	1 / 4
1e-3	0,2061	21 / 24

- Ở $\lambda_2 = 1e-7$, val Recall@5 đạt đỉnh ở epoch 3-4 rồi giảm trong khi loss train vẫn giảm (4,41 $\rightarrow$ 2,54): model học thuộc dữ liệu train. Tăng λ_2 lên $1e-5 - 3e-5$ cho đỉnh cao hơn và đến muộn hơn; từ $1e-4$ trở lên thì quá mạnh, loss train gần như đứng yên.

Sáu biến thể: 2 cách train × 3 hạng SVD

KẾT QUẢ TRÊN TẬP VALIDATION VỚI RECALL@5

Hạng SVD	BPR · có negative sampling	Full softmax · không negative sampling
q = 10 · SVD chính xác	0,1616	0,1711
q = 5 · svd_lowrank	0,1962	0,1965
q = 2 · SVD chính xác	0,2093	0,2102

FULL SOFTMAX THAY CHO BPR

Do tập item chỉ có 100 hotel cluster nên việc tính toán softmax trên 100 item không gây tốn kém quá lớn, trong khi lại loại bỏ nhiễu do lấy mẫu ngẫu nhiên của BPR

ĐỔI HẠNG SVD Q

Contrastive loss kéo embedding về gần view SVD với hạng q.
q nhỏ chỉ giữ vài hướng chung quan trọng nhất nên có tác dụng; q lớn thì SVD view gần graph gốc và không còn kéo model khỏi việc học thuộc.

Thêm số lần book vào graph: Recall@5 trên validation tăng từ 0,2102 lên 0,2160

Thử nghiệm trọng số cạnh (user, cluster) bằng số lần user đã book cluster đó thay vì 0-1: 84,4% cặp book 1 lần, 11,1% book 2 lần, 4,4% từ 3 lần. Positive của loss giữ nguyên; cả hai bản đều dùng full softmax, q = 2, lr bắt đầu 1e-4, chọn epoch tốt nhất trên validation.

Model	Val R@5	Val R@20	Val N@5	Val MAP@5
LightGCL, cạnh 0-1	0,2102	0,4870	0,1573	0,1218
LightGCL, cạnh theo số lần book	0,2160	0,4958	0,1633	0,1273

RECALL@5 VALIDATION

+2, 8%

0,2102 → 0,2160.

NDCG@5 VALIDATION

+3, 8%

Cluster đúng được xếp lên cao hơn; MAP@5 +4,5%.

RECALL@20 VALIDATION

+1, 8%

0,4870 → 0,4958: cuối danh sách cũng tăng.

Time attention: ưu tiên lần book gần nhất

Ý tưởng: trước khi lan truyền, chia lại trọng số các cạnh của từng user (và từng cluster) theo thời gian book, để cluster vừa book gần đây đóng góp nhiều hơn vào embedding.

1 · DÙNG THÔNG TIN VỀ RECENCY

Mỗi cạnh (user, cluster) lấy ra thời điểm book gần nhất của cặp đó.

2 · CHIA LẠI TRỌNG SỐ TRONG TỪNG USER

Softmax trên các cạnh của mỗi user: tổng bằng 1, cạnh book gần đây nhận phần lớn hơn.
Mỗi hotel cluster cũng chia lại như vậy trên các user đã book nó.

3 · LAN TRUYỀN VỚI TRỌNG SỐ MỚI

Trọng số mỗi cạnh = $\frac{1}{2}$ trọng số cũ (theo số lần book) + $\frac{1}{2}$ trọng số thời gian. Cách lan truyền giữ nguyên.

Model	Val R@5	Val R@20	Val N@5	Val MAP@5
LightGCL, trọng số cạnh 0–1	0,2102	0,4870	0,1573	0,1218
LightGCL, trọng số cạnh theo số lần book	0,2160	0,4958	0,1633	0,1273
LightGCL + time attention	0,2296	0,5229	0,1738	0,1361

HIỆU QUẢ

Recall@5 trên validation tăng từ 0,2160 (cạnh theo số lần book) lên 0,2296, cao nhất ở cả bốn chỉ số. Trọng số thời gian lớn hơn nhiều so với ma trận kề nên embedding user gần như là trung bình các cluster đã book, nghiêng về cluster book gần nhất; vì vậy cần L2 mạnh hơn bản thường ($\lambda_2 = 1e-4$ thay vì $1e-5$) để không overfit.

Kết quả trên test: time attention vượt History ở mọi chỉ số

Model	R@5	R@10	R@20	N@5	N@10	N@20	MAP@5	MAP@10	MAP@20
Popular	0,1523	0,2522	0,4047	0,1082	0,1431	0,1857	0,0824	0,0966	0,1087
History	0,2308	0,3404	0,4840	0,1742	0,2127	0,2529	0,1380	0,1542	0,1663
LightGCL, cạnh 0-1	0,2095	0,3273	0,4860	0,1544	0,1961	0,2408	0,1203	0,1380	0,1518
LightGCL, cạnh theo số lần book	0,2166	0,3335	0,4927	0,1612	0,2025	0,2474	0,1263	0,1439	0,1579
LightGCL + time attention	0,2353	0,3599	0,5308	0,1765	0,2205	0,2687	0,1395	0,1584	0,1735

Kết quả cuối trên test: thêm booking 09-10/2014 vào graph, không train lại

USER CŨ · ĐÃ BOOK TRƯỚC 11/2014 · 150.971 USER

Model	R@5	R@20	N@5	N@20	MAP@5	MAP@20
Popular	0,1523	0,4047	0,1082	0,1857	0,0824	0,1087
History	0,2308	0,4840	0,1742	0,2529	0,1380	0,1663
LightGCL + time attention	0,2353	0,5308	0,1765	0,2687	0,1395	0,1735

TRONG ĐÓ BOOK LẦN ĐẦU 09-10/2014 · 15.382 USER

Model	R@5	R@20	N@5	N@20	MAP@5	MAP@20
Popular	0,1501	0,3881	0,1061	0,1788	0,0808	0,1052
History	0,2325	0,4578	0,1851	0,2541	0,1519	0,1757
LightGCL + time attention	0,2411	0,5240	0,1906	0,2782	0,1561	0,1881

Model train trên dữ liệu trước 09/2014. Khi chấm test, booking 09-10 được thêm vào ma trận, chỉ cập nhật trọng số attention trên ma trận mới rồi truyền embedding lại, không train lại (fold-in): R@5 user cũ tăng từ 0,2101 (graph đến 08/2014) lên 0,2353; user book lần đầu 09-10 từ 0,1501 (Popular) lên 0,2411.

 **Cold-start:** 32,2% user trên tập test chưa book trước 11/2014 nên không có trong graph và không có embedding. Với nhóm này mọi phương pháp, kể cả History, dùng chung danh sách Popular (R@5 0,1323), nên không đưa vào bảng.