

LightGCL trên Expedia

Thử nghiệm và kết quả

Hai baseline để so sánh: Popular và History

POPULAR

Cùng một danh sách cho mọi user

Xếp 100 cluster theo số user đã đặt cluster đó trong giai đoạn train (trước 09/2014).

TOP-5 TRÊN EXPEDIA

91 • 48 • 42 • 59 • 28

Lần lượt 9,5%, 7,0%, 6,1%, 5,8% và 5,6% user đã đặt

Mốc tối thiểu: model nào thua Popular là chưa học được gì từ từng user.

HISTORY

Ưu tiên cluster user đã đặt

Các cluster user đã đặt trong giai đoạn train đứng đầu, đặt càng nhiều lần càng xếp trước, hoà nhau thì theo Popular. Các vị trí còn lại lấp theo thứ tự Popular.

VÍ DỤ MINH HOẠ

User đặt cluster 7 hai lần và cluster 30 một lần:

7 • 30 • 91 • 48 • 42

Mạnh vì user hay đặt lại: 15,6% cặp (user, cluster) ở train được đặt hơn một lần; 12,6% cặp ở test là đặt lại cluster cũ.

- Hai baseline và LightGCL được chấm trên cùng 135.589 user test có trong graph train, cùng nhãn và cùng metric.

Tái lập LightGCL trên Yelp: kết quả giống so với paper

Metric	Paper	Notebook	Lệch
Recall@20	0,0985	0,0975	-1,0%
NDCG@20	0,0842	0,0843	+0,1%
Recall@40	0,1553	0,1559	+0,4%
NDCG@40	0,1051	0,1055	+0,4%

 CÙNG ĐIỀU KIỆN VỚI PAPER

Bộ Yelp đã chia sẵn của repo HKUDS (29.601 user, 24.734 item), cấu hình mặc định, 100 epoch. Mốc so sánh là Table 6 (Appendix E), kết quả của code hiện có trên GitHub.

- Model, vòng lặp train và cách tính metric này được dùng lại nguyên vẹn cho Expedia.

Chia tập train/test/validation theo thời gian, đánh giá trên user đã book trong graph

Giai đoạn	Thời gian	Quy mô	Dùng để
Train	01/2013 – 08/2014	Booking: 664.727 user × 100 cluster, 1.776.919 cạnh	Dựng graph, train
Validation	09–10/2014	226.277 user	Early stopping
Test	11–12/2014	222.688 user, 60,9% có trong graph	Báo cáo kết quả

ĐÁNH GIÁ

- Recall@K, NDCG@K với K = 5, 10, 20
- 135.589 user test có trong graph train
- Giữ các cluster user đã đặt trong danh sách

CẤU HÌNH CHUNG

- d = 64, 2 layer, temp 0,2, $\lambda_1 = 0,2$, $\lambda_2 = 1e-7$
- lr 1e-4, batch 1024, tối đa 20 epoch
- Early stopping theo val Recall@5, patience 3

Từ Yelp sang Expedia: graph chỉ định từ booking

Khía cạnh	Yelp (paper)	Expedia (thử nghiệm này)
Tương tác	Đánh giá user-business, có sẵn trong bộ dữ liệu của tác giả	Chỉ dòng booking (is_booking = 1); 34,7 triệu dòng click không dùng
Item	24.734 business	100 hotel_cluster
Cạnh của graph	Mỗi cặp (user, business); trung bình 36 item mỗi user	Mỗi cặp (user, cluster) đã đặt; đặt lại nhiều lần gộp thành 1 cạnh; trung bình 2,7 cluster mỗi user
Chia dữ liệu	Train/test chia sẵn bởi tác giả	Theo thời gian: train trước 09/2014, validation 09-10, test 11-12/2014
Chọn tham số	100 epoch cố định	Early stopping theo val Recall@5, patience 3
lr / batch	1e-3 / 4096	1e-4 / 1024 (contrastive loss trên 665 nghìn user)

- Model, vòng lặp train và cách tính metric giữ nguyên như bản đã kiểm chứng trên Yelp; chỉ dữ liệu, cách chia, cách chấm và cách chọn tham số thay đổi.

LightGCL tốt nhất vượt History ở Recall@20, chưa vượt ở top-5

RECALL@20 · BẢN TỐT NHẤT

0,4830

Không negative sampling, q=2; History đạt 0,4716 (+2,4%).

RECALL@5 · CÙNG BẢN ĐÓ

0,2044

Vẫn thấp hơn History 0,2150 (-4,9%).

HẠNG SVD 5 → 2

+7-8%

Recall@5 tăng khi hạ q, ở cả hai cách train.

- Code được kiểm chứng trước khi dùng cho Expedia: tái lập LightGCL trên Yelp lệch tối đa 1,0% so với paper.

Validation giảm vì chỉ có 100 cluster: giảm lr xuống $1e-4$

Với cấu hình gốc, recall trên validation đạt đỉnh ngay epoch đầu rồi giảm dần.

🔍 NGUYÊN NHÂN

Danh mục chỉ có 100 cluster

Trung bình mỗi user chỉ cần “học thuộc” 2–3 cluster của mình, model mất dần tín hiệu độ phổ biến.

🕒 VÌ SAO PHẢI GIẢM LR



lr $1e-3$ của code gốc quá lớn

Một epoch Expedia (batch 1024) có 1.736 bước Adam, gấp 6,6 lần một epoch Yelp (batch 4096), nên với lr $1e-3$ model học thuộc ngay trong epoch đầu.

lr $1e-4$

cho kết quả tốt nhất: val Recall@20 đạt đỉnh cao nhất, 0,4408 ở epoch 8, rồi giảm chậm nên early stopping bắt được. Mọi thử nghiệm phía sau dùng lr $1e-4$.

Loss train và recall validation theo từng epoch



💡 lr càng lớn, loss tụt càng nhanh và recall đạt đỉnh càng sớm rồi giảm: model học thuộc tập train. lr 1e-4 cho đỉnh cao nhất (0,4408 ở epoch 8) và giảm chậm nhất sau đỉnh.

Bốn biến thể: 2 cách train × 2 hạng SVD

CÓ NEGATIVE SAMPLING

BPR, 1 cluster âm mỗi cặp

KHÔNG NEGATIVE SAMPLING

Full softmax trên 100 cluster

HẠNG SVD

val Recall@5 0,1962

Epoch tốt nhất 13, dừng ở 16

val Recall@5 0,1965

Epoch tốt nhất 4, dừng ở 7

q = 5

svd_lowrank, như
code gốc

val Recall@5 0,2093

Epoch tốt nhất 10, dừng ở 13

val Recall@5 0,2101

Epoch tốt nhất 3, dừng ở 6

q = 2

SVD chính xác

- Full softmax so mỗi cặp (user, cluster dương) với cả 100 cluster nên không cần lấy mẫu âm, và còn rẻ hơn lấy mẫu. Graph, view SVD và contrastive loss phía user giữ nguyên.

Kết quả trên test: History vẫn dẫn ở top-5

Model	R@5	R@10	R@20	N@5	N@10	N@20
Popular	0,1526	0,2529	0,4066	0,1084	0,1436	0,1865
History	0,2150	0,3252	0,4716	0,1604	0,1991	0,2401
Có negative sampling, q=5	0,1883	0,2894	0,4256	0,1390	0,1748	0,2134
Không negative sampling, q=5	0,1895	0,2952	0,4384	0,1400	0,1774	0,2179
Có negative sampling, q=2	0,2016	0,3147	0,4716	0,1471	0,1871	0,2314
Không negative sampling, q=2	0,2044	0,3231	0,4830	0,1491	0,1910	0,2362

135.589 user test có trong graph train; giữ các cluster user đã đặt; mỗi model dùng tham số của epoch có val Recall@5 tốt nhất. Chữ cam là giá trị cao nhất mỗi cột: History ở 5/6 metric, bản không negative sampling với q=2 (dòng tô xanh) ở R@20.

Ba điều rút ra từ bảng kết quả

1



q=2 tốt hơn q=5 ở mọi metric

Recall@5 tăng từ 0,1883 lên 0,2016 với BPR (+7,1%) và từ 0,1895 lên 0,2044 với softmax (+7,9%).

2



Bỏ negative sampling nhanh hơn và hội tụ nhanh hơn

Với q=2: Recall@5 0,2044 so với 0,2016. Epoch tốt nhất 3–4 so với 10–13, tức tiết kiệm khoảng 3 lần thời gian train.

3



History vẫn mạnh nhất ở đầu danh sách

Bản tốt nhất thắng ở Recall@20 (0,4830 so với 0,4716) nhưng thua ở Recall@5 (0,2044 so với 0,2150) và NDCG@20 (0,2362 so với 0,2401).

Hướng phát triển tiếp theo: theo góp ý của mentor

ĐÁNH GIÁ

1 Tách user mới (cold-start)

Chia train / val / test ngay trong tập train của Kaggle, rồi đo khả năng của model với user mới ở val và test (34,3% và 39,1% chưa có trong graph train).

2 Tính lại độ đo bằng Precision@K

Báo cáo Precision@K (K = 5, 10, 20) cùng Recall@K và NDCG@K cho mọi model và cả hai baseline.

MÔ HÌNH VÀ HUẤN LUYỆN

3 Learning rate scheduler

Thay lr cố định bằng lr giảm dần theo epoch: lr 1e-3 đạt đỉnh ngay epoch 1, còn lr 1e-4 cần 8–12 epoch.

4 Trọng số theo số lần book

Graph và SVD dùng số lần book thay vì 0/1: cặp đặt 2 lần được đặt lại ở validation 11,66%, đặt 1 lần chỉ 6,64%.

5 Embedding 32 chiều

Giảm d từ 64 xuống 32 để cùng VRAM GPU chạy được nhiều lượt hơn: embedding và trạng thái Adam nhẹ đi một nửa.