



Methodology

Phân tích từng thuật toán trước khi chọn methodology cho bài toán next-best-product trên dữ liệu đặt phòng khách sạn.

Vì sao chọn Collaborative Filtering

Hệ gợi ý có nhiều hướng — Collaborative Filtering, Content-based, Context-aware. Bài toán next-best-product về bản chất là khai thác mẫu hình hành vi lặp lại giữa nhiều user và nhiều hotel — đúng thể mạnh của Collaborative Filtering.

01

Ma trận CF sẵn có

user × hotel_cluster dựng trực tiếp từ is_booking, tách được click/book.

02

Thiếu content

hotel_cluster chỉ là mã ẩn danh — không hạng sao, tiện nghi, giá phòng.

03

Cold-start nặng

58,43% user chỉ đặt ≤1 lần, chỉ đóng góp 10,52% booking.

04

Session > row

Gộp theo "chuyến nghiên cứu" nâng tỷ lệ chốt từ 7,97% lên 21–26%.

- Phát triển sâu **một** hướng CF thay vì kết hợp nhiều phương pháp. Content-based & Context-aware: ghi nhận để so sánh, không phải trọng tâm.

Hai nhánh Collaborative Filtering

Sau khi tìm hiểu các phương pháp SOTA hiện nay, Collaborative Filtering được chia thành 2 hướng phát triển chính:

GRAPH-BASED



Lọc cộng tác dựa trên đồ thị

Biến lịch sử tương tác user-item thành một đồ thị (graph): mỗi user và mỗi item là một "điểm" (node), mỗi lượt tương tác là một "đường nối" (edge). Thông tin được lan truyền qua nhiều bước trên đồ thị để suy luận sở thích gián tiếp — kể cả giữa những user/item chưa từng tương tác trực tiếp với nhau.

Input điển hình: ma trận (user, item) đã tương tác — không cần biết thứ tự thời gian.

SESSION-BASED



Lọc cộng tác dựa trên phiên truy cập

Chỉ nhìn vào chuỗi hành vi trong một phiên truy cập (session) hiện tại của user, không cần biết lịch sử dài hạn hay danh tính cố định. Dự đoán hành động tiếp theo dựa trên thứ tự các hành động đã xảy ra trong phiên đó.

Input điển hình: chuỗi ($\text{item}_1 \rightarrow \text{item}_2 \rightarrow \dots$) theo đúng thứ tự thời gian trong 1 phiên.

3 kỹ thuật dùng chung cho cả 2 nhánh

Áp dụng được lên cả Graph-based lẫn Session-based, chỉ khác ở loại dữ liệu.

01



Negative Sampling

Lấy 1 số nhỏ hotel chưa tương tác làm ví dụ "không quan tâm" thay vì so với toàn danh mục.

VÍ DỤ

User A chỉ đặt hotel_cluster #17 → chọn ngẫu nhiên vài cluster A chưa từng đặt (#3, #42, #88) làm mẫu âm, thay vì so với toàn bộ ~100 cluster.

02



Contrastive Learning

Không cần nhãn: tạo 2 phiên bản dữ liệu gốc, dạy mô hình nhận ra chúng là "cùng một đối tượng".

VÍ DỤ

Cùng 1 graph tương tác, tạo thêm 1 "bản sao" — dạy mô hình: embedding của user A ở cả 2 bản phải gần nhau, còn khác user B thì tách xa.

03



Sampled Softmax

Kết hợp cả 2 ý tưởng trên vào 1 hàm mất mát — phổ biến nhất trong nghiên cứu 2015–2026.

VÍ DỤ

Thay vì tính điểm cho toàn bộ ~100 hotel_cluster mỗi lần huấn luyện, chỉ tính cho cluster đúng + vài cluster lấy mẫu (giống Negative Sampling), rồi dùng softmax để xếp hạng.

5 thuật toán, phân tích trước khi chọn

Để không chỉ dựa vào lý luận chung, nhóm nghiên cứu sâu 5 thuật toán cụ thể — 3 Graph-based, 2 Session-based — theo cùng 4 tiêu chí, rồi mới kết luận chọn baseline ở mục 10.



1 • Ý tưởng



2 • Mạnh & yếu



3 • Điều kiện dùng



4 • Phù hợp Expedia

GRAPH-BASED • 3 ỨNG VIÊN

LightGCL (ICLR 2023) • SCCF (KDD 2024) • RaDAR (WWW 2026)

SESSION-BASED • 2 ỨNG VIÊN

SASRec / TiSASRec (2018/2020) • TRON (RecSys 2023)

LightGCL

Ý TƯỞNG

Vẫn lan truyền thông tin qua graph như bình thường, nhưng thêm 1 "phiên bản đối chiếu" của graph tạo bằng SVD (phép nén ma trận, giữ xu hướng chính, bỏ nhiễu) — thay vì tạo phiên bản đối chiếu bằng cách xoá ngẫu nhiên node/edge như các phương pháp contrastive learning (học đối chiếu) khác hay làm.

MẠNH & YẾU

Mạnh: không cần dò cách xoá ngẫu nhiên node/edge vì SVD tính sẵn, không ngẫu nhiên. Yếu: phải tính lại SVD khi dữ liệu tương tác đổi nhiều (không cập nhật dần được), và phải chọn đúng số chiều giữ lại (gọi là q).

ĐIỀU KIỆN DÙNG


GPU tiêu chuẩn + thư viện SVD xấp xỉ trên ma trận thưa. Mã nguồn chính thức ổn định (HKUDS/LightGCL).

PHÙ HỢP EXPEDIA

Ma trận thưa + thiên lệch phổ biến — đúng bối cảnh LightGCL nhắm tới. 58,43% cold-start giới hạn lợi ích view toàn cục.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Yelp



LightGCL, 4 bước – không công thức



SCCF

🔍 Ý TƯỞNG

Chứng minh bằng lý thuyết rằng việc sử dụng contrastive learning (học đối chiếu) thực chất đã làm đúng việc lan truyền thông tin qua graph — nên bỏ hẳn các lớp lan truyền, chỉ giữ 1 bảng embedding đơn giản cộng contrastive loss thiết kế lại.

📝 MẠNH & YẾU

Mạnh: rẻ nhất trong nhóm vì không có bước lan truyền nào, tránh được over-smoothing (embedding các node trở nên giống nhau khi xếp quá nhiều lớp). Yếu: mất tín hiệu gián tiếp kiểu "bạn của bạn" mà lan truyền nhiều lớp nắm trực tiếp được.

⚙️ ĐIỀU KIỆN DÙNG


Nhẹ hơn về GPU/bộ nhớ (không propagation). RecBole, embedding size 64 — cấu hình tiêu chuẩn.

🏠 PHÙ HỢP EXPEDIA

Phương án rẻ nhất để thử nhanh — phép thử đối chiếu, chưa chắc đủ mạnh cho nhóm cold-start.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Yelp2018



RaDAR

Ý TƯỞNG

Kết hợp 3 kỹ thuật: (1) diffusion — thêm nhiều dần vào graph rồi học cách khử nhiễu, giống mô hình sinh ảnh nhưng áp dụng cho cấu trúc graph; (2) tính lại độ tin cậy từng liên kết dựa trên đặc trưng 2 node; (3) đối chiếu 2 nhánh không đối xứng (1 nhánh học, 1 nhánh ổn định) với mẫu âm lấy từ cả batch — nắm được cả user giống nhau qua liên kết gián tiếp (2 bước, không chỉ 1 bước trực tiếp).

MẠNH & YẾU

Mạnh: vượt qua toàn bộ phương pháp được so sánh trong paper. Yếu: phức tạp nhất trong nhóm Graph-based (3 thành phần phải phối hợp), tốn thêm chi phí tính toán cho bước khử nhiễu và bước đối chiếu trên toàn batch.

ĐIỀU KIỆN DÙNG

Cần GPU + tinh chỉnh batch size (chi phí tăng theo batch bình phương).

PHÙ HỢP EXPEDIA

Khớp sát đặc điểm thưa của Expedia, nhưng chi phí cao nhất trong nhóm.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Yelp



SASRec / TiSASRec

🕒 Ý TƯỞNG

Coi lịch sử tương tác của mỗi user là 1 chuỗi theo thời gian, dùng self-attention để tự học nên chú ý hành động nào trong quá khứ khi dự đoán item tiếp theo. TiSASRec thêm khoảng cách thời gian thực tế giữa các lượt tương tác, không chỉ dựa vào thứ tự.

📁 MẠNH & YẾU

Mạnh: là baseline sequential được dùng phổ biến nhất, không cần xây graph nên pipeline dữ liệu nhẹ hơn hẳn Graph-based. Yếu: cần chuỗi tương tác đủ dài để "có gì đó để nhìn" — chỉ 1-2 tương tác thì attention gần như không học được gì.

⚙️ ĐIỀU KIỆN DÙNG


Cần log có thứ tự thời gian (TiSASRec cần cả khoảng cách thời gian thực). Chi phí tính toán không phải vấn đề ở quy mô session thường.

👥 PHÙ HỢP EXPEDIA

58,43% cold-start + session dao động 7,97-25,78% → phần lớn user không đủ chuỗi để mô hình học được gì.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Amazon Beauty (paper TiSASRec, WSDM 2020) — báo cáo Hit@10/NDCG@10,



TRON

🔍 Ý TƯỞNG

Xây trên kiến trúc SASRec (mục 08), nhưng thay vì chỉ lấy 1 mẫu âm ngẫu nhiên mỗi bước, lấy nhiều mẫu âm cùng lúc từ 2 nguồn trộn lẫn (chọn đều trên toàn danh mục + chọn theo độ phổ biến thực tế), rồi tính loss kiểu "so 1 lần với nhiều lựa chọn" (Sampled Softmax dạng listwise) thay vì so từng cặp một.

🕒 MẠNH & YẾU

Production thật, A/B test +18,14% CTR so với SASRec. Nhưng kế thừa nguyên giới hạn cần-chuỗi-dài của SASRec.

⚙️ ĐIỀU KIỆN DÙNG


Cùng input như SASRec, GPU tương đương. Mã nguồn công khai (github.com/otto-de/TRON) + dataset ẩn danh đi kèm.

🏢 PHÙ HỢP EXPEDIA

Thừa hưởng giới hạn sequential của SASRec. Giá trị lớn nhất: mình chứng "Negative Sampling + Sampled Softmax" kết hợp thật sự hiệu quả.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Diginetica (paper TRON, RecSys 2023) — báo cáo Recall@20/MRR@20, không phải NDCG@20



Sau khi phân tích cả 5 method – LightGCL được chọn

1

LightGCL làm mô hình nền tảng (baseline) — kế thừa lan truyền graph đơn giản đã kiểm chứng rộng rãi, cộng nhánh contrastive learning qua SVD giải quyết trực tiếp đặc điểm thừa & ít feedback tích cực mà EDA đã chỉ ra.

SO VỚI SCCF & RADAR

Không thay đổi lựa chọn — cả hai dùng cùng kiểu lan truyền đơn giản LightGCL cũng dùng làm nền. Cải tiến của chúng (làm sạch graph, thiết kế loss) đưa vào lộ trình Bước 3, không phải baseline đầu tiên.

SO VỚI SASREC/TISASREC & TRON

Xác nhận cụ thể hơn: 58,43% cold-start + ranh giới session mơ hồ khiến sequential khó đủ tín hiệu. Ý tưởng lấy mẫu âm + Sampled Softmax của TRON vẫn mượn lại cho Bước 2 & 4.

RỦI RO & CHI PHÍ

ICLR 2023, hàng trăm trích dẫn, mã nguồn ổn định — rủi ro thấp hơn RaDAR (2026, rất mới) hay SCCF (2024, ít triển khai quy mô lớn). SVD tính một lần rẻ hơn diffusion.


HẠN CHẾ CÒN LẠI

Nhóm cold-start vẫn ít hưởng lợi từ view SVD toàn cục — chính là lý do lộ trình mục 11 tiếp tục bổ sung Negative Sampling & denoising.

⚠ Số liệu Recall@20/NDCG@20 ở mục 05–09 lấy từ dataset và cách tiền xử lý riêng của từng paper (kể cả cùng tên "Yelp" hay "Gowalla") — không so sánh trực tiếp được giữa 5 thuật toán, chỉ cho thấy mỗi thuật toán vượt baseline riêng của nó bao nhiêu.

Mở rộng từ baseline

Mỗi bước chỉ thêm đúng 1 kỹ thuật, đánh giá độc lập trên cùng dữ liệu — tham khảo trực tiếp từ 4 thuật toán ở mục 06–09.



EVAL Recall@K và NDCG@K trên cùng tập kiểm tra, so với baseline LightGCL.