



Methodology

Phân tích từng thuật toán trước khi chọn methodology cho bài toán next-best-product trên dữ liệu đặt phòng khách sạn.

Vì sao chọn Collaborative Filtering

Hệ gợi ý có nhiều hướng — Collaborative Filtering, Content-based, Context-aware. Bài toán next-best-product với tập dataset Expedia về bản chất là khai thác mẫu hành vi lặp lại giữa nhiều user và nhiều hotel — đúng thể mạnh của Collaborative Filtering.

01

Ma trận CF sẵn có

user × hotel_cluster dựng trực tiếp từ is_booking, tách được click/book.

02

Thiếu content

hotel_cluster chỉ là mã ẩn danh — không có các thông tin cụ thể về hạng sao, tiện nghi, giá phòng.

03

Cold-start nặng

58,43% user chỉ đặt ≤ 1 lần, chỉ đóng góp 10,52% booking.

04

Định nghĩa session

Việc định nghĩa "session" là gì sẽ làm thay đổi tỷ lệ booking của user.

- Phát triển sâu **một** hướng CF thay vì kết hợp nhiều phương pháp. Content-based & Context-aware: ghi nhận để so sánh, không phải trọng tâm.

Hai nhánh Collaborative Filtering

Sau khi tìm hiểu các phương pháp SOTA hiện nay, Collaborative Filtering được chia thành 2 hướng phát triển chính:

GRAPH-BASED



Lọc cộng tác dựa trên đồ thị

Biến lịch sử tương tác user-item thành một đồ thị (graph): mỗi user và mỗi item là một node, mỗi lượt tương tác là một edge. Thông tin được lan truyền qua nhiều bước trên đồ thị để suy luận sở thích gián tiếp — kể cả giữa những user/item chưa từng tương tác trực tiếp với nhau.

Input điển hình: ma trận (user, item) đã tương tác — không cần biết thứ tự thời gian.

SESSION-BASED



Lọc cộng tác dựa trên phiên truy cập

Chỉ nhìn vào chuỗi hành vi trong một phiên truy cập (session) hiện tại của user, không cần biết lịch sử dài hạn hay danh tính cố định. Dự đoán hành động tiếp theo dựa trên thứ tự các hành động đã xảy ra trong phiên đó.

Input điển hình: chuỗi (item₁ → item₂ → ...) theo đúng thứ tự thời gian trong 1 phiên.

3 kỹ thuật dùng chung cho cả 2 nhánh

Negative Sampling là kỹ thuật nền — Contrastive Learning và Sampled Softmax đều dùng lại nó, cho 2 mục đích khác nhau, không phải 3 kỹ thuật độc lập ngang hàng.

01



KỸ THUẬT NỀN

Negative Sampling

Lấy 1 số nhỏ hotel chưa tương tác làm mẫu "âm" để so sánh, thay vì dùng toàn bộ danh mục — 2 kỹ thuật bên phải đều xây trên nền này.

VÍ DỤ

User A chỉ đặt hotel_cluster #17 → chọn ngẫu nhiên vài cluster A chưa từng đặt (#3, #42, #88) làm mẫu âm, thay vì so với toàn bộ ~100 cluster.

02



DÙNG LẠI NEGATIVE SAMPLING

Contrastive Learning

Không cần nhần: tạo 2 phiên bản dữ liệu gốc, kéo gần cặp "cùng 1 đối tượng" — còn cặp "đẩy xa" chính là mẫu âm lấy từ Negative Sampling.

VÍ DỤ

Cùng 1 graph tương tác, tạo thêm 1 "bản sao" — dạy mô hình: embedding của user A ở cả 2 bản phải gần nhau, còn khác user B thì tách xa.

03



DÙNG LẠI NEGATIVE SAMPLING

Sampled Softmax

Không phải kỹ thuật riêng biệt — là hàm mất mát dạng phân loại (softmax), nhưng chỉ tính trên item đúng + mẫu âm lấy từ Negative Sampling, thay vì toàn bộ danh mục.

VÍ DỤ

Thay vì tính điểm cho toàn bộ ~100 hotel_cluster mỗi lần huấn luyện, chỉ tính cho cluster đúng + các cluster lấy mẫu ở kỹ thuật 01, rồi dùng công thức softmax để xếp hạng.

5 thuật toán, phân tích trước khi chọn

Để không chỉ dựa vào lý luận chung, em thực hiện nghiên cứu sâu 5 thuật toán cụ thể — 3 Graph-based, 2 Session-based — theo cùng 4 tiêu chí, rồi mới kết luận chọn baseline.



1 • Ý tưởng



2 • Mạnh & yếu



3 • Điều kiện dùng



4 • Phù hợp Expedia

GRAPH-BASED • 3 ỨNG VIÊN


LightGCL (ICLR 2023) • SCCF (KDD 2024) • RaDAR (WWW 2026)

SESSION-BASED • 2 ỨNG VIÊN

SASRec / TiSASRec (2018/2020) • TRON (RecSys 2023)


Graph Convolutional Network hoạt động thế nào?

4 bước chuẩn dưới đây là khung chung của mọi phương pháp Graph-based CF. Cả 3 phương pháp graph-based đều xây trên khung này với cải tiến tương ứng.



💡 Việc xây dựng graph và lan truyền hầu như không đổi qua các thể hệ Graph-based CF gần đây .

LightGCL - 4 bước



LightGCL

🔍 CẢI TIẾN

Thêm 1 "phiên bản đối chiếu" của graph tạo bằng SVD (phép nén ma trận, giữ xu hướng chính, bỏ nhiễu) để huấn luyện đối chiếu, thay vì xoá ngẫu nhiên node/edge như các phương pháp contrastive learning khác hay làm.

📁 MẠNH & YẾU

Mạnh: không cần tìm cách xoá ngẫu nhiên node/edge vì SVD tính sẵn, không ngẫu nhiên.
Yếu: phải tính lại SVD khi dữ liệu tương tác đổi nhiều (không cập nhật dần được), và phải chọn đúng số chiều giữ lại (gọi là q).

⚙️ ĐIỀU KIỆN DÙNG


GPU tiêu chuẩn + thư viện SVD xấp xỉ trên ma trận thưa.
Mã nguồn chính thức ổn định (HKUDS/LightGCL).

🌐 PHÙ HỢP EXPEDIA

Ma trận thưa + thiên lệch phổ biến — đúng bối cảnh LightGCL nhắm tới. 58,43% cold-start giới hạn lợi ích view toàn cục.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Yelp



SCCF(Simple Contrastive Collaborative Filtering)

🔍 CẢI TIẾN

Bỏ hẳn khâu lan truyền (propagation) qua graph — chứng minh bằng lý thuyết rằng contrastive learning tự nó đã làm đúng việc lan truyền, nên chỉ giữ 1 bảng embedding cộng contrastive loss thiết kế lại.

📁 MẠNH & YẾU

Mạnh: rẻ nhất trong nhóm vì không có bước lan truyền nào, tránh được over-smoothing (embedding các node trở nên giống nhau khi xếp quá nhiều lớp).
Yếu: mất tín hiệu gián tiếp kiểu "bạn của bạn" mà lan truyền nhiều lớp nắm trực tiếp được.

⚙️ ĐIỀU KIỆN DÙNG


Nhẹ hơn về GPU/bộ nhớ (không propagation). RecBole, embedding size 64 — cấu hình tiêu chuẩn.

🌐 PHÙ HỢP EXPEDIA

Phương án rẻ nhất để thử nhanh — phép thử đối chiếu, chưa chắc đủ mạnh cho nhóm cold-start.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Yelp2018



RaDAR (Relation-aware Diffusion-Asymmetric Graph Contrastive Learning for Recommendation)

☁ CẢI TIẾN

Thêm cơ chế diffusion (thêm nhiều lần rồi học khử nhiễu) và tính lại độ tin cậy từng liên kết trước khi lan truyền. Thực hiện asymmetric contrastive learning (đối chiếu giữa 1 nhánh học, 1 nhánh ổn định) với negative sample lấy từ cả batch, song song với BPR.

📁 MẠNH & YẾU

Mạnh: kỹ thuật tiên tiến, vượt qua toàn bộ phương pháp được so sánh trong paper.

Yếu: phức tạp nhất trong nhóm Graph-based, tốn thêm chi phí tính toán cho bước khử nhiễu và bước đối chiếu trên toàn batch.

⚙ ĐIỀU KIỆN DÙNG

Cần GPU + tinh chỉnh batch size (chi phí tăng theo batch bình phương).

🌐 PHÙ HỢP EXPEDIA

Khớp sát đặc điểm thưa của Expedia, nhưng chi phí cao nhất trong nhóm.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Yelp



SASRec / TiSASRec

🕒 CẢI TIẾN

SASRec: dùng self-attention để tự học nên chú ý item nào trong quá khứ khi dự đoán item tiếp theo.
Cải tiến của TiSASRec: thêm khoảng cách thời gian thực tế giữa các lượt tương tác, không chỉ dựa vào thứ tự.

📁 MẠNH & YẾU

Mạnh: là baseline sequential được dùng phổ biến nhất, không cần xây graph nên pipeline dữ liệu nhẹ hơn hẳn Graph-based.
Yếu: cần chuỗi tương tác đủ dài để "có gì đó để nhìn" — chỉ 1–2 tương tác thì attention gần như không học được gì.

⚙️ ĐIỀU KIỆN DÙNG


Cần log có thứ tự thời gian (TiSASRec cần cả khoảng cách thời gian thực). Chi phí tính toán không phải vấn đề ở quy mô session thường.

👥 PHÙ HỢP EXPEDIA

58,43% cold-start + session dao động 7,97–25,78% → phần lớn user không đủ chuỗi để mô hình học được gì.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Amazon Beauty (paper TiSASRec, WSDM 2020) — báo cáo Hit@10/NDCG@10,



TRON

🔍 CẢI TIẾN

Xây trên kiến trúc SASRec, nhưng thay vì chỉ lấy 1 mẫu âm ngẫu nhiên mỗi bước, lấy nhiều mẫu âm cùng lúc từ 2 nguồn trộn lẫn (chọn đều trên toàn danh mục + chọn theo độ phổ biến thực tế), rồi tính loss kiểu "so 1 lần với nhiều lựa chọn" (Sampled Softmax dạng listwise) thay vì so từng cặp một.

🕒 MẠNH & YẾU

Production thật, A/B test +18,14% CTR so với SASRec. Nhưng kế thừa nguyên giới hạn cần-chuỗi-dài của SASRec.

⚙️ ĐIỀU KIỆN DÙNG


Cùng input như SASRec, GPU tương đương. Mã nguồn công khai (github.com/otto-de/TRON) + dataset ẩn danh đi kèm.

🏢 PHÙ HỢP EXPEDIA

Thừa hưởng giới hạn sequential của SASRec. Giá trị lớn nhất: mình chứng "Negative Sampling + Sampled Softmax" kết hợp thật sự hiệu quả.

KẾT QUẢ GỐC TRONG PAPER

Dataset: Diginetica (paper TRON, RecSys 2023) — báo cáo Recall@20/MRR@20, không phải NDCG@20



Sau khi phân tích cả 5 method – LightGCL được chọn

1

LightGCL làm mô hình nền tảng (baseline) — kế thừa lan truyền graph đơn giản đã kiểm chứng rộng rãi, cộng nhánh contrastive learning qua SVD giải quyết trực tiếp đặc điểm của ma trận thưa & ít feedback tích cực mà EDA đã chỉ ra.

SO VỚI SCCF & RADAR

SCCF sẽ làm mất đi trọng số học qua tương tác giữa user với item qua lan truyền, việc training diffusion model trong RaDAR yêu cầu chi phí lớn trong khi chưa chứng minh được kết quả sẽ tốt hơn phương pháp cơ bản.

SO VỚI SASREC/TISASREC & TRON

Việc lựa chọn các phương pháp session-based sẽ cần phải thử nghiệm và chọn ra định nghĩa session, đồng thời vẫn gặp vấn đề với dataset chiếm 58,43% cold-start.

RỦI RO & CHI PHÍ


ICLR 2023, hàng trăm trích dẫn, mã nguồn ổn định — rủi ro thấp hơn RaDAR (2026, rất mới) hay SCCF (2024, ít triển khai quy mô lớn). SVD tính một lần rẻ hơn training diffusion model.

HẠN CHẾ CÒN LẠI

Nhóm cold-start vẫn ít hưởng lợi từ view SVD toàn cục — cần thực hiện cải tiến hoặc bổ sung các kỹ thuật khác để hỗ trợ.

Mở rộng từ baseline

Sau khi chọn LightGCL làm baseline, em sẽ nghiên cứu để cải tiến và phát triển thêm methodology để phù hợp với dataset đã cho.



EVAL Recall@K và NDCG@K trên cùng tập kiểm tra, so với baseline LightGCL.